

黎曼流形上双层优化问题的单循环自适应算法探究

金琪

复旦大学大数据学院

24300270001@m.fudan.edu.cn

甘凌玮

复旦大学数学科学学院

23300180105@m.fudan.edu.cn

摘要

现有的解决黎曼双层优化 (RBO) 问题的方法需要预先掌握问题的阶信息 (一阶和二阶) 以及黎曼流形的曲率参数来确定步长, 当这些参数未知或计算成本过高时, 这在实际应用中存在局限性。现有求解黎曼流形上双层优化问题的双循环自适应算法 AdaRHD 计算复杂度较高, 梯度复杂度达到了 $\mathcal{O}(1/\epsilon^2)$ 。在本文中, 我们提出一个单循环 (Single-Loop) 的算法, 它的计算复杂度比 AdaRHD 要低且与现有求解黎曼流形上双层优化问题的非自适应算法的复杂度保持一致, 在寻找 ϵ -驻点时达到了 $\mathcal{O}(1/\epsilon)$ 的迭代复杂度 (与 AdaRHD 双循环算法一致), 以及 $\tilde{\mathcal{O}}(1/\epsilon)$ 梯度复杂度, 并给出了相应的收敛性分析与数据实验模拟。这种算法减少了对问题参数的先验知识要求, 并表现出了很强的鲁棒性。此外, 我们证明了用收缩映射 (retraction mapping) 代替指数映射 (exponential mapping) 仍能保持相同的复杂度界限。

关键词: 单循环自适应算法, 双层优化, 黎曼流形, 复杂度

1 引言

双层优化由于其在强化学习 [35, 26]、元学习 [3, 47, 30]、超参数优化 [18, 50, 69]、对抗学习 [4, 61, 62] 以及信号处理 [36, 16] 等领域的广泛应用而备受关注。本文重点研究“黎曼双层优化 (RBO)” [24, 15, 39], 这一框架出现在黎曼元学习 [55]、神经架构搜索 [52]、图像分割 [20]、黎曼极小极大优化 [33, 29, 73, 23, 63, 28] 以及低秩自适应 [70] 等应用中。RBO 的一般形式如下:

$$\begin{aligned} \min_{x \in \mathcal{M}_x} \quad & F(x) := f(x, y^*(x)), \\ \text{s.t.} \quad & y^*(x) = \arg \min_{y \in \mathcal{M}_y} g(x, y), \end{aligned} \tag{1}$$

其中 $\mathcal{M}_x, \mathcal{M}_y$ 分别是 d^x 维和 d^y 维的完备黎曼流形 [39], 函数 $f, g : \mathcal{M}_x \times \mathcal{M}_y \rightarrow \mathbb{R}$ 是光滑的, 下层函数 $g(x, y)$ 关于 y 是测地强凸的, 而上层函数 f 不要求是凸的。

为了解决问题 (1), 我们扩展了欧几里得自适应双层优化的最新进展 [67], 提出了自适应黎曼超梯度方法。虽然欧几里得分析的某些方面可以自然地延伸到黎曼设置中, 但流形的曲率参数引入了变形, 从而带来了独特的分析挑战。我们将设计解决 RBO 问题的自适应方法所面临的关键技术困难总结如下:

- (i) RBO 要求变量约束在黎曼流形上, 这使其本质上比欧几里得对应问题更复杂。此外, 测地强凸性、Lipschitz 连续性和曲率参数等关键参数在流形上的估计计算量巨大。因此, 流形的几何结构引入了变形, 在自适应算法的收敛性分析中制造了独特的挑战。
- (ii) 与单层黎曼优化相比, RBO 本质上涉及相互依赖的变量更新, 导致由于耦合的 (超) 梯度动力学而产生的复杂的步长选择挑战。
- (iii) 与非自适应 RBO 方法不同, 自适应步长策略在初始迭代期间可能表现出发散行为, 必须通过严格的处理来实现稳健的理论收敛分析。

在本文中，我们提出了全面的收敛性分析，展示了我们解决这些挑战的方法。

1.1 相关工作

在表 1 中，我们总结了与我们方法相关的研究，提供了它们的适用场景、是否具有自适应性，以及一阶和二阶信息的计算复杂度。请注意，为了简化起见，计算复杂度分析中省略了所有常数（如条件数）。关于相关工作的详细信息，请参阅附录 A。

表 1: 达到 ϵ -驻点的一阶和二阶复杂度比较。这里，“Euc”和“Rie”分别代表算法的约束区域是欧几里得空间和黎曼流形。符号“Det”、“F-S”和“Sto”分别代表适用于确定性、函数和以及随机问题。此外， G_f 和 G_g 是 f 和 g 的梯度复杂度。 JV_g 和 HV_g 是计算 g 的二阶交叉导数和 Hessian 向量积的复杂度。符号 $\tilde{\mathcal{O}}$ 表示与标准 $\mathcal{O}$ 符号相比省略了对数项。此外，符号“NA”表示相应的复杂度不适用。

方法	空间	自适应	类型	G_f	G_g	JV_g	HV_g
D-TFBO [67]	Euc	✓	Det	$\mathcal{O}(1/\epsilon)$	$\mathcal{O}(1/\epsilon^2)$	$\mathcal{O}(1/\epsilon)$	$\mathcal{O}(1/\epsilon^2)$
S-TFBO [67]				$\tilde{\mathcal{O}}(1/\epsilon)$	$\tilde{\mathcal{O}}(1/\epsilon)$	$\tilde{\mathcal{O}}(1/\epsilon)$	$\tilde{\mathcal{O}}(1/\epsilon)$
RHGD-HINV [24]	Rie	✗	Det	$\mathcal{O}(1/\epsilon)$	$\tilde{\mathcal{O}}(1/\epsilon)$	$\mathcal{O}(1/\epsilon)$	NA
RHGD-CG [24]				$\mathcal{O}(1/\epsilon)$	$\tilde{\mathcal{O}}(1/\epsilon)$	$\mathcal{O}(1/\epsilon)$	$\tilde{\mathcal{O}}(1/\epsilon)$
RHGD-NS [24]				$\mathcal{O}(1/\epsilon)$	$\tilde{\mathcal{O}}(1/\epsilon)$	$\mathcal{O}(1/\epsilon)$	$\tilde{\mathcal{O}}(1/\epsilon)$
RHGD-AD [24]				$\mathcal{O}(1/\epsilon)$	$\tilde{\mathcal{O}}(1/\epsilon)$	$\mathcal{O}(1/\epsilon)$	$\tilde{\mathcal{O}}(1/\epsilon)$
RSHGD-HINV [24]	Rie	✗	F-S	$\mathcal{O}(1/\epsilon^2)$	$\tilde{\mathcal{O}}(1/\epsilon^2)$	$\mathcal{O}(1/\epsilon^2)$	NA
RieBO [39]			Det	$\mathcal{O}(1/\epsilon)$	$\tilde{\mathcal{O}}(1/\epsilon)$	$\mathcal{O}(1/\epsilon)$	$\tilde{\mathcal{O}}(1/\epsilon)$
RieSBO [39]			Sto	$\mathcal{O}(1/\epsilon^2)$	$\tilde{\mathcal{O}}(1/\epsilon^2)$	$\mathcal{O}(1/\epsilon^2)$	$\tilde{\mathcal{O}}(1/\epsilon^2)$
RF ² SA [15]	Rie	✗	Det	$\tilde{\mathcal{O}}(1/\epsilon^{3/2})$	$\tilde{\mathcal{O}}(1/\epsilon^{3/2})$	NA	NA
RF ² SA [15]			Sto	$\tilde{\mathcal{O}}(1/\epsilon^{7/2})$	$\tilde{\mathcal{O}}(1/\epsilon^{7/2})$	NA	NA
AdaRHD-GD	Rie	✓	Det	$\mathcal{O}(1/\epsilon)$	$\mathcal{O}(1/\epsilon^2)$	$\mathcal{O}(1/\epsilon)$	$\mathcal{O}(1/\epsilon^2)$
AdaRHD-CG				$\mathcal{O}(1/\epsilon)$	$\mathcal{O}(1/\epsilon^2)$	$\mathcal{O}(1/\epsilon)$	$\tilde{\mathcal{O}}(1/\epsilon)$
AdaRHD-S(Ours)	Rie	✓	Det	$\tilde{\mathcal{O}}(1/\epsilon)$	$\tilde{\mathcal{O}}(1/\epsilon)$	$\tilde{\mathcal{O}}(1/\epsilon)$	$\tilde{\mathcal{O}}(1/\epsilon)$

1.2 贡献

本文引入了自适应黎曼超梯度下降（AdaRHD）算法，这是首个结合了完全自适应步长策略的方法，消除了 RBO 对参数特定先验知识的依赖。本文的贡献总结如下：

- (i) 我们引入了黎曼梯度下降和切空间共轭梯度两种策略来计算近似黎曼超梯度，并建立了精确超梯度与近似超梯度之间的误差界限；
- (ii) 我们开发了一种解决 RBO 问题的自适应算法，消除了对强凸性、Lipschitz 连续性或曲率参数先验知识的依赖。我们的方法达到了与非自适应参数依赖方法相匹配的收敛速度。此外，通过用计算效率高的收缩映射代替指数映射，我们的算法在保持相当的收敛保证的同时降低了计算成本。
- (iii) 对于解决黎曼流形上的平滑强凸问题（问题 (1) 的下层问题），据我们所知，我们提出的方法是首个具有非渐近收敛速度的自适应黎曼超梯度下降算法。

2 预备知识

在本节中，我们回顾黎曼流形上的标准定义和初步结论。此处给出的所有结果均见于文献 [38, 5, 24, 39]，为了简明起见，我们对其进行重述。

我们首先建立黎曼流形的基本性质和符号。黎曼流形的定义已在文献 [38, 5] 中给出。在黎曼流形 $\mathcal{M}$ 上点 $x \in \mathcal{M}$ 处的黎曼度量记为 $\langle \cdot, \cdot \rangle_x : T_x \mathcal{M} \times T_x \mathcal{M} \rightarrow \mathbb{R}$ ，其在切空间 $T_x \mathcal{M}$ 上诱导的范数定义为 $\|u\|_x = \sqrt{\langle u, u \rangle_x}$ (对于 $u \in T_x \mathcal{M}$)。接着，我们回顾指数映射和平行移动的定义。对于切向量 $u \in T_x \mathcal{M}$ 以及满足 $c(0) = x$ 、 $c(1) = y$ 和 $c'(0) = u$ 的测地线 $c : [0, 1] \rightarrow \mathcal{M}$ ，指数映射 $\text{Exp}_x : T_x \mathcal{M} \rightarrow \mathcal{M}$ 定义为 $\text{Exp}_x(u) = y$ 。指数映射的逆映射 $\text{Exp}_x^{-1} : \mathcal{M} \rightarrow T_x \mathcal{M}$ 称为对数映射 [5, 定义 10.20]，两点 $x, y \in \mathcal{M}$ 之间的黎曼距离由 $d(x, y) = \|\text{Exp}_x^{-1}(y)\|_x = \|\text{Exp}_y^{-1}(x)\|_y$ 给出。平行移动 $\mathcal{P}_{x_1}^{x_2} : T_{x_1} \mathcal{M} \rightarrow T_{x_2} \mathcal{M}$ 是一个保持内积结构的线性算子，满足对所有 $u, v \in T_{x_1} \mathcal{M}$ ，有 $\langle u, v \rangle_{x_1} = \langle \mathcal{P}_{x_1}^{x_2} u, \mathcal{P}_{x_1}^{x_2} v \rangle_{x_2}$ 。

现在我们定义黎曼流形上函数的关键性质。可微函数 $f : \mathcal{M} \rightarrow \mathbb{R}$ 的黎曼梯度 $\mathcal{G}f(x) \in T_x \mathcal{M}$ 是满足下式的唯一向量：

$$\langle \mathcal{G}f(x), u \rangle_x = \text{D}f(x)[u], \quad \forall u \in T_x \mathcal{M},$$

其中 $\text{D}f(x)[u]$ 表示 f 在 x 处沿 u 的方向导数 [59, 5, 39]。对于二次可微的 f ，黎曼 Hessian $\mathcal{H}f(x)$ 定义为 $\mathcal{G}f(x)$ 的协变导数。如果对于所有测地线 $c : [0, 1] \rightarrow \Omega$ (其中 $\Omega \subseteq \mathcal{M}$ 是测地凸集)， $f(c(t))$ 关于 $t \in [0, 1]$ 是 (强) 凸的，则函数 $f : \mathcal{M} \rightarrow \mathbb{R}$ 是 “测地 (强) 凸的” [39, 定义 4]。具体而言，如果 f 是二次可微的，则 f 的 μ -测地强凸性等价于 $\mathcal{H}f(x) \succeq \mu \text{Id}$ ，其中 Id 是恒等算子。类似地，如果满足下式，则 f 是 “测地 L_f -Lipschitz 光滑的”：

$$\|\mathcal{G}f(x) - \mathcal{P}_y^x \mathcal{G}f(y)\|_x \leq L_f d(x, y), \quad \forall x, y \in \mathcal{M},$$

对于二次可微的 f ，该性质等价于 $\mathcal{H}f(x) \preceq L_f \text{Id}$ 。

最后，对于双变量函数 $f : \mathcal{M}_x \times \mathcal{M}_y \rightarrow \mathbb{R}$ ， f 关于 x 和 y 的黎曼梯度分别记为 $\mathcal{G}_x f(x, y)$ 和 $\mathcal{G}_y f(x, y)$ ，而黎曼 Hessian 分别记为 $\mathcal{H}_x f(x, y)$ 和 $\mathcal{H}_y f(x, y)$ 。此外，在 [24, 39] 中讨论的黎曼交叉导数 $\mathcal{G}_{xy}^2 f(x, y) : T_y \mathcal{M}_y \rightarrow T_x \mathcal{M}_x$ 和 $\mathcal{G}_{yx}^2 f(x, y) : T_x \mathcal{M}_x \rightarrow T_y \mathcal{M}_y$ 是线性算子。此外，线性算子 $\mathcal{G} : T_y \mathcal{M}_y \rightarrow T_x \mathcal{M}_x$ 的算子范数定义为

$$\|\mathcal{G}\|_x = \sup_{u \in T_y \mathcal{M}_y, \|u\|_y=1} \|\mathcal{G}[u]\|_x.$$

基于定义在黎曼流形上函数的 Lipschitz 连续性 (见定义 B.1) 和测地强凸性概念，我们给出以下命题。

命题 2.1 ([5, 24, 39]). 对于函数 $f : \mathcal{M} \rightarrow \mathbb{R}$ ，如果其黎曼梯度 $\mathcal{G}f$ 是 L -Lipschitz 连续的，那么对于所有 $x, y \in \mathcal{U} \subseteq \mathcal{M}$ ，有

$$f(y) \leq f(x) + \langle \mathcal{G}f(x), \text{Exp}_x^{-1}(y) \rangle_x + \frac{L}{2} d^2(x, y).$$

如果 f 是 μ -测地强凸的，那么对于所有 $x, y \in \mathcal{U}$ ，有

$$f(y) \geq f(x) + \langle \mathcal{G}f(x), \text{Exp}_x^{-1}(y) \rangle_x + \frac{\mu}{2} d^2(x, y). \quad (2)$$

然后，关于函数和算子的 Lipschitz 性质，以及黎曼流形上三角距离界限的重要结果，我们在附录 B 中给出。

3 自适应黎曼超梯度下降算法

标准的黎曼双层优化 (RBO) 方法 [15, 24, 39] 使用特定问题的参数 (如强凸性、Lipschitz 性质和曲率常数) 来确定更新变量的步长。然而，这些参数在实际中往往难以估计或计算，给步长的确定带来了挑战。这种局限性强调了对无需参数先验知识即可运行的自适应 RBO 算法的需求。

3.1 近似黎曼超梯度

在介绍我们的主要算法之前，我们首先引入黎曼超梯度，因为我们方法的核心概念依赖于这一构造。遵循一般的双层优化框架，我们将问题 (1) 中 $F(x)$ 的黎曼超梯度定义如下：

命题 3.1. [24, 39] $F(x)$ 的黎曼超梯度由下式给出：

$$\mathcal{G}F(x) = \mathcal{G}_x f(x, y^*(x)) - \mathcal{G}_{xy}^2 g(x, y^*(x)) \mathcal{H}_y^{-1} g(x, y^*(x)) [\mathcal{G}_y f(x, y^*(x))] \in T_x \mathcal{M}. \quad (3)$$

上述命题从根本上取决于黎曼流形的隐函数定理 [23]，该定理要求下层目标函数 g 关于 y 的 Hessian 矩阵是可逆的。在本文中，由于 g 关于 y 是测地强凸的，因此满足这一要求。结果， $y^*(x)$ 是唯一且可微的。

然而，(3) 中定义的黎曼超梯度在计算上具有挑战性。首先，下层目标的精确解 $y^*(x)$ 在大多数情况下是无法显式获得的，因此需要使用近似解 $\hat{y}$ ，我们采用自适应黎曼梯度下降法来计算该近似值。其次，计算 (3) 中的 Hessian 逆向量积 $\mathcal{H}_y^{-1} g(x, y^*(x)) [\mathcal{G}_y f(x, y^*(x))]$ 会产生极高的计算成本。为了解决这个问题，给定 $y^*(x)$ 的近似值 $\hat{y}$ ，由于 g 是测地强凸的，我们可以通过求解线性系统 $\mathcal{H}_y g[v](x, \hat{y}) = \mathcal{G}_y f(x, \hat{y})$ 来近似 Hessian 逆向量积 $\mathcal{H}_y^{-1} g(x, \hat{y}) [\mathcal{G}_y f(x, \hat{y})]$ ，该系统源于以下二次问题：

$$\min_{v \in T_{\hat{y}} \mathcal{M}_y} R(x, \hat{y}, v) = \frac{1}{2} \langle v, \mathcal{H}_y g(x, \hat{y})[v] \rangle_{\hat{y}} - \langle v, \mathcal{G}_y f(x, \hat{y}) \rangle_{\hat{y}}. \quad (4)$$

令 $\hat{v}$ 为问题 (4) 的近似解。在本文中，我们使用自适应梯度下降法（参见文献 [51]）或切空间共轭梯度法 [56, 5] 来获得这样的 $\hat{v}$ 。具体而言，给定初始值 $v^0 \in T_{\hat{y}} \mathcal{M}_y$ 和误差容限 ϵ_v ，求解线性系统 $\mathcal{H}_y g[v](x, \hat{y}) = \mathcal{G}_y f(x, \hat{y})$ 的切空间共轭梯度算法如附录 C 中的算法 2 所示。

因此，给定估计值 $\hat{y}$ 和 $\hat{v}$ ，近似黎曼超梯度 [15, 24, 39] 定义如下：

$$\hat{\mathcal{G}}F(x, \hat{y}, \hat{v}) = \mathcal{G}_x f(x, \hat{y}) - \mathcal{G}_{xy}^2 g(x, \hat{y}) \hat{v} \in T_x \mathcal{M}_x. \quad (5)$$

3.2 自适应黎曼超梯度下降算法：AdaRHD

受近期解决通用双层优化的自适应方法 [67] 的启发，我们采用“累积梯度范数之逆”策略来设计自适应步长 [66, 64, 67]，即根据累积的黎曼（超）梯度范数来调整步长。

给定总迭代次数 T ，将求解问题 (1) 的下层问题和线性系统的精度分别设置为 $\epsilon_y = 1/T$ 和 $\epsilon_v = 1/T$ 。我们用于解决问题 (1) 的自适应黎曼超梯度下降（AdaRHD）算法。为简便起见，当分别采用梯度下降和共轭梯度法求解线性系统时，我们将 AdaRHD 分别表示为 AdaRHD-GD 和 AdaRHD-CG。具体的双循环算法可见参考文献 [51]

3.3 超梯度误差分析

本节确立了近似黎曼超梯度 (5) 与精确黎曼超梯度 (3) 之间的误差、AdaRHD 类算法的收敛结果以及相应的计算复杂度。

3.3.1 定义与假设

类似于通用双层优化中 ϵ -驻点的定义 [20, 31, 32]，黎曼双层优化中 ϵ -驻点的定义 [15, 24, 39] 如下。

定义 3.1 (ϵ -驻点). 如果点 $x \in \mathcal{M}_x$ 满足 $\|\mathcal{G}F(x)\|_x^2 \leq \epsilon$ ，则称其为问题 (1) 的 ϵ -驻点。

我们首先关注引理 B.1 中定义的曲率常数 $\zeta(\tau, c)$ 的上界。

假设 3.1. 流形 $\mathcal{M}_x$ 和 $\mathcal{M}_y$ 是完备黎曼流形。此外， $\mathcal{M}_y$ 是一个截面曲率下界为 $\tau < 0$ 的 Hadamard 流形。此外，对于下层问题中的所有迭代点 y_t^k ，引理 B.1 中定义的曲率常数 $\zeta(\tau, d(y_t^k, y^*(x_t)))$ 对于所有 $t \geq 0$ 和 $p \geq 0$ 始终由常数 ζ 上界。

假设 3.1 在凸黎曼优化中常用，它确保了下层目标函数 g 可以是测地强凸的 [71, 39]，并且对于下层问题的收敛至关重要 [24, 39]。

随后，我们对问题 (1) 的上层和下层目标函数的基本性质采用以下假设。

假设 3.2. 对于所有 $(x, y) \in \mathcal{U} \subseteq \mathcal{M}_x \times \mathcal{M}_y$ ，函数 $f(x, y)$ 是连续可微的， $g(x, y)$ 是二次连续可微的，并且对于任何 $x \in \mathcal{U}_x$ ， $g(x, y)$ 关于 $y \in \mathcal{U}_y$ 是 μ -测地强凸的。

这一假设在（黎曼）双层优化中非常普遍 [20, 31, 32, 42, 27, 37, 15, 24, 39]。在此假设下，对于所有 $x \in \mathcal{M}_x$ ，下层问题的最优解 $y^*(x)$ 是唯一且可微的 [24, 39]，从而保证了黎曼超梯度 (3.1) 的存在性。

假设 3.3. 函数 $f(x, y)$ 在 $\mathcal{U} \in \mathcal{M}_x \times \mathcal{M}_y$ 上是 l_f -Lipschitz 连续的。黎曼梯度 $\mathcal{G}_x f(x, y)$ 和 $\mathcal{G}_y f(x, y)$ 在 $\mathcal{U}$ 上是 L_f -Lipschitz 连续的。黎曼梯度 $\mathcal{G}_x g(x, y)$ 和 $\mathcal{G}_y g(x, y)$ 在 $\mathcal{U}$ 上是 L_g -Lipschitz 连续的。此外，黎曼 Hessian $\mathcal{H}_y g(x, y)$ 、交叉导数 $\mathcal{G}_{xy}^2 g(x, y)$ 和 $\mathcal{G}_{yx}^2 g(x, y)$ 在 $\mathcal{U}$ 上是 ρ -Lipschitz 连续的。

假设 3.3 是现有（黎曼）双层优化文献中的标准条件 [20, 31, 32, 24, 39]。这些条件确保了函数 F 和黎曼超梯度 $\mathcal{G}F$ 的光滑性。

假设 3.4. F 在 $\mathcal{M}_x \times \mathcal{M}_y$ 上的最小值（记作 F^* ）是有下界的。

假设 3.4 涉及上层问题最小值的存在性，这是一个基本要求。

3.3.2 收敛结果

令 $\hat{v}_t^*(x, y) := \arg \min_{v \in T_y \mathcal{M}_y} R(x, y, v)$ 。我们可以如下界定所提出的近似超梯度方案的估计误差。

引理 3.1 (超梯度近似误差界限). 假设 3.1、3.2、3.3 和 3.4 成立。由 *AdaRHD* 类算法生成的近似黎曼超梯度的误差满足：

$$\|\hat{\mathcal{G}}F(x_t, y_t^{K_t}, v_t^{N_t}) - \mathcal{G}F(x_t)\|_{x_t} \leq L_1 d\left(y^*(x_t), y_t^{K_t}\right) + L_g \|v_t^{N_t} - \hat{v}_t^*(x_t, y_t^{K_t})\|_{y_t^{K_t}},$$

其中 $L_1 := L_f + \frac{l_f \rho}{\mu} + L_g \left(\frac{L_f}{\mu} + \frac{l_f \rho}{\mu^2}\right)$ 。

引理 3.1 确立了近似黎曼超梯度与精确黎曼超梯度之间的误差受限于解公式 (1) 中的下层问题和线性系统 (4) 所产生的误差。

3.4 单循环自适应黎曼超梯度下降算法：AdaRHD-S

AdaRHD 中的双循环（double-loops）结构可能会增加实现的复杂性，并增加一阶和二阶导数的计算复杂度。因此，在本节中，我们提出了一种更为简化的全循环（single-loop）自适应黎曼双层优化方法，如算法 1 所示。

Algorithm 1 Adaptive Riemannian Hypergradient Descent with Single-loop (AdaRHD-S)

```

1: Input: Initial points  $x_0 \in \mathcal{M}_x, y_0 \in \mathcal{M}_y$ , and  $v_0 \in T_{y_0}\mathcal{M}$ , initial step sizes  $a_0, b_0$ , and  $c_0$ , total iteration round  $T$ .
2: for  $t = 0, 1, 2, \dots, T-1$  do
3:    $b_{t+1}^2 = b_t^2 + \|\mathcal{G}_y g(x_t, y_t)\|_{y_t}^2$ 
4:    $c_{t+1}^2 = c_t^2 + \|\nabla_v R(x_t, y_t, v_t)\|_{y_t}^2$ 
5:    $d_{t+1} = \max\{b_{t+1}, c_{t+1}\}$ 
6:    $a_{t+1}^2 = a_t^2 + \|\hat{\mathcal{G}}f(x_t, y_t, v_t)\|_{x_t}^2$ 
7:    $y_{t+1} = \text{Exp}_{y_t}(-\frac{1}{b_{t+1}}\mathcal{G}_y g(x_t, y_t))$ 
8:    $v_{t+1} = v_t - \frac{1}{d_{t+1}}\nabla_v R(x_t, y_t, v_t)$ 
9:    $x_{t+1} = \text{Exp}_{x_t}(-\frac{1}{a_{t+1}d_{t+1}}\hat{\mathcal{G}}f(x_t, y_t, v_t))$ 
10: end for

```

算法 1 中的步长设计遵循了 [67] 中提出的类似思路, 即变量 y_t, v_t 和 x_t 通过自适应步长 $\{\frac{1}{b_t}, \frac{1}{\max\{b_t, c_t\}}, \frac{1}{a_t \max\{b_t, c_t\}}\}$ 进行更新。

3.4.1 收敛结果

与需要对问题 (1) 的下层问题和线性系统 (4) 达到极高精度的双循环算法 [51] 不同, 分析算法 1 收敛性的主要挑战在于处理随迭代累积的、用于更新所有变量的近似误差。然而, 我们证明了算法 1 具有与双循环算法 [51] 类似的收敛结果, 如下所示。

定理 3.1. 假设 3.1、3.2、3.3 和 3.4 成立。由算法 1 生成的序列 $\{x_t\}_{t=0}^T$ 满足:

$$\frac{1}{T} \sum_{t=0}^T \|\mathcal{G}F(x_t)\|^2 \leq C_S \frac{\log^4(T)}{T} \leq \mathcal{O}\left(\frac{\log^4(T)}{T}\right).$$

其中 C_S 是附录 G 中定义的常数。

我们得到算法 1 的如下复杂度结果。

推论 3.1. 假设 3.1、3.2、3.3 和 3.4 成立。算法 1 需要 $T = \tilde{\mathcal{O}}(1/\epsilon)$ 次迭代即可达到问题 (1) 的 ϵ -驻点。 f 和 g 的梯度复杂度, 以及计算二阶交叉导数和 *Hessian* 向量积的复杂度均为 $G_f = G_g = JV_g = HV_g = \tilde{\mathcal{O}}(1/\epsilon)$ 。

推论 3.1 表明, 算法 1 达到了 $\mathcal{O}(\log^4(T)/T)$ 的收敛速度和 $\mathcal{O}(\frac{1}{\epsilon} \log^4(\frac{1}{\epsilon}))$ 的梯度复杂度。若忽略对数项, 这与文献 [32] 中标准的、经过良好调参的双层优化方法的结果几乎一致。

3.5 扩展至收缩映射

考虑到在实际应用中, 收缩映射 (retraction mapping) 因其计算效率通常优于指数映射, 本节证明了将其整合进算法 1 后仍能获得相当的理论收敛保证。算法 1 结合收缩映射后的修改版本见算法 3 (详见附录 D)。为了使这一扩展形式化, 假设 3.1 的第二个条件必须修改如下:

假设 3.5. 由算法 3 生成的下层问题的所有迭代点均位于 $\mathcal{M}_y$ 的一个包含最优解的有界集中。即: 对于所有 $t \geq 0$, 存在常数 $\bar{D} > 0$, 使得对于所有 $k \geq 0$, 有 $d(y_t^k, y^*(x_t)) \leq \bar{D}$ 。

在假设 3.5 下, 假设 3.1 中的曲率常数 $\zeta(\tau, d(y_t^k, y^*(x_t)))$ 根据其定义是有界的, 从而确保了与假设 3.1 的一致性。此外, 有必要考虑指数映射与收缩映射之间的误差。

假设 3.6. 给定 $z_1 \in \mathcal{U} \in \mathcal{M}$ (此处 $\mathcal{M}$ 可以是 $\mathcal{M}_x$ 或 $\mathcal{M}_y$) 以及 $u \in T_x \mathcal{M}$, 令 $z_2 = \text{Retr}_{z_1}(u)$ 。存在常数 $c_u \geq 1, c_R \geq 0$, 使得 $d^2(z_1, z_2) \leq c_u \|u\|_{z_1}^2$ 且 $\|\text{Exp}_{z_1}^{-1}(z_2) - u\|_{z_1} \leq c_R \|u\|_{z_1}^2$ 。

假设 3.6 是界定指数映射与收缩映射之间误差的标准条件（例如见 [24, 假设 2] 和 [34, 假设 1]），因为收缩映射是指数映射的一阶近似 [24]。

定理 3.2. 假设 3.1、3.2、3.3、3.4、3.5 和 3.6 成立。由算法 3 生成的序列 $\{x_t\}_{t=0}^T$ 满足：

$$\frac{1}{T} \sum_{t=0}^{T-1} \|\mathcal{G}F(x_t)\|_{x_t}^2 \leq \tilde{C}_S \frac{\log^4(T)}{T} = \tilde{\mathcal{O}}\left(\frac{1}{T}\right),$$

其中 $\tilde{C}$ 为附录 H 中定义的常数 $\bar{b}$ （其代表了自适应步长参数的上界）。

4 数值实验 (Experimental Results)

本节我们对比了单循环架构 (AdaRHD-S) 与双循环架构 (含 AdaRHD-CG 和 AdaRHD-GD) 在多种黎曼流形双层优化场景下的表现。

4.1 合成实验 (Simple Problem)

我们考虑一个矩阵相似度最大化问题。该问题旨在寻找两个矩阵 $X \in \mathbb{R}^{n \times d}$ 和 $Y \in \mathbb{R}^{n \times r}$ 之间的最大关联，其优化目标表述如下：

$$\begin{aligned} \max_{W \in St(d, r)} \quad & \text{trace}(M^*(W)X^\top YW^\top) \\ \text{s.t. } \quad & M^*(W) = \arg \min_{M \in \mathcal{S}_d^{++}} \langle M, X^\top X \rangle + \langle M^{-1}, WY^\top YW^\top + \lambda I \rangle, \end{aligned} \quad (6)$$

其中 $St(d, r)$ 表示 Stiefel 流形， $\mathcal{S}_d^{++}$ 表示对称正定 (SPD) 矩阵流形。我们在 $n = 100$ 和 $n = 1000$ 两种样本规模下进行实验，设置 $d = 50, r = 20$ 。




图 1: Simple 问题的实验结果对比：不同样本量 n 下的时间与目标函数收敛曲线。

图 1 展示了上层目标函数值随时间的变化以及超梯度估计误差。实验结果揭示了两种架构在计算效率与精度之间的关键权衡：

- **收敛速度差异：**在 Time-Objective 曲线中，AdaRHD-S 在实验初期展现出较快的下降速度。这归因于其单循环结构避免了每轮迭代对下层 SPD 子问题的多次求解，在 $n = 1000$ 和 $n = 5000$ 的场景下，这种单步时间优势尤为显著。
- **迭代质量权衡：**从 Epochs 维度衡量，AdaRHD-S 需要更多的迭代轮数达到与双循环算法相当的精度。这表明单循环架构通过牺牲单位轮数内的更新质量，换取了更快的时钟运行时间。

- **算法性能对比**: 截断梯度方法 RHGD-20/50 受限于固定的内层迭代步数, 收敛速度明显滞后于 AdaRHD 系列, 且最终精度难以抗衡基于隐式函数的 CG 方法。

4.2 鲁棒性分析: 深度超表示学习 (Deep Robustness Analysis)

我们进一步通过 AFEW 数据集上的 3 层 SPD 网络评估算法鲁棒性:

$$\begin{aligned}
 & \min_{A_1, A_2, A_3} -\frac{1}{|\mathcal{D}_{val}|} \sum_{i \in \mathcal{D}_{val}} y_i^\top \log(\text{SPDnet}(D_i; A_1, A_2, A_3) \beta^*(A_1, A_2, A_3)) \\
 & \text{s.t. } \beta^*(A_1, A_2, A_3) = \arg \min_{\beta \in \mathbb{R}^{r(r+1)/2}} -\frac{1}{|\mathcal{D}_{tr}|} \sum_{i \in \mathcal{D}_{tr}} y_i^\top \log(\text{SPDnet}(D_i; A_1, A_2, A_3) \beta) + \frac{\lambda}{2} \|\beta\|^2, \\
 & A_1 \in St(d, d_1), \quad A_2 \in St(d_1, d_2), \quad A_3 \in St(d_2, r).
 \end{aligned} \tag{7}$$




图 2: 深度实验综合结果: 展示了验证集准确率与超梯度范数的收敛过程。

1. **超参数鲁棒性差异**: AdaRHD-CG 与 GD 在 0.05 至 5.0 的宽步长范围内均能稳定收敛至高准确率; RHGD 系列对步长高度敏感, 仅在极小步长下有效。
2. **阶段性效率特征**: AdaRHD-S 在训练初期展现出极佳的计算效率, 但在追求极限精度时收敛速度放缓。
3. **性能瓶颈**: AdaRHD-CG 凭借精确梯度估计实现了最深的范数下降, 突破了单循环算法的精度瓶颈。

4. **梯度稳定性**: RHGD-20/50 存在明显平台期, 在应对深度 SPD 网络二阶曲率影响时逊色于具备自适应特性的 AdaRHD 系列。

以下对比表直观展示了各算法在不同步长下的差异。数据表明, **AdaRHD-S** 在达到 50% 准确率阶段具有显著时间优势 (如 $lr = 0.5$ 时仅需 8.95s), 但追求 85% 精度时耗时长或无法收敛。相比之下, **AdaRHD-CG** 在 5.0 至 0.05 的宽步长内均能稳定达到 85% 阈值。**AdaRHD-S** 则适用于快速的近似估计或热启动。

表 2: Time to reach validation accuracy thresholds (seconds) for all methods

Step Size	AdaRHD-CG			AdaRHD-GD			RHGD-50			RHGD-20			AdaRHD-S		
	50%	70%	85%	50%	70%	85%	50%	70%	85%	50%	70%	85%	50%	70%	85%
5.0	287.20 (93.61)	464.79 (124.76)	1217.06 (635.57)	432.66 (157.76)	690.62 (136.52)	1488.26 (426.67)	/	/	/	/	/	/	/	/	/
1.0	131.84 (18.76)	191.51 (34.15)	245.63 (72.42)	200.26 (31.21)	317.31 (68.92)	421.99 (88.31)	/	/	/	/	/	/	13.85 (4.84)	161.47 (74.25)	362.87 (24.79)
0.5	118.09 (19.91)	169.79 (28.59)	241.54 (33.09)	192.51 (22.86)	291.83 (54.21)	477.49 (120.17)	/	/	/	/	/	/	8.95 (3.34)	108.29 (42.63)	457.99 (69.64)
0.125	/	/	/	/	/	/	/	/	/	/	/	/	10.81 (3.48)	179.94 (65.35)	/
0.1	217.32 (33.96)	312.58 (33.66)	427.84 (53.40)	297.90 (42.60)	447.60 (53.50)	546.18 (66.68)	171.97 (78.36)	370.69 (68.61)	808.48 (146.57)	36.01 (12.37)	168.47 (120.86)	540.46 (88.54)	12.67 (4.02)	207.37 (73.91)	/
0.05	251.47 (36.27)	415.51 (49.75)	633.46 (96.54)	358.25 (32.89)	504.80 (15.58)	648.86 (42.91)	137.88 (136.10)	715.91 (104.62)	1510.09 (363.41)	41.36 (6.88)	179.11 (157.76)	1067.92 (122.98)	27.40 (9.04)	415.46 (120.36)	/

5 结论

本文提出了一种用于解决黎曼双层优化 (RBO) 问题的单循环自适应算法。其引入的步长机制消除了对问题参数先验知识的需求, 且它的计算复杂度比现有的双循环自适应算法要低, 并给出了相应的收敛性分析与数据实验模拟。我们证明了该方法在达到 ϵ -驻点时具有 $\mathcal{O}(1/\epsilon)$ 的迭代复杂度, 与双循环自适应算法的复杂度保持一致。此外, 我们证明了用计算效率高的收缩映射代替指数映射后, 仍能保持相同的复杂度保证。

参考文献

- [1] P-A Absil, Robert Mahony, and Rodolphe Sepulchre. Optimization algorithms on matrix manifolds. In *Optimization Algorithms on Matrix Manifolds*. Princeton University Press, 2009.
- [2] Tamir Bendory, Yonina C Eldar, and Nicolas Boumal. Non-convex phase retrieval from stft measurements. *IEEE Transactions on Information Theory*, 64(1):467–484, 2017.
- [3] Luca Bertinetto, Joao F Henriques, Philip HS Torr, and Andrea Vedaldi. Meta-learning with differentiable closed-form solvers. *arXiv preprint arXiv:1805.08136*, 2018.
- [4] Nicholas Bishop, Long Tran-Thanh, and Enrico Gerding. Optimal learning from verified training data. *Advances in Neural Information Processing Systems*, 33:9520–9529, 2020.
- [5] Nicolas Boumal. *An introduction to optimization on smooth manifolds*. Cambridge University Press, 2023.
- [6] Nicolas Boumal and Pierre-antoine Absil. Rtrmc: A riemannian trust-region method for low-rank matrix completion. *Advances in neural information processing systems*, 24, 2011.
- [7] Nicolas Boumal, Pierre-Antoine Absil, and Coralia Cartis. Global rates of convergence for nonconvex optimization on manifolds. *IMA Journal of Numerical Analysis*, 39(1):1–33, 2019.
- [8] Michael Brückner and Tobias Scheffer. Stackelberg games for adversarial prediction problems. In *Proceedings of the 17th ACM SIGKDD international conference on Knowledge discovery and data mining*, pages 547–555, 2011.
- [9] Sébastien Bubeck et al. Convex optimization: Algorithms and complexity. *Foundations and Trends® in Machine Learning*, 8(3-4):231–357, 2015.
- [10] Tianyi Chen, Yuejiao Sun, and Wotao Yin. Closing the gap: Tighter analysis of alternating stochastic gradient methods for bilevel problems. *Advances in Neural Information Processing Systems*, 34:25294–25307, 2021.
- [11] Tianyi Chen, Yuejiao Sun, Quan Xiao, and Wotao Yin. A single-timescale method for stochastic bilevel optimization. In *International Conference on Artificial Intelligence and Statistics*, pages 2466–2488. PMLR, 2022.
- [12] Anoop Cherian and Suvrit Sra. Riemannian dictionary learning and sparse coding for positive definite matrices. *IEEE transactions on neural networks and learning systems*, 28(12):2859–2871, 2016.
- [13] Mathieu Dagr  ou, Pierre Ablin, Samuel Vaiter, and Thomas Moreau. A framework for bilevel optimization that enables stochastic and global variance reduction algorithms. *Advances in Neural Information Processing Systems*, 35:26698–26710, 2022.
- [14] Justin Domke. Generic methods for optimization-based modeling. In *Artificial Intelligence and Statistics*, pages 318–326. PMLR, 2012.
- [15] Sanchayan Dutta, Xiang Cheng, and Suvrit Sra. Riemannian bilevel optimization. *arXiv preprint arXiv:2405.15816*, 2024.

- [16] Rémi Flamary, Alain Rakotomamonjy, and Gilles Gasso. Learning constrained task similarities in graphregularized multi-task learning. *Regularization, Optimization, Kernels, and Support Vector Machines*, 103:1, 2014.
- [17] Luca Franceschi, Michele Donini, Paolo Frasconi, and Massimiliano Pontil. Forward and reverse gradient-based hyperparameter optimization. In *International conference on machine learning*, pages 1165–1173. PMLR, 2017.
- [18] Luca Franceschi, Paolo Frasconi, Saverio Salzo, Riccardo Grazi, and Massimiliano Pontil. Bilevel programming for hyperparameter optimization and meta-learning. In *International conference on machine learning*, pages 1568–1577. PMLR, 2018.
- [19] Daniel Gabay. Minimizing a differentiable function over a differential manifold. *Journal of Optimization Theory and Applications*, 37:177–219, 1982.
- [20] Saeed Ghadimi and Mengdi Wang. Approximation methods for bilevel programming. *arXiv preprint arXiv:1802.02246*, 2018.
- [21] Riccardo Grazi, Luca Franceschi, Massimiliano Pontil, and Saverio Salzo. On the iteration complexity of hypergradient computation. In *International Conference on Machine Learning*, pages 3748–3758. PMLR, 2020.
- [22] Andi Han, Bamdev Mishra, Pratik Kumar Jawanpuria, and Junbin Gao. On riemannian optimization over positive definite matrices with the bures-wasserstein geometry. *Advances in Neural Information Processing Systems*, 34:8940–8953, 2021.
- [23] Andi Han, Bamdev Mishra, Pratik Jawanpuria, and Junbin Gao. Nonconvex-nonconcave min-max optimization on riemannian manifolds. *Transactions on Machine Learning Research*, 2023.
- [24] Andi Han, Bamdev Mishra, Pratik Kumar Jawanpuria, and Akiko Takeda. A framework for bilevel optimization on riemannian manifolds. *Advances in Neural Information Processing Systems*, 37:103829–103872, 2024.
- [25] Mehrtash Harandi, Mathieu Salzmann, and Richard Hartley. Dimensionality reduction on spd manifolds: The emergence of geometry-aware methods. *IEEE transactions on pattern analysis and machine intelligence*, 40(1):48–62, 2017.
- [26] Mingyi Hong, Hoi-To Wai, Zhaoran Wang, and Zhuoran Yang. A two-timescale framework for bilevel optimization: Complexity analysis and application to actor-critic. *arXiv preprint arXiv:2007.05170*, 2020.
- [27] Mingyi Hong, Hoi-To Wai, Zhaoran Wang, and Zhuoran Yang. A two-timescale stochastic algorithm framework for bilevel optimization: Complexity analysis and application to actor-critic. *SIAM Journal on Optimization*, 33(1):147–180, 2023.
- [28] Zihao Hu, Guanghui Wang, Xi Wang, Andre Wibisono, Jacob D Abernethy, and Molei Tao. Extra-gradient type methods for riemannian variational inequality problems. In *International Conference on Artificial Intelligence and Statistics*, pages 2080–2088. PMLR, 2024.
- [29] Feihu Huang and Shangqian Gao. Gradient descent ascent for minimax problems on riemannian manifolds. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 45(7):8466–8476, 2023.

- [30] Kaiyi Ji, Jason D Lee, Yingbin Liang, and H Vincent Poor. Convergence of meta-learning with task-specific adaptation over partial parameters. *Advances in Neural Information Processing Systems*, 33: 11490–11500, 2020.
- [31] Kaiyi Ji, Junjie Yang, and Yingbin Liang. Bilevel optimization: Convergence analysis and enhanced design. In *International conference on machine learning*, pages 4882–4892. PMLR, 2021.
- [32] Kaiyi Ji, Mingrui Liu, Yingbin Liang, and Lei Ying. Will bilevel optimizers benefit from loops. *Advances in Neural Information Processing Systems*, 35:3011–3023, 2022.
- [33] Michael Jordan, Tianyi Lin, and Emmanouil-Vasileios Vlatakis-Gkaragkounis. First-order algorithms for min-max optimization in geodesic metric spaces. *Advances in Neural Information Processing Systems*, 35:6557–6574, 2022.
- [34] Hiroyuki Kasai, Hiroyuki Sato, and Bamdev Mishra. Riemannian stochastic recursive gradient algorithm. In *International conference on machine learning*, pages 2516–2524. PMLR, 2018.
- [35] Vijay Konda and John Tsitsiklis. Actor-critic algorithms. *Advances in neural information processing systems*, 12, 1999.
- [36] Gautam Kunapuli, Kristin P Bennett, Jing Hu, and Jong-Shi Pang. Classification model selection via bilevel programming. *Optimization Methods & Software*, 23(4):475–489, 2008.
- [37] Jeongyeol Kwon, Dohyun Kwon, Stephen Wright, and Robert D Nowak. A fully first-order method for stochastic bilevel optimization. In *International Conference on Machine Learning*, pages 18083–18113. PMLR, 2023.
- [38] John M Lee. *Riemannian manifolds: an introduction to curvature*, volume 176. Springer Science & Business Media, 2006.
- [39] Jiaxiang Li and Shiqian Ma. Riemannian bilevel optimization. *Journal of Machine Learning Research*, 26(18):1–44, 2025.
- [40] Lizhen Lin, Brian St. Thomas, Hongtu Zhu, and David B Dunson. Extrinsic local regression on manifold-valued data. *Journal of the American Statistical Association*, 112(519):1261–1273, 2017.
- [41] Lizhen Lin, Drew Lazar, Bayan Sarpabayeva, and David B Dunson. Robust optimization and inference on manifolds. *arXiv preprint arXiv:2006.06843*, 2020.
- [42] Bo Liu, Mao Ye, Stephen Wright, Peter Stone, and Qiang Liu. Bome! bilevel optimization made easy: A simple first-order approach. *Advances in neural information processing systems*, 35:17248–17262, 2022.
- [43] Dougal Maclaurin, David Duvenaud, and Ryan Adams. Gradient-based hyperparameter optimization through reversible learning. In *International conference on machine learning*, pages 2113–2122. PMLR, 2015.
- [44] Bamdev Mishra, Hiroyuki Kasai, Pratik Jawanpuria, and Atul Saroop. A riemannian gossip approach to subspace learning on grassmann manifold. *Machine Learning*, 108:1783–1803, 2019.
- [45] Fabian Pedregosa. Hyperparameter optimization with approximate gradient. In *International conference on machine learning*, pages 737–746. PMLR, 2016.
- [46] Peter Petersen. *Riemannian geometry*, volume 171. Springer, 2006.

- [47] Aravind Rajeswaran, Chelsea Finn, Sham M Kakade, and Sergey Levine. Meta-learning with implicit gradients. *Advances in neural information processing systems*, 32, 2019.
- [48] Hiroyuki Sato. A dai–yuan-type riemannian conjugate gradient method with the weak wolfe conditions. *Computational optimization and Applications*, 64:101–118, 2016.
- [49] Hiroyuki Sato, Hiroyuki Kasai, and Bamdev Mishra. Riemannian stochastic variance reduced gradient algorithm with retraction and vector transport. *SIAM Journal on Optimization*, 29(2):1444–1472, 2019.
- [50] Amirreza Shaban, Ching-An Cheng, Nathan Hatch, and Byron Boots. Truncated back-propagation for bilevel optimization. In *The 22nd International Conference on Artificial Intelligence and Statistics*, pages 1723–1732. PMLR, 2019.
- [51] Xu Shi, Rufeng Xiao, and Rujun Jiang. An adaptive algorithm for bilevel optimization on riemannian manifolds. *arXiv preprint*, 2024.
- [52] Rhea Sanjay Sukthanker, Zhiwu Huang, Suryansh Kumar, Erik Goron Endsjo, Yan Wu, and Luc Van Gool. Neural architecture search of spd manifold networks. *arXiv preprint arXiv:2010.14535*, 2020.
- [53] Ju Sun, Qing Qu, and John Wright. Complete dictionary recovery over the sphere ii: Recovery by riemannian trust-region method. *IEEE Transactions on Information Theory*, 63(2):885–914, 2016.
- [54] Ju Sun, Qing Qu, and John Wright. A geometric analysis of phase retrieval. *Foundations of Computational Mathematics*, 18:1131–1198, 2018.
- [55] Hadi Tabealhojeh, Peyman Adibi, Hossein Karshenas, Soumava Kumar Roy, and Mehrtash Harandi. Rmaml: Riemannian meta-learning with orthogonality constraints. *Pattern Recognition*, 140:109563, 2023.
- [56] Lloyd N Trefethen and David Bau. *Numerical linear algebra*. SIAM, 2022.
- [57] Nilesh Tripuraneni, Nicolas Flammarion, Francis Bach, and Michael I Jordan. Averaging stochastic gradient descent on riemannian manifolds. In *Conference On Learning Theory*, pages 650–687. PMLR, 2018.
- [58] Ioannis Tsaknakis, Prashant Khanduri, and Mingyi Hong. An implicit gradient-type method for linearly constrained bilevel problems. In *ICASSP 2022-2022 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, pages 5438–5442. IEEE, 2022.
- [59] Loring W Tu. Manifolds. In *An Introduction to Manifolds*, pages 47–83. Springer, 2011.
- [60] Bart Vandereycken. Low-rank matrix completion by riemannian optimization. *SIAM Journal on Optimization*, 23(2):1214–1236, 2013.
- [61] Jiali Wang, He Chen, Rujun Jiang, Xudong Li, and Zihao Li. Fast algorithms for stackelberg prediction game with least squares loss. In *International Conference on Machine Learning*, pages 10708–10716. PMLR, 2021.
- [62] Jiali Wang, Wen Huang, Rujun Jiang, Xudong Li, and Alex L Wang. Solving stackelberg prediction game with least squares loss via spherically constrained least squares reformulation. In *International conference on machine learning*, pages 22665–22679. PMLR, 2022.

- [63] Xi Wang, Deming Yuan, Yiguang Hong, Zihao Hu, Lei Wang, and Guodong Shi. Riemannian optimistic algorithms. *arXiv preprint arXiv:2308.16004*, 2023.
- [64] Rachel Ward, Xiaoxia Wu, and Leon Bottou. Adagrad stepsizes: Sharp convergence over nonconvex landscapes. *Journal of Machine Learning Research*, 21(219):1–30, 2020.
- [65] Quan Xiao, Han Shen, Wotao Yin, and Tianyi Chen. Alternating projected sgd for equality-constrained bilevel optimization. In *International Conference on Artificial Intelligence and Statistics*, pages 987–1023. PMLR, 2023.
- [66] Yuege Xie, Xiaoxia Wu, and Rachel Ward. Linear convergence of adaptive stochastic gradient descent. In *International conference on artificial intelligence and statistics*, pages 1475–1485. PMLR, 2020.
- [67] Yifan Yang, Hao Ban, Minhui Huang, Shiqian Ma, and Kaiyi Ji. Tuning-free bilevel optimization: New algorithms and convergence analysis. *arXiv preprint arXiv:2410.05140*, 2024.
- [68] Wei Yao, Chengming Yu, Shangzhi Zeng, and Jin Zhang. Constrained bi-level optimization: Proximal lagrangian value function approach and hessian-free algorithm. *arXiv preprint arXiv:2401.16164*, 2024.
- [69] Tong Yu and Hong Zhu. Hyper-parameter optimization: A review of algorithms and applications. *arXiv preprint arXiv:2003.05689*, 2020.
- [70] Emanuele Zangrando, Sara Venturini, Francesco Rinaldi, and Francesco Tudisco. debora: Efficient bilevel optimization-based low-rank adaptation. In *The Thirteenth International Conference on Learning Representations*, 2025.
- [71] Hongyi Zhang and Suvrit Sra. First-order methods for geodesically convex optimization. In *Conference on learning theory*, pages 1617–1638. PMLR, 2016.
- [72] Hongyi Zhang, Sashank J Reddi, and Suvrit Sra. Riemannian svrg: Fast stochastic optimization on riemannian manifolds. *Advances in Neural Information Processing Systems*, 29, 2016.
- [73] Peiyuan Zhang, Jingzhao Zhang, and Suvrit Sra. Sion’ s minimax theorem in geodesic metric spaces and a riemannian extragradient algorithm. *SIAM Journal on Optimization*, 33(4):2885–2908, 2023.

Appendix

A 相关工作

双层优化 (Bilevel optimization): 双层优化起源于 Stackelberg 博弈 [8, 4, 61, 62]。当下层目标函数是强凸时, 学者们已经提出了各种方法 [20, 10, 31, 32, 13, 42, 27, 37]。超梯度 (Hypergradient) 的计算方法包括: 近似隐式微分 (AID) [14, 45]; 迭代微分 (ITD) [43, 17, 50, 21]; Neumann 级数 (NS) [20]; 以及共轭梯度 (CG) [31]。最近的研究开始关注在上层或下层目标中带有约束的双层问题。例如, [11, 27] 专注于仅在上层目标施加约束的场景, 而 [58, 65, 68] 则为带有下层约束的问题开发了相关方法。更多阅读可参考 [31, 32, 37] 及其参考文献。

黎曼流形优化 (Riemannian manifold optimization): 黎曼流形优化因其广泛的应用而备受关注, 包括低秩矩阵补全 [6, 60]; 相位恢复 [2, 54]; 字典学习 [12, 53]; 降维 [25, 57, 44]; 以及流形回归 [40, 41]。该方法通过将流形视为环境空间, 并利用收缩映射 (retractions) 来补偿线性度的缺失, 将流形约束问题重新表述为无约束问题, 从而改善收敛性质 [39]。在平滑黎曼优化中, 已开发出多种方法, 如黎曼梯度下降 [19, 1, 2, 7]; 非线性共轭梯度 [48]; 以及方差缩减随机梯度 [72, 49]。更多细节请参考 [5] 及其参考文献。

黎曼双层优化 (Riemannian bilevel optimization): 关于黎曼双层优化的研究目前还比较有限。[39] 研究了黎曼流形上此类问题的超梯度 (hypergradient) 计算, 并开发了确定性和随机算法 (即 RieBO 和 RieSBO) 用于解决黎曼双层及随机双层优化。与此同时, [24] 提出了一个名为 RHGD 的黎曼双层优化框架, 提供了多种超梯度估计策略, 并附带了收敛性和复杂度分析。作者还将该框架扩展到了黎曼极小极大 (minimax) 和组合优化问题。通过利用价值函数 (value-function) 重构和拉格朗日 (Lagrange) 方法, [15] 引入了一种全随机一阶方法, 适用于两个目标函数均为随机、确定性或混合的情况。

自适应双层优化 (Adaptive bilevel optimization): 与本文方法最接近的方法是 [67] 提出的 D-TFBO, 该方法通过采用类似的自适应步长策略解决了欧几里得空间下的双层优化问题。虽然欧几里得分析的某些方面可以直接扩展到黎曼设置, 但几何曲率引入的失真产生了独特的分析挑战。我们推导出了与 D-TFBO 类似的收敛保证, 并通过使用收缩映射 (retraction mapping) 替代指数映射 (exponential mapping) 来提高算法效率, 从而减少了计算开销。据我们所知, 本项工作是首个具有解决黎曼双层优化问题理论收敛保证的全自适应方法。

B 第 2 节的补充预备知识

黎曼流形中函数和算子的 Lipschitz 性定义如下:

定义 B.1. [24, Definition 1] 对于任意 $x, x_1, x_2 \in \mathcal{U}_x, y, y_1, y_2 \in \mathcal{U}_y$, 其中 $\mathcal{U}_x \times \mathcal{U}_y \subseteq \mathcal{M}_x \times \mathcal{M}_y$,

- (i) 若函数 $f: \mathcal{M}_x \rightarrow \mathbb{R}$ 满足 $\|\mathcal{P}_{x_1}^{x_2} \mathcal{G}f(x_1) - \mathcal{G}f(x_2)\|_{x_2} \leq Ld(x_1, x_2)$, 则称其在 $\mathcal{U}_x$ 内具有 L -Lipschitz 黎曼梯度。
- (ii) 若双变量函数 $f: \mathcal{M}_x \times \mathcal{M}_y \rightarrow \mathbb{R}$ 满足 $\|\mathcal{P}_{y_1}^{y_2} \mathcal{G}_y f(x, y_1) - \mathcal{G}_y f(x, y_2)\|_{y_2} \leq Ld(y_1, y_2)$, $\|\mathcal{G}_x f(x, y_1) - \mathcal{G}_x f(x, y_2)\|_x \leq Ld(y_1, y_2)$, $\|\mathcal{P}_{x_1}^{x_2} \mathcal{G}_x f(x_1, y) - \mathcal{G}_x f(x_2, y)\|_{x_2} \leq Ld(x_1, x_2)$ 且 $\|\mathcal{G}_y f(x_1, y) - \mathcal{G}_y f(x_2, y)\|_y \leq Ld(x_1, x_2)$, 则称其在 $\mathcal{U}_x \times \mathcal{U}_y$ 内具有 L -Lipschitz 黎曼梯度。
- (iii) 若线性算子 $\mathcal{G}(x, y): T_y \mathcal{M}_y \rightarrow T_x \mathcal{M}_x$ (例如 $\mathcal{G}_{xy} g(x, y)$) 满足 $\|\mathcal{P}_{x_1}^{x_2} \mathcal{G}(x_1, y) - \mathcal{G}(x_2, y)\|_{x_2} \leq \rho d(x_1, x_2)$ 且 $\|\mathcal{G}(x, y_1) - \mathcal{G}(x, y_2)\|_{y_1} \leq \rho d(y_1, y_2)$, 则称其在 $\mathcal{U}_x \times \mathcal{U}_y$ 内是 ρ -Lipschitz 的。
- (iv) 若线性算子 $\mathcal{H}(x, y): T_y \mathcal{M}_y \rightarrow T_y \mathcal{M}_y$ (例如 $\mathcal{H}_{yy} g(x, y)$) 满足 $\|\mathcal{P}_{y_1}^{y_2} \mathcal{H}(x, y_1) \mathcal{P}_{y_2}^{y_1} - \mathcal{H}(x, y_2)\|_{y_2} \leq \rho d(y_1, y_2)$ 且 $\|\mathcal{H}(x_1, y) - \mathcal{H}(x_2, y)\|_y \leq \rho d(x_1, x_2)$, 则称其在 $\mathcal{U}_x \times \mathcal{U}_y$ 内是 ρ -Lipschitz 的。

受黎曼流形曲率的影响，与欧几里得空间中定义的距离不同，我们在黎曼流形上具有以下三角距离界限 (trigonometric distance bound)。

引理 B.1 (三角距离界限 [71, 72, 22])。令 $x_a, x_b, x_c \in \mathcal{U} \subseteq \mathcal{M}$ ，并记 $a = d(x_b, x_c)$, $b = d(x_a, x_c)$, $c = d(x_a, x_b)$ 为测地线边长。则有：

$$a^2 \leq \zeta(\tau, c)b^2 + c^2 - 2\langle \text{Exp}_{x_a}^{-1}(x_b), \text{Exp}_{x_a}^{-1}(x_c) \rangle_{x_a}$$

其中，若 $\tau < 0$, $\zeta(\tau, c) = \frac{\sqrt{|\tau|}c}{\tanh(\sqrt{|\tau|}c)}$ ；若 $\tau \geq 0$, $\zeta(\tau, c) = 1$ 。这里 τ 表示 $\mathcal{U}$ 的截面曲率下界 [46, Section 3.1.3]。

C 切空间共轭梯度算法

在本节中，我们介绍第 3.1 节所需的切空间共轭梯度 (tangent-space conjugate gradient) 方法 [56, 5]。

Algorithm 2 Tangent Space Conjugate Gradient $v^n = \text{TSCG}(\mathcal{H}_y g(x, \hat{y}), \mathcal{G}_y f(x, \hat{y}), v^0, \epsilon_v)$

```

1: Let  $r^0 = \mathcal{G}_y f(x, \hat{y}) \in T_y \mathcal{M}_y, p^0 = r^0$ .
2: while  $\mathcal{H}_y g(x, \hat{y})[v^n] - \mathcal{G}_y f(x, \hat{y}) > \epsilon_v$  do
3:   Compute  $\mathcal{H}_y g(x, \hat{y})[p^n]$ .
4:    $a^{n+1} = \frac{\|r^n\|_{\hat{y}}^2}{\langle p^n, \mathcal{H}_y g(x, \hat{y})[p^n] \rangle_{\hat{y}}}$ ,
5:    $v^{n+1} = v^n + a^{n+1}p^n$ ,
6:    $r^{n+1} = r^n - a^{n+1}\mathcal{H}_y g(x, \hat{y})[p^n]$ ,
7:    $b^{n+1} = \frac{\|r^{n+1}\|_{\hat{y}}^2}{\|r^n\|_{\hat{y}}^2}$ ,
8:    $p^{n+1} = r^{n+1} + b^{n+1}p^n$ ,
9:    $n = n + 1$ .
10: end while
```

D 第 3.5 节的补充结果

由于收缩映射 (retraction mapping) 仅影响问题 (1) 中下层问题收敛所需的总迭代次数，而不影响误差界限，因此超梯度近似误差界 (Lemma 3.1) 与双循环算法保持一致。此外，我们为解决问题 (1) 中的下层问题和线性系统 (4) 所需的总迭代次数建立了以下上界。

命题 D.1. 假设 Assumptions 3.1, 3.2, 3.3, 3.4, 3.5, 和 3.6 成立。则对于任何 $0 \leq t \leq T$ ，算法 3 所需的迭代次数 K_t 和 N_t 满足：

$$K_t \leq \frac{\log(C_b^2/b_0^2)}{\log(1 + \epsilon_y/C_b^2)} + \frac{1}{(\mu/\bar{b} - \bar{\zeta}L_g^2/\bar{b}^2)} \log\left(\frac{\tilde{b}}{\epsilon_y}\right).$$

AdaRHD-GD:

$$N_t \leq \frac{\log(C_c^2/c_0^2)}{\log(1 + \epsilon_v/C_c^2)} + \frac{\bar{c}}{\mu} \log\left(\frac{\tilde{c}}{\epsilon_v}\right),$$

其中 $C_b, C_c, \bar{b}, \bar{c}, \tilde{b}, \tilde{c}$ 和 $\bar{\zeta}$ 是附录 H 中定义的常数。

AdaRHD-CG:

$$N_t \leq \frac{1}{2} \log\left(\frac{4L_g^3 l_f^2}{\mu^3 \epsilon_v}\right) / \log\left(\frac{\sqrt{L_g/\mu} + 1}{\sqrt{L_g/\mu} - 1}\right).$$

Algorithm 3 AdaRHD with Retraction (AdaRHD-R)

```

1: Initia points  $x_0 \in \mathcal{M}_x, y_0 \in \mathcal{M}_y$ , and  $v_0 \in T_{y_0}\mathcal{M}$ , initial step sizes  $a_0 > 0$ ,  $b_0 > 0$ , and  $c_0 > 0$ , total
   iterations  $T$ , error tolerances  $\epsilon_y = \epsilon_v = \frac{1}{T}$ .
2: for  $t = 0, 1, 2, \dots, T - 1$  do
3:   Set  $p = 0$  and  $y_t^0 = y_{t-1}^{K_{t-1}}$  if  $t > 0$  and  $y_0$  otherwise.
4:   while  $\|\mathcal{G}_y g(x_t, y_t^k)\|_{y_t^k}^2 > \epsilon_y$  do
5:      $b_{k+1}^2 = b_k^2 + \|\mathcal{G}_y g(x_t, y_t^k)\|_{y_t^k}^2$ ,
6:      $y_t^{k+1} = \text{Retr}_{y_t^k}(-\frac{1}{b_{k+1}} \mathcal{G}_y g(x_t, y_t^k))$ ,  $p = p + 1$ .
7:   end while
8:    $K_t = k$ 
9:   Set  $n = 0$  and  $v_t^0 = \mathcal{P}_{y_{t-1}^{K_{t-1}}}^{y_t^{K_t}} v_{t-1}^{N_{t-1}}$  if  $t > 0$  and  $v_0$  otherwise.
10:  while  $\|\nabla_v R(x_t, y_t^{K_t}, v_t^n)\|_{y_t^{K_t}}^2 > \epsilon_v$  do
11:     $c_{n+1}^2 = c_n^2 + \|\nabla_v R(x_t, y_t^{K_t}, v_t^n)\|_{y_t^{K_t}}^2$ ,
12:     $v_t^{n+1} = v_t^n - \frac{1}{c_{n+1}} \nabla_v R(x_t, y_t^{K_t}, v_t^n)$ , ▷ Gradient descent
13:     $n = n + 1$ .
14:  end while
15:  Or set  $v_t^0 = 0$  and invoke  $v_t^n = \text{TSCG}(\mathcal{H}_y g(x_t, y_t^{K_t}), \mathcal{G}_y f(x_t, y_t^{K_t}), v_t^0, \epsilon_v)$ . ▷ Conjugate gradient
16:   $N_t = n$ ,
17:   $\hat{\mathcal{G}}F(x_t, y_t^{K_t}, v_t^{N_t}) = \mathcal{G}_x f(x_t, y_t^{K_t}) - \mathcal{G}_{xy}^2 g(x_t, y_t^{K_t})[v_t^{N_t}]$ ,
18:   $a_{t+1}^2 = a_t^2 + \|\hat{\mathcal{G}}F(x_t, y_t^{K_t}, v_t^{N_t})\|_{x_t}^2$ ,  $x_{t+1} = \text{Retr}_{x_t}(-\frac{1}{a_{t+1}} \hat{\mathcal{G}}F(x_t, y_t^{K_t}, v_t^{N_t}))$ .
19: end for

```

E 证明的预备结果

引理 E.1. [64, 引理 3.2] 对于任何非负数 $\alpha_1, \dots, \alpha_T$, 且满足 $\alpha_1 \geq 1$, 我们有:

$$\sum_{l=1}^T \frac{\alpha_l}{\sum_{i=1}^l \alpha_i} \leq \log \left(\sum_{l=1}^T \alpha_l \right) + 1.$$

引理 E.2. 假设假设 3.1、3.2 和 3.3 成立。则以下陈述成立:

(1) 对于 $x_1, x_2 \in \mathcal{M}_x$, 有:

$$d(y^*(x_1), y^*(x_2)) \leq L_y d(x_1, x_2),$$

其中 $L_y := \frac{L_g}{\mu}$, 且 $y^*(x)$ 是问题 (1) 中下层问题的最优解;

(2) 黎曼超梯度 (Riemannian hypergradient) $\mathcal{G}F(x)$ 满足 $\|\mathcal{G}F(x)\|_x \leq l_f(1 + L_g/\mu)$ 。此外, 对于 $x_1, x_2 \in \mathcal{M}_x$, 有:

$$\|\mathcal{G}F(x_1) - \mathcal{P}_{x_2}^{x_1} \mathcal{G}F(x_2)\|_{x_1} \leq L_F d(x_1, x_2),$$

其中 $L_F := \left(L_f + \frac{\rho l_f}{\mu} \right) \left(1 + \frac{L_g}{\mu} \right)^2$ 。

证明. 引理 E.2 的证明可由 [20, 引理 2.2] 推导得出, 此处为了完整性予以提供。

(1): 对于 $x_1, x_2 \in \mathcal{M}_x$, 存在两条测地线 (geodesics) $c_1 : [0, 1] \rightarrow \mathcal{M}_y$ 和 $c_2 : [0, 1] \rightarrow \mathcal{M}_x$, 使得对于 $t \in [0, 1]$ 有 $c_1(t) = y^*(c_2(t))$, 且 $c_2(0) = x_1, c_2(1) = x_2$ 。于是我们有:

$$d(y^*(x_1), y^*(x_2)) = \int_0^1 \|c_1'(t)\|_{c_1(t)} dt = \int_0^1 \|\text{D}y^*(c_2(t))[c_2'(t)]\|_{c_2(t)} dt \leq \frac{L_g}{\mu} \int_0^1 \|c_2'(t)\|_{c_2(t)} dt = \frac{L_g}{\mu} d(x_1, x_2),$$

其中第一个不等式由 $Dy^*(x) := -\mathcal{H}_y^{-1}g(x, y^*(x))\mathcal{G}_{yx}^2g(x, y^*(x))$ 导出。

(2): 根据 $\mathcal{G}F(x)$ 的定义, 由假设 3.2 和 3.3 可知:

$$\begin{aligned}\|\mathcal{G}F(x)\|_x &= \|\mathcal{G}_x f(x, y^*(x)) - \mathcal{G}_{xy}^2 g(x, y^*(x))[\mathcal{H}_y^{-1}g(x, y^*(x))[\mathcal{G}_y f(x, y^*(x))]]\|_x \\ &= \|\mathcal{G}_x f(x, y^*(x))\|_x + \|\mathcal{G}_{xy}^2 g(x, y^*(x))\|_{y^*(x)} \|\mathcal{H}_y^{-1}g(x, y^*(x))\|_{y^*(x)} \|\mathcal{G}_y f(x, y^*(x))\|_{y^*(x)} \leq l_f + \frac{L_g}{\mu} l_f.\end{aligned}$$

此外, 我们有:

$$\begin{aligned}& \|\mathcal{P}_{x_1}^{x_2} \mathcal{G}F(x_1) - \mathcal{G}F(x_2)\|_{x_2} \\ & \leq \|\mathcal{P}_{x_1}^{x_2} \mathcal{G}_x f(x_1, y^*(x_1)) - \mathcal{G}_x f(x_2, y^*(x_2))\|_{x_2} \\ & \quad + \|\mathcal{P}_{x_1}^{x_2} \mathcal{G}_{xy}^2 g(x_1, y^*(x_1)) - \mathcal{G}_{xy}^2 g(x_2, y^*(x_2))\mathcal{P}_{y^*(x_1)}^{y^*(x_2)}\|_{x_2} \|\mathcal{H}_y^{-1}g(x_1, y^*(x_1))\|_{y^*(x_1)} \|\mathcal{G}_y f(x_1, y^*(x_1))\|_{y^*(x_1)} \\ & \quad + \|\mathcal{G}_{xy}^2 g(x_2, y^*(x_2))\|_{x_2} \|\mathcal{P}_{y^*(x_1)}^{y^*(x_2)} \mathcal{H}_y^{-1}g(x_1, y^*(x_1))\mathcal{P}_{y^*(x_2)}^{y^*(x_1)} - \mathcal{H}_y^{-1}g(x_2, y^*(x_2))\|_{y^*(x_2)} \|\mathcal{G}_y f(x_1, y^*(x_1))\|_{y^*(x_1)} \\ & \quad + \|\mathcal{G}_{xy}^2 g(x_2, y^*(x_2))\|_{x_2} \|\mathcal{H}_y^{-1}g(x_2, y^*(x_2))\|_{y^*(x_2)} \|\mathcal{P}_{y^*(x_1)}^{y^*(x_2)} \mathcal{G}_y f(x_1, y^*(x_1)) - \mathcal{G}_y f(x_2, y^*(x_2))\|_{y^*(x_2)}. \quad (8)\end{aligned}$$

根据假设 3.2 和 3.3, 对于 (8) 的第一项, 有:

$$\begin{aligned}& \|\mathcal{P}_{x_1}^{x_2} \mathcal{G}_x f(x_1, y^*(x_1)) - \mathcal{G}_x f(x_2, y^*(x_2))\|_{x_2} \\ & \leq \|\mathcal{G}_x f(x_1, y^*(x_1)) - \mathcal{G}_x f(x_1, y^*(x_2))\|_{x_1} + \|\mathcal{P}_{x_1}^{x_2} \mathcal{G}_x f(x_1, y^*(x_2)) - \mathcal{G}_x f(x_2, y^*(x_2))\|_{x_2} \\ & \leq L_f d(y^*(x_1), y^*(x_2)) + L_f d(x_1, x_2) = \left(\frac{L_f L_g}{\mu} + L_f \right) d(x_1, x_2).\end{aligned}$$

接着考虑 (8) 的第四项:

$$\begin{aligned}& \|\mathcal{P}_{y^*(x_1)}^{y^*(x_2)} \mathcal{G}_y f(x_1, y^*(x_1)) - \mathcal{G}_y f(x_2, y^*(x_2))\|_{y^*(x_2)} \\ & \leq \|\mathcal{P}_{y^*(x_1)}^{y^*(x_2)} \mathcal{G}_y f(x_1, y^*(x_1)) - \mathcal{G}_y f(x_1, y^*(x_2))\|_{y^*(x_2)} + \|\mathcal{G}_y f(x_1, y^*(x_2)) - \mathcal{G}_y f(x_2, y^*(x_2))\|_{y^*(x_2)} \\ & \leq \left(\frac{L_f L_g}{\mu} + L_f \right) d(x_1, x_2).\end{aligned}$$

对于 (8) 的第二项:

$$\begin{aligned}& \|\mathcal{P}_{x_1}^{x_2} \mathcal{G}_{xy}^2 g(x_1, y^*(x_1)) - \mathcal{G}_{xy}^2 g(x_2, y^*(x_2))\mathcal{P}_{y^*(x_1)}^{y^*(x_2)}\|_{x_2} \\ & \leq \|\mathcal{P}_{x_1}^{x_2} \mathcal{G}_{xy}^2 g(x_1, y^*(x_1))\mathcal{P}_{y^*(x_2)}^{y^*(x_1)} - \mathcal{P}_{x_1}^{x_2} \mathcal{G}_{xy}^2 g(x_1, y^*(x_2))\|_{x_2} + \|\mathcal{P}_{x_1}^{x_2} \mathcal{G}_{xy}^2 g(x_1, y^*(x_2)) - \mathcal{G}_{xy}^2 g(x_2, y^*(x_2))\|_{x_2} \\ & \leq \left(\frac{\rho L_g}{\mu} + \rho \right) d(x_1, x_2).\end{aligned}$$

对于 (8) 的第三项:

$$\begin{aligned}& \|\mathcal{P}_{y^*(x_1)}^{y^*(x_2)} \mathcal{H}_y^{-1}g(x_1, y^*(x_1))\mathcal{P}_{y^*(x_2)}^{y^*(x_1)} - \mathcal{H}_y^{-1}g(x_2, y^*(x_2))\|_{y^*(x_2)} \\ & \leq \|\mathcal{H}_y^{-1}g(x_1, y^*(x_1)) - \mathcal{H}_y^{-1}g(x_2, y^*(x_1))\|_{y^*(x_1)} + \|\mathcal{P}_{y^*(x_1)}^{y^*(x_2)} \mathcal{H}_y^{-1}g(x_2, y^*(x_1))\mathcal{P}_{y^*(x_2)}^{y^*(x_1)} - \mathcal{H}_y^{-1}g(x_2, y^*(x_2))\|_{y^*(x_2)} \\ & \leq \left(\frac{\rho}{\mu^2} + \frac{\rho L_g}{\mu^3} \right) d(x_1, x_2),\end{aligned}$$

其中最后一个不等式由算子范数满足的性质得出:

$$\|A^{-1} - B^{-1}\| \leq \|B^{-1}(B - A)A^{-1}\| \leq \|A^{-1}\| \|B^{-1}\| \|A - B\|. \quad (9)$$

结合上述所有不等式, 我们得到:

$$\|\mathcal{P}_{x_1}^{x_2} \mathcal{G}F(x_1) - \mathcal{G}F(x_2)\|_{x_2}$$

$$\begin{aligned}
&\leq \left(\frac{L_f L_g}{\mu} + L_f \right) d(x_1, x_2) + \frac{l_f}{\mu} \left(\frac{\rho L_g}{\mu} + \rho \right) d(x_1, x_2) \\
&\quad + L_g l_f \left(\frac{\rho}{\mu^2} + \frac{\rho L_g}{\mu^3} \right) d(x_1, x_2) + \frac{L_g}{\mu} \left(\frac{L_f L_g}{\mu} + L_f \right) d(x_1, x_2) \\
&= \left(\frac{L_f L_g}{\mu} + L_f + \frac{l_f}{\mu} \left(\frac{\rho L_g}{\mu} + \rho \right) + L_g l_f \left(\frac{\rho}{\mu^2} + \frac{\rho L_g}{\mu^3} \right) + \frac{L_g}{\mu} \left(\frac{L_f L_g}{\mu} + L_f \right) \right) d(x_1, x_2) \\
&= \left(L_f + \frac{\rho l_f}{\mu} \right) \left(1 + \frac{L_g}{\mu} \right)^2 d(x_1, x_2).
\end{aligned}$$

证毕。 $\square$

记 $v^*(x) := \arg \min_{v \in T_{y^*(x)} \mathcal{M}_y} R(x, y^*(x), v)$ 且 $\hat{v}^*(x, y) := \arg \min_{v \in T_y \mathcal{M}_y} R(x, y, v)$ 。

引理 E.3. 假设假设 3.1、3.2 和 3.3 成立。则以下陈述成立：

- (1) 目标函数 $R(x, y, v)$ 关于 v 是 μ -强凸且 L_g -平滑的；
- (2) $v^*(x)$ 满足 $\|v^*(x)\|_{y^*(x)} \leq \frac{l_f}{\mu}$ ，且 $\hat{v}^*(x, y)$ 同样满足 $\|\hat{v}^*(x, y)\|_y \leq \frac{l_f}{\mu}$ ；
- (3) 对于 $x, x_1, x_2 \in \mathcal{M}_x$ 和 $y_1, y_2 \in \mathcal{M}_y$ ，有：

$$\left\| v^*(x_1) - \mathcal{P}_{y^*(x_2)}^{y^*(x_1)} v^*(x_2) \right\|_{y^*(x_1)} \leq L_v d(x_1, x_2), \text{ 且 } \|\hat{v}^*(x, y_1) - \mathcal{P}_{y_2}^{y_1} \hat{v}^*(x, y_2)\|_{y_1} \leq \hat{L}_v d(y_1, y_2),$$

其中 $L_v := (\frac{L_f}{\mu} + \frac{l_f \rho}{\mu^2})(1 + L_y)$ ，且 $\hat{L}_v := \frac{L_f}{\mu} + \frac{l_f \rho}{\mu^2}$ 。

证明. (1): 由于 $\nabla_v^2 R(x, y, v) = \mathcal{H}_y g(x, y)$ ，根据假设 3.2 可直接得出 $R(x, y, v)$ 的强凸性。此外由假设 3.3，对于 $v_1, v_2 \in T_y \mathcal{M}_y$ ，有：

$$\|\nabla_v R(x, y, v_1) - \nabla_v R(x, y, v_2)\|_y \leq \|\mathcal{H}_y g(x, y)\|_y \|v_1 - v_2\|_y \leq L_g \|v_1 - v_2\|_y.$$

(2): 对于 $\hat{v}^*(x, y)$ ，我们有：

$$\nabla_v R(x, y, \hat{v}^*(x, y)) = \mathcal{H}_y g(x, y) [\hat{v}^*(x, y)] - \mathcal{G}_y f(x, y) = 0,$$

这表明：

$$\|\hat{v}^*(x, y)\|_y = \|\mathcal{H}_y^{-1} g(x, y) \mathcal{G}_y f(x, y)\|_y \leq \|\mathcal{H}_y^{-1} g(x, y)\|_y \cdot \|\mathcal{G}_y f(x, y)\|_y \leq \frac{l_f}{\mu}.$$

由于 $v^*(x)$ 满足 $v^*(x) = \hat{v}^*(x, y^*(x))$ ，结论得证。

(3): 根据 $v^*(x)$ 的定义，有：

$$\begin{aligned}
&\left\| v^*(x_1) - \mathcal{P}_{y^*(x_2)}^{y^*(x_1)} v^*(x_2) \right\|_{y^*(x_1)} \\
&\leq \left\| \mathcal{H}_y^{-1} g(x_1, y^*(x_1)) [\mathcal{G}_y f(x_1, y^*(x_1))] - \mathcal{P}_{y^*(x_2)}^{y^*(x_1)} \mathcal{H}_y^{-1} g(x_2, y^*(x_2)) [\mathcal{G}_y f(x_2, y^*(x_2))] \right\|_{y^*(x_1)}.
\end{aligned}$$

剩余部分的证明与引理 E.2 (2) 类似，故省略。

根据 $\hat{v}^*(x, y)$ 的定义，有：

$$\begin{aligned}
&\|\hat{v}^*(x, y_1) - \mathcal{P}_{y_2}^{y_1} \hat{v}^*(x, y_2)\|_{y_1} = \|\mathcal{H}_y^{-1} g(x, y_1) \mathcal{G}_y f(x, y_1) - \mathcal{P}_{y_2}^{y_1} \mathcal{H}_y^{-1} g(x, y_2) \mathcal{G}_y f(x, y_2)\|_{y_1} \\
&\leq \|\mathcal{H}_y^{-1} g(x, y_1) (\mathcal{G}_y f(x, y_1) - \mathcal{P}_{y_2}^{y_1} \mathcal{G}_y f(x, y_2))\|_{y_1} + \|(\mathcal{H}_y^{-1} g(x, y_1) \mathcal{P}_{y_2}^{y_1} - \mathcal{P}_{y_2}^{y_1} \mathcal{H}_y^{-1} g(x, y_2)) \mathcal{G}_y f(x, y_2)\|_{y_1} \\
&\leq \frac{L_f}{\mu} d(y_1, y_2) + l_f \frac{\rho}{\mu^2} d(y_1, y_2),
\end{aligned}$$

其中第二个不等式由 (9) 导出。 $\square$

引理 E.4. 假设假设 3.1、3.2 和 3.3 成立。则对于任何 $t \geq 0$ ，有：

$$d(y_t^{K_t}, y^*(x_t))^2 \leq \frac{\epsilon_y}{\mu^2}, \text{ 且 } \|v_t^{N_t} - \hat{v}^*(x_t, y_t^{K_t})\|_{y_t^{K_t}}^2 \leq \frac{\epsilon_v}{\mu^2}.$$

证明. 根据 AdaRHD 类算法对于下层问题和线性系统的终止条件，我们有：

$$\|\mathcal{G}_y g(x_t, y_t^{K_t})\|_{y_t^{K_t}}^2 \leq \epsilon_y, \text{ 且 } \|\nabla_v R(x_t, y_t^{K_t}, v_t^{N_t})\|_{y_t^{K_t}}^2 \leq \epsilon_v.$$

由 g 和 R 的强凸性（参见引理 E.3），有：

$$d^2(y_t^{K_t}, y^*(x_t)) \leq \frac{1}{\mu^2} \left\| \mathcal{G}_y g(x_t, y_t^{K_t}) - \mathcal{P}_{y^*(x_t)}^{y_t^{K_t}} \mathcal{G}_y g(x_t, y^*(x_t)) \right\|_{y_t^{K_t}}^2 \leq \frac{\epsilon_y}{\mu^2}$$

以及

$$\|v_t^{N_t} - \hat{v}^*(x_t, y_t^{K_t})\|_{y_t^{K_t}}^2 \leq \frac{1}{\mu^2} \left\| \nabla_v R(x_t, y_t^{K_t}, v_t^{N_t}) - \nabla_v R(x_t, y_t^{K_t}, \hat{v}^*(x_t, y_t^{K_t})) \right\|_{y_t^{K_t}}^2 \leq \frac{\epsilon_v}{\mu^2},$$

其中利用了 $\|\mathcal{G}_y g(x_t, y^*(x_t))\|^2 = 0$ 和 $\|\nabla_v R(x_t, y_t^{K_t}, \hat{v}^*(x_t, y_t^{K_t}))\|^2 = 0$ 的定义。 $\square$

引理 E.5. 假设假设 3.1、3.2 和 3.3 成立。则对于任何 $t \geq 0$ ，有：

$$\|\hat{\mathcal{G}}F(x_t, y_t^{K_t}, v_t^{N_t})\|^2 \leq C_f^2,$$

其中 $C_f := \left(\frac{2L_g^2 \epsilon_v}{\mu^2} + \frac{4L_g^2 l_f^2}{\mu^2} + 4l_f^2 \right)^{\frac{1}{2}}$ 。

证明. 根据 $\hat{\mathcal{G}}F$ 的定义，有：

$$\begin{aligned} & \|\hat{\mathcal{G}}F(x_t, y_t^{K_t}, v_t^{N_t})\|_{x_t}^2 \\ & \leq 2 \left\| \hat{\mathcal{G}}F(x_t, y_t^{K_t}, v_t^{N_t}) - \hat{\mathcal{G}}F(x_t, y_t^{K_t}, \hat{v}^*(x_t, y_t^{K_t})) \right\|_{x_t}^2 + 2 \left\| \hat{\mathcal{G}}F(x_t, y_t^{K_t}, \hat{v}^*(x_t, y_t^{K_t})) \right\|_{x_t}^2 \\ & = 2 \left\| \mathcal{G}_{xy}^2 g(x_t, y_t^{K_t}) (v_t^{N_t} - \hat{v}^*(x_t, y_t^{K_t})) \right\|_{x_t}^2 + 2 \left\| \mathcal{G}_x f(x_t, y_t^{K_t}) - \mathcal{G}_{xy}^2 g(x_t, y_t^{K_t}) \hat{v}^*(x_t, y_t^{K_t}) \right\|_{x_t}^2 \\ & \leq 2 \left\| \mathcal{G}_{xy}^2 g(x_t, y_t^{K_t}) \right\|_{x_t}^2 \|v_t^{N_t} - \hat{v}^*(x_t, y_t^{K_t})\|_{y_t^{K_t}}^2 + 4 \|\mathcal{G}_x f(x_t, y_t^{K_t})\|_{x_t}^2 + 4 \|\mathcal{G}_{xy}^2 g(x_t, y_t^{K_t}) \hat{v}^*(x_t, y_t^{K_t})\|_{x_t}^2 \\ & \leq \frac{2L_g^2 \epsilon_v}{\mu^2} + \frac{4L_g^2 l_f^2}{\mu^2} + 4l_f^2, \end{aligned}$$

其中最后一个不等式由假设 3.1、3.2、3.3 以及引理 E.3 和 E.4 导出。 $\square$

F 第 3.3 节的证明

F.1 引理 3.1 的证明

证明. 根据 $v_t^*(x_t)$ 和 $\hat{v}_t^*(x_t, y_t^{K_t})$ 的定义，我们有：

$$\begin{aligned} & \|\hat{\mathcal{G}}F(x_t, y_t^{K_t}, v_t^{N_t}) - \mathcal{G}F(x_t)\|_{x_t} \\ & \leq \|\mathcal{G}_x f(x_t, y_t^{K_t}) - \mathcal{G}_x f(x_t, y^*(x_t))\|_{x_t} + \|\mathcal{G}_{xy}^2 g(x_t, y_t^{K_t}) v_t^{N_t} - \mathcal{G}_{xy}^2 g(x_t, y^*(x_t)) v_t^*(x_t)\|_{x_t} \\ & \leq L_f d(y_t^{K_t}, y^*(x_t)) + \|\mathcal{G}_{xy}^2 g(x_t, y_t^{K_t})\|_{x_t} \|v_t^{N_t} - \mathcal{P}_{y^*(x_t)}^{y_t^{K_t}} v_t^*(x_t)\|_{y_t^{K_t}} \\ & \quad + \|\mathcal{G}_{xy}^2 g(x_t, y_t^{K_t}) - \mathcal{G}_{xy}^2 g(x_t, y^*(x_t)) \mathcal{P}_{y_t^{K_t}}^{y^*(x_t)}\|_{x_t} \|v_t^*(x_t)\|_{y^*(x_t)} \end{aligned}$$

$$\begin{aligned}
&\leq L_f d(y_t^{K_t}, y^*(x_t)) + L_g \|v_t^{N_t} - \mathcal{P}_{y^*(x_t)}^{y_t^{K_t}} v_t^*(x_t)\|_{y_t^{K_t}} + \rho \|v_t^*(x_t)\|_{y^*(x_t)} d(y_t^{K_t}, y^*(x_t)) \\
&\leq (L_f + \frac{\rho l_f}{\mu}) d(y_t^{K_t}, y^*(x_t)) + L_g \|v_t^{N_t} - \mathcal{P}_{y^*(x_t)}^{y_t^{K_t}} v_t^*(x_t)\|_{y_t^{K_t}},
\end{aligned} \tag{10}$$

其中第三和第四个不等式分别由假设 3.3 和引理 E.3 (2) 导出。

对于 $\|v_t^{N_t} - \mathcal{P}_{y^*(x_t)}^{y_t^{K_t}} v_t^*(x_t)\|_{y_t^{K_t}}$, 我们有:

$$\begin{aligned}
\|v_t^{N_t} - \mathcal{P}_{y_t^{K_t}}^{y^*(x_t)} v_t^*(x_t)\|_{y_t^{K_t}} &\leq \|v_t^{N_t} - \hat{v}_t^*(x_t, y_t^{K_t})\|_{y_t^{K_t}} + \|\hat{v}_t^*(x_t, y_t^{K_t}) - \mathcal{P}_{y_t^{K_t}}^{y^*(x_t)} \hat{v}_t^*(x_t, y^*(x_t))\|_{y_t^{K_t}} \\
&\leq \|v_t^{N_t} - \hat{v}_t^*(x_t, y_t^{K_t})\|_{y_t^{K_t}} + (\frac{L_f}{\mu} + \frac{l_f \rho}{\mu^2}) d(y_t^{K_t}, y^*(x_t)),
\end{aligned}$$

其中最后一个不等式由引理 E.3 (3) 以及 $v_t^*(x_t) = \hat{v}_t^*(x_t, y^*(x_t))$ 这一事实得出。

将其与 (10) 结合可证:

$$\begin{aligned}
\|\hat{\mathcal{G}}F(x_t, y_t^{K_t}, v_t^{N_t}) - \mathcal{G}F(x_t)\|_{x_t} &\leq \left(L_f + \frac{\rho l_f}{\mu}\right) d(y_t^{K_t}, y^*(x_t)) + L_g \|v_t^{N_t} - \mathcal{P}_{y^*(x_t)}^{y_t^{K_t}} v_t^*(x_t)\|_{y_t^{K_t}} \\
&\leq \left(L_f + \frac{\rho l_f}{\mu}\right) d(y_t^{K_t}, y^*(x_t)) + L_g \left(\|v_t^{N_t} - \hat{v}_t^*(x_t, y_t^{K_t})\|_{y_t^{K_t}} + (\frac{L_f}{\mu} + \frac{l_f \rho}{\mu^2}) d(y_t^{K_t}, y^*(x_t))\right) \\
&= \left(L_f + \frac{l_f \rho}{\mu} + L_g \left(\frac{L_f}{\mu} + \frac{l_f \rho}{\mu^2}\right)\right) d(y_t^{K_t}, y^*(x_t)) + L_g \|v_t^{N_t} - \hat{v}_t^*(x_t, y_t^{K_t})\|_{y_t^{K_t}}.
\end{aligned}$$

证毕。 $\square$

F.2 命题 F.1 及其引理

受 [67] 中命题 1 的启发, 我们首先给出关于步长 a_t 、 b_k 和 c_n 的结果。

命题 F.1. 假设假设 3.1、3.2 和 3.3 成立。记 $\{T, K, N\}$ 为变量 $\{x, y, v\}$ 的迭代次数。给定任意常数 $C_a \geq a_0$, $C_b \geq b_0$, $C_c \geq c_0$, 则:

AdaRHD-GD:

- (1) 要么对于所有 $t \leq T$ 都有 $a_t \leq C_a$, 要么存在 $t_1 \leq T$ 使得 $a_{t_1} \leq C_a$ 且 $a_{t_1+1} > C_a$;
- (2) 要么对于所有 $k \leq K$ 都有 $b_k \leq C_b$, 要么存在 $k_1 \leq K$ 使得 $b_{k_1} \leq C_b$ 且 $b_{k_1+1} > C_b$;
- (3) 要么对于所有 $n \leq N$ 都有 $c_n \leq C_c$, 要么存在 $n_1 \leq N$ 使得 $c_{n_1} \leq C_c$ 且 $c_{n_1+1} > C_c$ 。

在证明命题 F.1 之前, 我们需要两个技术引理。

引理 F.1. 假设假设 3.1、3.2 和 3.3 成立。则有:

$$d^2(y_t^{k+1}, y^*(x_t)) \leq (1 + \frac{1}{b_{k+1}^2} \zeta L_g^2 - \frac{\mu}{b_{k+1}}) d^2(y_t^k, y^*(x_t)).$$

证明. 由引理 B.1 可得:

$$\begin{aligned}
d^2(y_t^{k+1}, y^*(x_t)) &\leq d^2(y_t^k, y^*(x_t)) + \frac{1}{b_{k+1}^2} \zeta \|\mathcal{G}_y g(x_t, y_t^k)\|_{y_t^k}^2 + \frac{2}{b_{k+1}} \langle \mathcal{G}_y g(x_t, y_t^k), \text{Exp}_{y_t^k}^{-1} y^*(x_t) \rangle_{y_t^k} \\
&\leq d^2(y_t^k, y^*(x_t)) + \frac{1}{b_{k+1}^2} \zeta \|\mathcal{G}_y g(x_t, y_t^k)\|_{y_t^k}^2 + \frac{2}{b_{k+1}} (g(x_t, y^*(x_t)) - g(x_t, y_t^k) - \frac{\mu}{2} d^2(y_t^k, y^*(x_t))) \\
&\leq (1 + \frac{1}{b_{k+1}^2} \zeta L_g^2 - \frac{\mu}{b_{k+1}}) d^2(y_t^k, y^*(x_t)),
\end{aligned}$$

其中第二个不等式由 g 的测地线强凸性得出，第三个不等式由下式得出：

$$\|\mathcal{G}_y g(x_t, y_t^k)\|_{y_t^k}^2 = \|\mathcal{G}_y g(x_t, y_t^k) - \mathcal{P}_{y^*(x_t)}^{y_t^k} \mathcal{G}_y g(x_t, y^*(x_t))\|_{y_t^k}^2 \leq L_g^2 d^2(y_t^k, y^*(x_t)).$$

证毕。 $\square$

引理 F.2. 假设假设 3.1、3.2 和 3.3 成立。则有：

$$\langle \mathcal{G}_y g(x_t, y_t^k), \text{Exp}_{y_t^k}^{-1}(y^*(x_t)) \rangle_{y_t^k} \leq -\frac{1}{2L_g} \|\mathcal{G}_y g(x_t, y_t^k)\|_{y_t^k}^2.$$

证明. 根据假设 3.3, 对于给定的任意 $y \in \mathcal{M}_y$, 有：

$$g(x_t, y^*(x_t)) \leq g(x_t, y) \leq g(x_t, y_t^k) + \langle \mathcal{G}_y g(x_t, y_t^k), \text{Exp}_{y_t^k}^{-1}(y) \rangle_{y_t^k} + \frac{L_g}{2} d^2(y_t^k, y). \quad (11)$$

在 (13) 中取 $y = \text{Exp}_{y_t^k}(-\frac{1}{L_g} \mathcal{G}_y g(x_t, y_t^k))$ 可得：

$$g(x_t, y^*(x_t)) \leq g(x_t, y_t^k) - \frac{1}{L_g} \|\mathcal{G}_y g(x_t, y_t^k)\|_{y_t^k}^2 + \frac{L_g}{2} \|\frac{1}{L_g} \mathcal{G}_y g(x_t, y_t^k)\|_{y_t^k}^2 = g(x_t, y_t^k) - \frac{1}{2L_g} \|\mathcal{G}_y g(x_t, y_t^k)\|_{y_t^k}^2,$$

这表明：

$$g(x_t, y^*(x_t)) - g(x_t, y_t^k) \leq -\frac{1}{2L_g} \|\mathcal{G}_y g(x_t, y_t^k)\|_{y_t^k}^2. \quad (12)$$

由 g 关于 y 的测地线凸性可知：

$$g(x_t, y^*(x_t)) - g(x_t, y_t^k) \geq \langle \mathcal{G}_y g(x_t, y_t^k), \text{Exp}_{y_t^k}^{-1}(y^*(x_t)) \rangle_{y_t^k}.$$

结合 (14) 意味着：

$$\langle \mathcal{G}_y g(x_t, y_t^k), \text{Exp}_{y_t^k}^{-1}(y^*(x_t)) \rangle_{y_t^k} \leq g(x_t, y^*(x_t)) - g(x_t, y_t^k) \leq -\frac{1}{2L_g} \|\mathcal{G}_y g(x_t, y_t^k)\|_{y_t^k}^2.$$

证毕。 $\square$

证明. 由 Lemma B.1 可得：

$$\begin{aligned} d^2(y_t^{k+1}, y^*(x_t)) &\leq d^2(y_t^k, y^*(x_t)) + \frac{1}{b_{k+1}^2} \zeta \|\mathcal{G}_y g(x_t, y_t^k)\|_{y_t^k}^2 + \frac{2}{b_{k+1}} \langle \mathcal{G}_y g(x_t, y_t^k), \text{Exp}_{y_t^k}^{-1} y^*(x_t) \rangle_{y_t^k} \\ &\leq d^2(y_t^k, y^*(x_t)) + \frac{1}{b_{k+1}^2} \zeta \|\mathcal{G}_y g(x_t, y_t^k)\|_{y_t^k}^2 + \frac{2}{b_{k+1}} (g(x_t, y^*(x_t)) - g(x_t, y_t^k) - \frac{\mu}{2} d^2(y_t^k, y^*(x_t))) \\ &\leq (1 + \frac{1}{b_{k+1}^2} \zeta L_g^2 - \frac{\mu}{b_{k+1}}) d^2(y_t^k, y^*(x_t)), \end{aligned}$$

其中第二个不等式由 g 的测地线强凸性得出，第三个不等式由下式得出：

$$\|\mathcal{G}_y g(x_t, y_t^k)\|_{y_t^k}^2 = \|\mathcal{G}_y g(x_t, y_t^k) - \mathcal{P}_{y^*(x_t)}^{y_t^k} \mathcal{G}_y g(x_t, y^*(x_t))\|_{y_t^k}^2 \leq L_g^2 d^2(y_t^k, y^*(x_t)).$$

证毕。 $\square$

引理 F.3. 假设假设 3.1、3.2 和 3.3 成立。则有：

$$\langle \mathcal{G}_y g(x_t, y_t^k), \text{Exp}_{y_t^k}^{-1}(y^*(x_t)) \rangle_{y_t^k} \leq -\frac{1}{2L_g} \|\mathcal{G}_y g(x_t, y_t^k)\|_{y_t^k}^2.$$

证明. 根据假设 3.3, 对于给定的任意 $y \in \mathcal{M}_y$, 有:

$$g(x_t, y^*(x_t)) \leq g(x_t, y) \leq g(x_t, y_t^k) + \langle \mathcal{G}_y g(x_t, y_t^k), \text{Exp}_{y_t^k}^{-1}(y) \rangle_{y_t^k} + \frac{L_g}{2} d^2(y_t^k, y). \quad (13)$$

在 (13) 中取 $y = \text{Exp}_{y_t^k}(-\frac{1}{L_g} \mathcal{G}_y g(x_t, y_t^k))$ 可得:

$$g(x_t, y^*(x_t)) \leq g(x_t, y_t^k) - \frac{1}{L_g} \|\mathcal{G}_y g(x_t, y_t^k)\|_{y_t^k}^2 + \frac{L_g}{2} \left\| \frac{1}{L_g} \mathcal{G}_y g(x_t, y_t^k) \right\|_{y_t^k}^2 = g(x_t, y_t^k) - \frac{1}{2L_g} \|\mathcal{G}_y g(x_t, y_t^k)\|_{y_t^k}^2,$$

这表明:

$$g(x_t, y^*(x_t)) - g(x_t, y_t^k) \leq -\frac{1}{2L_g} \|\mathcal{G}_y g(x_t, y_t^k)\|_{y_t^k}^2. \quad (14)$$

由 g 关于 y 的测地线凸性可知:

$$g(x_t, y^*(x_t)) - g(x_t, y_t^k) \geq \langle \mathcal{G}_y g(x_t, y_t^k), \text{Exp}_{y_t^k}^{-1}(y^*(x_t)) \rangle_{y_t^k}.$$

结合 (14) 意味着:

$$\langle \mathcal{G}_y g(x_t, y_t^k), \text{Exp}_{y_t^k}^{-1}(y^*(x_t)) \rangle_{y_t^k} \leq g(x_t, y^*(x_t)) - g(x_t, y_t^k) \leq -\frac{1}{2L_g} \|\mathcal{G}_y g(x_t, y_t^k)\|_{y_t^k}^2.$$

证毕. $\square$

G 第 3.4 节的证明

我们首先定义步长 a_t 、 b_t 、 c_t 和 d_t 的阈值常数如下:

$$\begin{aligned} C_a &:= \max \left\{ \frac{2L_F}{d_0}, a_0 \right\}, \\ C_b &:= \max \left\{ \mu + L_g, \frac{2\mu L_g}{\mu + L_g}, b_0, 64\alpha_0^2, 1 \right\}, \\ C_c &:= \max \left\{ 2(\mu + L_g), \frac{\mu L_g}{\mu + L_g}, c_0, 64\alpha_0^2, 1, L_g \right\}, \\ C_d &:= C_b + C_c, \end{aligned} \quad (15)$$

其中 α_0 为:

$$\begin{aligned} \alpha_0 &:= \left(\left(\frac{4(\mu + L_g)^2}{\mu L_g} + 8 \right) \left(\frac{\rho l_f}{\mu} + L_f \right)^2 \frac{1}{\mu^2} + 1 \right) \frac{(\mu + L_g)^2 L_y^2}{\zeta \mu L_g C_b} \\ &\quad + \frac{4(\mu + L_g)(\mu + L_g) L_y^2}{\mu^3 L_g d_0} \left(\frac{\rho l_f}{\mu} + L_f \right)^2 + \frac{4(\mu + L_g)^2 L_v^2}{\mu L_g c_0}. \end{aligned} \quad (16)$$

G.1 单步更新后目标函数的改进

我们给出以下关于单步更新后 F 改进量的引理。

引理 G.1. 假设假设 3.1、3.2 和 3.3 成立。则有:

$$\begin{aligned} F(x_{t+1}) &\leq F(x_t) - \frac{1}{2a_{t+1}d_{t+1}} \|\mathcal{G}F(x_t)\|_{x_t}^2 - \frac{1}{2a_{t+1}d_{t+1}} \left(1 - \frac{L_F}{a_{t+1}d_{t+1}} \right) \|\widehat{\mathcal{G}}F(x_t, y_t, v_t)\|_{x_t}^2 \\ &\quad + \frac{\bar{L}^2}{2\mu^2} \left[1 + 2 \left(\frac{l_f}{\mu} + \frac{l_f \rho}{\mu^2} \right)^2 \right] \frac{\|\mathcal{G}_y g(x_t, y_t)\|_{y_t}^2}{a_{t+1}d_{t+1}} + \frac{\bar{L}^2}{\mu^2} \frac{\|\nabla_v R(x_t, y_t, v_t)\|_{y_t}^2}{a_{t+1}d_{t+1}}. \end{aligned} \quad (17)$$

此外, 如果命题 F.1 中的 t_1 存在, 则对于 $t \geq t_1$, 我们有:

$$\begin{aligned} F(x_{t+1}) \leq & F(x_t) - \frac{1}{2a_{t+1}d_{t+1}} \|\mathcal{G}F(x_t)\|_{x_t}^2 - \frac{1}{4a_{t+1}d_{t+1}} \|\widehat{\mathcal{G}}F(x_t, y_t, v_t)\|_{x_t}^2 \\ & + \frac{\bar{L}^2}{2\mu^2} \left[1 + 2 \left(\frac{l_f}{\mu} + \frac{l_f \rho}{\mu^2} \right)^2 \right] \frac{\|\mathcal{G}_y g(x_t, y_t)\|_{y_t}^2}{a_{t+1}d_{t+1}} + \frac{\bar{L}^2}{\mu^2} \frac{\|\nabla_v R(x_t, y_t, v_t)\|_{y_t}^2}{a_{t+1}d_{t+1}}, \end{aligned} \quad (18)$$

其中 $\bar{L}$ 在文献 [51] 中定义。

证明. 根据引理 E.2 2, 同 [51] 中的推导可得:

$$\begin{aligned} F(x_{t+1}) \leq & F(x_t) - \frac{1}{2a_{t+1}d_{t+1}} \|\mathcal{G}F(x_t)\|_{x_t}^2 - \frac{1}{2a_{t+1}d_{t+1}} \left(1 - \frac{L_F}{a_{t+1}d_{t+1}} \right) \|\widehat{\mathcal{G}}F(x_t, y_t, v_t)\|_{x_t}^2 \\ & + \frac{1}{2a_{t+1}d_{t+1}} \left\| \mathcal{G}F(x_t) - \widehat{\mathcal{G}}F(x_t, y_t, v_t) \right\|_{x_t}^2 \\ \leq & F(x_t) - \frac{1}{2a_{t+1}d_{t+1}} \|\mathcal{G}F(x_t)\|_{x_t}^2 - \frac{1}{2a_{t+1}d_{t+1}} \left(1 - \frac{L_F}{a_{t+1}d_{t+1}} \right) \|\widehat{\mathcal{G}}F(x_t, y_t, v_t)\|_{x_t}^2 \\ & + \frac{\bar{L}^2}{2a_{t+1}d_{t+1}} (d^2(y_t, y^*(x_t)) + \|v_t - \mathcal{P}_{y^*(x_t)}^{y_t} v^*(x_t)\|_{y_t}^2). \end{aligned} \quad (19)$$

其中最后一个不等式由引理 3.1 得出。

由于 $g(x, y)$ 关于 y 是 μ -强凸的, 且 $R(x, y, v)$ 关于 v 是 μ -强凸的, 我们有:

$$\begin{aligned} & d^2(y_t, y^*(x_t)) + \|v_t - \mathcal{P}_{y^*(x_t)}^{y_t} v^*(x_t)\|_{y_t}^2 \\ \leq & \frac{1}{\mu^2} \left\| \mathcal{G}_y g(x_t, y_t) - \mathcal{G}_y g(x_t, y^*(x_t)) \right\|_{y_t}^2 + 2\|v_t - \hat{v}^*(x_t, y_t)\|_{y_t}^2 + 2\|\hat{v}^*(x_t, y_t) - \mathcal{P}_{y^*(x_t)}^{y_t} v^*(x_t)\|_{y_t}^2 \\ \leq & \frac{1}{\mu^2} \|\mathcal{G}_y g(x_t, y_t)\|_{y_t}^2 + \frac{2}{\mu^2} \|\nabla_v R(x_t, y_t, v_t)\|_{y_t}^2 + 2 \left(\frac{l_f}{\mu} + \frac{l_f \rho}{\mu^2} \right)^2 d^2(y_t, y^*(x_t)) \\ \leq & \frac{1}{\mu^2} \|\mathcal{G}_y g(x_t, y_t)\|_{y_t}^2 + \frac{2}{\mu^2} \|\nabla_v R(x_t, y_t, v_t)\|_{y_t}^2 + \frac{2}{\mu^2} \left(\frac{l_f}{\mu} + \frac{l_f \rho}{\mu^2} \right)^2 \|\mathcal{G}_y g(x_t, y_t)\|_{y_t}^2 \\ \leq & \left[\frac{1}{\mu^2} + \frac{2}{\mu^2} \left(\frac{l_f}{\mu} + \frac{l_f \rho}{\mu^2} \right)^2 \right] \|\mathcal{G}_y g(x_t, y_t)\|_{y_t}^2 + \frac{2}{\mu^2} \|\nabla_v R(x_t, y_t, v_t)\|_{y_t}^2, \end{aligned} \quad (20)$$

其中第二个不等式由引理 E.3 3 得出。由此可得 (17) 所需的结果。

如果命题 F.1 中的 t_1 存在, 则对于 $t \geq t_1$, 我们有 $a_{t+1} > C_a \geq 2L_F/d_0$ 。因此:

$$1 - \frac{L_F}{a_{t+1}d_{t+1}} \geq 1 - \frac{L_F}{a_{t+1}d_0} \geq \frac{1}{2}.$$

结合 (17) 即可得出 (18)。证毕。 $\square$

G.2 初步界限

引理 G.2. 假设假设 3.1、3.2 和 3.3 成立。如果命题 F.1 中的 k_1 存在, 则对于所有整数 $k_1 \leq t < T$, 有:

$$\sum_{i=k_1}^t \frac{\|\mathcal{G}_y g(x_i, y_i)\|_{y_i}^2}{b_{i+1}} \leq \frac{(\mu + L_g)C_b^2}{\zeta\mu^2} + \frac{(\mu + L_g)^2 L_y^2}{\zeta\mu L_g d_0} + \frac{(\mu + L_g)^2 L_y^2}{\zeta\mu L_g} \sum_{i=k_1}^t \frac{\|\widehat{\mathcal{G}}F(x_i, y_i, v_i)\|_{y_i}^2}{a_{i+1}^2 d_{i+1}}$$

证明. 给定 $\bar{\lambda}_{t+1} > 0$, 根据 Young 不等式:

$$d^2(y_{t+1}, y^*(x_{t+1})) \leq (1 + \bar{\lambda}_{t+1})d^2(y_{t+1}, y^*(x_t)) + \left(1 + \frac{1}{\bar{\lambda}_{t+1}}\right)d^2(y^*(x_t), y^*(x_{t+1})). \quad (21)$$

对于 $d^2(y_{t+1}, y^*(x_t))$, 由引理 B.1 可得:

$$\begin{aligned}
& d^2(y_{t+1}, y^*(x_t)) \\
&= d^2(y_t, y^*(x_t)) + \frac{\zeta}{b_{t+1}^2} \|\mathcal{G}_y g(x_t, y_t)\|_{y_t}^2 + \frac{2}{b_{t+1}} \langle \text{Exp}_{y_t}^{-1} y^*(x_t), \mathcal{G}_y g(x_t, y_t) \rangle \\
&\leq d^2(y_t, y^*(x_t)) + \frac{\zeta}{b_{t+1}^2} \|\mathcal{G}_y g(x_t, y_t)\|_{y_t}^2 - \frac{2}{b_{t+1}} \left(\frac{\mu L_g}{\mu + L_g} d^2(y_t, y^*(x_t)) + \frac{1}{\mu + L_g} \|\mathcal{G}_y g(x_t, y_t)\|_{y_t}^2 \right) \\
&= \left(1 - \frac{2\mu L_g}{b_{t+1}(\mu + L_g)} \right) d^2(y_t, y^*(x_t)) + \frac{\zeta}{b_{t+1}} \left(\frac{1}{b_{t+1}} - \frac{2}{\mu + L_g} \right) \|\mathcal{G}_y g(x_t, y_t)\|_{y_t}^2 \\
&\leq \left(1 - \frac{2\mu L_g}{b_{t+1}(\mu + L_g)} \right) d^2(y_t, y^*(x_t)) - \frac{\zeta}{b_{t+1}(\mu + L_g)} \|\mathcal{G}_y g(x_t, y_t)\|_{y_t}^2,
\end{aligned} \tag{22}$$

其中第一个不等式由 [9, 引理 3.11] 得出, 即:

$$\langle -\text{Exp}_{y_t}^{-1} y^*(x_t), \mathcal{G}_y g(x_t, y_t) \rangle \geq \frac{\mu L_g}{\mu + L_g} d^2(y_t, y^*(x_t)) + \frac{1}{\mu + L_g} \|\mathcal{G}_y g(x_t, y_t)\|_{y_t}^2,$$

最后一个不等式由 $b_{t+1} \geq c_b \geq \mu + L_g$ 得出。

结合 (21), 我们有:

$$\begin{aligned}
& d^2(y_{t+1}, y^*(x_{t+1})) \\
&\leq (1 + \bar{\lambda}_{t+1}) \left(1 - \frac{2\mu L_g}{b_{t+1}(\mu + L_g)} \right) d^2(y_t, y^*(x_t)) - (1 + \bar{\lambda}_{t+1}) \frac{\zeta}{b_{t+1}(\mu + L_g)} \|\mathcal{G}_y g(x_t, y_t)\|_{y_t}^2 \\
&\quad + \left(1 + \frac{1}{\bar{\lambda}_{t+1}} \right) d^2(y^*(x_t), y^*(x_{t+1})).
\end{aligned} \tag{23}$$

由此可得:

$$\begin{aligned}
& (1 + \bar{\lambda}_{t+1}) \frac{\zeta}{b_{t+1}(\mu + L_g)} \|\mathcal{G}_y g(x_t, y_t)\|_{y_t}^2 \\
&\leq (1 + \bar{\lambda}_{t+1}) \left(1 - \frac{2\mu L_g}{b_{t+1}(\mu + L_g)} \right) d^2(y_t, y^*(x_t)) - d^2(y_{t+1}, y^*(x_{t+1})) \\
&\quad + \left(1 + \frac{1}{\bar{\lambda}_{t+1}} \right) d^2(y^*(x_t), y^*(x_{t+1})).
\end{aligned}$$

若设 $\bar{\lambda}_{t+1} := \frac{2\mu L_g}{b_{t+1}(\mu + L_g)}$, 由于根据 (15) 有 $b_{t+1} > C_b \geq \frac{2\mu L_g}{\mu + L_g}$, 则 $\bar{\lambda}_{t+1} \leq 1$ 成立。于是有:

$$\begin{aligned}
\zeta \frac{\|\mathcal{G}_y g(x_t, y_t)\|_{y_t}^2}{b_{t+1}} &\leq \zeta (1 + \bar{\lambda}_{t+1}) \frac{\|\mathcal{G}_y g(x_t, y_t)\|_{y_t}^2}{b_{t+1}} \\
&\leq (\mu + L_g) (1 - \bar{\lambda}_{t+1}^2) d^2(y_t, y^*(x_t)) - d^2(y_{t+1}, y^*(x_{t+1})) + (\mu + L_g) \frac{2}{\bar{\lambda}_{t+1}} d^2(y^*(x_t), y^*(x_{t+1})) \\
&\leq (\mu + L_g) (d^2(y_t, y^*(x_t)) - d^2(y_{t+1}, y^*(x_{t+1}))) + \frac{2(\mu + L_g)}{\bar{\lambda}_{t+1}} d^2(y^*(x_t), y^*(x_{t+1})) \\
&= (\mu + L_g) (d^2(y_t, y^*(x_t)) - d^2(y_{t+1}, y^*(x_{t+1}))) + \frac{(\mu + L_g)^2 b_{t+1}}{\mu L_g} d^2(y^*(x_t), y^*(x_{t+1})) \\
&\leq (\mu + L_g) (d^2(y_t, y^*(x_t)) - d^2(y_{t+1}, y^*(x_{t+1}))) + \frac{(\mu + L_g)^2 L_y^2 b_{t+1}}{\mu L_g} d^2(x_t, x_{t+1})
\end{aligned} \tag{24}$$

其中第二个不等式由 $\bar{\lambda}_{t+1} \leq 1$ 得出, 最后一个不等式由 $y^*(x)$ 关于 x 的 L_y -Lipschitz 连续性得出。

将 (24) 从 k_1 到 t 求和:

$$\sum_{i=k_1}^t \zeta \frac{\|\mathcal{G}_y g(x_i, y_i)\|_{y_i}^2}{b_{i+1}}$$

$$\begin{aligned}
&\leq (\mu + L_g)d^2(y_{k_1-1}, y^*(x_{k_1-1})) + \frac{(\mu + L_g)^2 L_y^2}{\mu L_g} \sum_{i=k_1-1}^t b_{i+1} d^2(x_i, x_{i+1}) \\
&\leq \frac{\mu + L_g}{\mu^2} \|\mathcal{G}_y g(x_{k_1-1}, y_{k_1-1})\|_{y_{k_1-1}}^2 + \frac{(\mu + L_g)^2 L_y^2}{\mu L_g} \sum_{i=k_1-1}^t \frac{\|\widehat{\mathcal{G}}F(x_i, y_i, v_i)\|_{x_i}^2}{a_{i+1}^2 d_{i+1}} \\
&\leq \frac{(\mu + L_g)C_b^2}{\mu^2} + \frac{(\mu + L_g)^2 L_y^2}{\mu L_g d_0} + \frac{(\mu + L_g)^2 L_y^2}{\mu L_g} \sum_{i=k_1}^t \frac{\|\widehat{\mathcal{G}}F(x_i, y_i, v_i)\|_{x_i}^2}{a_{i+1}^2 d_{i+1}}, \tag{25}
\end{aligned}$$

其中第三个不等式由 g 的测地线强凸性和 x_i 的更新方式得出，第四个不等式由 $d_{i+1} = \max\{b_{i+1}, c_{i+1}\}$ 得出，最后一个不等式由 C_b 和 a_i 的定义以及 $d_0 \leq d_{k_1}$ 这一事实得出。证毕。 $\square$

引理 G.3. 假设假设 3.1、3.2 和 3.3 成立。如果命题 F.1 中的 n_1 存在，则对于所有 $n_1 \leq t < T$ ，有：

$$\begin{aligned}
&\sum_{i=n_1}^t \frac{\|\nabla_v R(x_i, y_i, v_i)\|_{y_i}^2}{d_{i+1}} \\
&\leq \frac{4(\mu + L_g)C_c^2}{\mu^2} + \frac{4(\mu + L_g)C_b^2}{\mu^4} \left(\frac{\rho l_f}{\mu} + L_f \right)^2 \\
&\quad + \frac{4(\mu + L_g)(\mu + L_g)L_y^2}{\mu^3 L_g d_0} \left(\frac{\rho l_f}{\mu} + L_f \right)^2 \sum_{i=k_1-1}^{n_1-2} \frac{\|\widehat{\mathcal{G}}F(x_i, y_i, v_i)\|_{x_i}^2}{a_{i+1}^2} \\
&\quad + \frac{4(\mu + L_g)^2 L_v^2}{\mu L_g C_c} \sum_{i=n_1-1}^t \frac{\|\widehat{\mathcal{G}}F(x_i, y_i, v_i)\|_{x_i}^2}{a_{i+1}^2} \\
&\quad + \left(\frac{4(\mu + L_g)^2}{\mu L_g} + 8 \right) \left(\frac{\rho l_f}{\mu} + L_f \right)^2 \frac{1}{\mu^2} \sum_{i=n_1-1}^t \frac{\|\mathcal{G}_y g(x_i, y_i)\|_{y_i}^2}{b_{i+1}}.
\end{aligned}$$

证明. 给定 $\hat{\lambda}_{t+1} > 0$ ，根据 Young 不等式：

$$\|v_{t+1} - \mathcal{P}_{y^*(x_{t+1})}^{y_t} v^*(x_{t+1})\|_{y_t}^2 \leq (1 + \hat{\lambda}_{t+1}) \|v_{t+1} - \mathcal{P}_{y^*(x_t)}^{y_t} v^*(x_t)\|_{y_t}^2 + \left(1 + \frac{1}{\hat{\lambda}_{t+1}}\right) \|v^*(x_t) - \mathcal{P}_{y^*(x_{t+1})}^{y^*(x_t)} v^*(x_{t+1})\|_{y^*(x_t)}^2. \tag{26}$$

对于 $\|v_{t+1} - \mathcal{P}_{y^*(x_t)}^{y_t} v^*(x_t)\|_{y_t}^2$ ，有：

$$\begin{aligned}
&\|v_{t+1} - \mathcal{P}_{y^*(x_t)}^{y_t} v^*(x_t)\|_{y_t}^2 \\
&= \left\| v_t - \frac{1}{d_{t+1}} \nabla_v R(x_t, y_t, v_t) - \mathcal{P}_{y^*(x_t)}^{y_t} v^*(x_t) \right\|_{y_t}^2 \\
&= \|v_t - \mathcal{P}_{y^*(x_t)}^{y_t} v^*(x_t)\|_{y_t}^2 + \frac{1}{d_{t+1}^2} \|\nabla_v R(x_t, y_t, v_t)\|_{y_t}^2 - \frac{2}{d_{t+1}} \langle v_t - \mathcal{P}_{y^*(x_t)}^{y_t} v^*(x_t), \nabla_v R(x_t, y_t, v_t) \rangle_{y_t}. \tag{27}
\end{aligned}$$

对于 $-\langle v_t - \mathcal{P}_{y^*(x_t)}^{y_t} v^*(x_t), \nabla_v R(x_t, y_t, v_t) \rangle_{y_t}$ ，根据 $\nabla_v R(x_t, y_t, v_t)$ 的定义，有：

$$\begin{aligned}
&-\langle v_t - \mathcal{P}_{y^*(x_t)}^{y_t} v^*(x_t), \nabla_v R(x_t, y_t, v_t) \rangle_{y_t} \\
&= -\langle v_t - \mathcal{P}_{y^*(x_t)}^{y_t} v^*(x_t), \nabla_v R(x_t, y_t, v_t) - \nabla_v R(x_t, y_t, \mathcal{P}_{y^*(x_t)}^{y_t} v^*(x_t)) \rangle_{y_t} \\
&\quad - \langle v_t - \mathcal{P}_{y^*(x_t)}^{y_t} v^*(x_t), \nabla_v R(x_t, y_t, \mathcal{P}_{y^*(x_t)}^{y_t} v^*(x_t)) - \mathcal{P}_{y^*(x_t)}^{y_t} \nabla_v R(x_t, y^*(x_t), v^*(x_t)) \rangle_{y_t} \\
&\leq -\frac{1}{\mu + L_g} \|\nabla_v R(x_t, y_t, v_t) - \nabla_v R(x_t, y_t, \mathcal{P}_{y^*(x_t)}^{y_t} v^*(x_t))\|_{y_t}^2 - \frac{\mu L_g}{\mu + L_g} \|v_t - \mathcal{P}_{y^*(x_t)}^{y_t} v^*(x_t)\|_{y_t}^2 \\
&\quad + \frac{\mu + L_g}{2\mu L_g} \|\nabla_v R(x_t, y_t, \mathcal{P}_{y^*(x_t)}^{y_t} v^*(x_t)) - \mathcal{P}_{y^*(x_t)}^{y_t} \nabla_v R(x_t, y^*(x_t), v^*(x_t))\|_{y_t}^2 + \frac{\mu L_g}{2(\mu + L_g)} \|v_t - \mathcal{P}_{y^*(x_t)}^{y_t} v^*(x_t)\|_{y_t}^2
\end{aligned}$$

$$\begin{aligned}
&\leq -\frac{1}{2(\mu + L_g)} \|\nabla_v R(x_t, y_t, v_t)\|_{y_t}^2 + \frac{1}{\mu + L_g} \|\nabla_v R(x_t, y_t, \mathcal{P}_{y^*(x_t)}^{y_t} v^*(x_t))\|_{y_t}^2 \\
&\quad + \frac{\mu + L_g}{2\mu L_g} \|\nabla_v R(x_t, y_t, \mathcal{P}_{y^*(x_t)}^{y_t} v^*(x_t)) - \mathcal{P}_{y^*(x_t)}^{y_t} \nabla_v R(x_t, y^*(x_t), v^*(x_t))\|_{y_t}^2 - \frac{\mu L_g}{2(\mu + L_g)} \|v_t - \mathcal{P}_{y^*(x_t)}^{y_t} v^*(x_t)\|_{y_t}^2 \\
&= -\frac{1}{2(\mu + L_g)} \|\nabla_v R(x_t, y_t, v_t)\|_{y_t}^2 - \frac{\mu L_g}{2(\mu + L_g)} \|v_t - \mathcal{P}_{y^*(x_t)}^{y_t} v^*(x_t)\|_{y_t}^2 \\
&\quad + \left(\frac{1}{\mu + L_g} + \frac{\mu + L_g}{2\mu L_g} \right) \|\nabla_v R(x_t, y_t, \mathcal{P}_{y^*(x_t)}^{y_t} v^*(x_t)) - \mathcal{P}_{y^*(x_t)}^{y_t} \nabla_v R(x_t, y^*(x_t), v^*(x_t))\|_{y_t}^2 \\
&\leq -\frac{1}{2(\mu + L_g)} \|\nabla_v R(x_t, y_t, v_t)\|_{y_t}^2 - \frac{\mu L_g}{2(\mu + L_g)} \|v_t - \mathcal{P}_{y^*(x_t)}^{y_t} v^*(x_t)\|_{y_t}^2 \\
&\quad + \left(\frac{1}{\mu + L_g} + \frac{\mu + L_g}{2\mu L_g} \right) \left(\frac{\rho l_f}{\mu} + L_f \right)^2 d^2(y_t, y^*(x_t)), \tag{28}
\end{aligned}$$

其中第一个不等式由 [9, 引理 3.11] 导出, 第二个不等式由于 $-\|a - b\|^2 \leq -\frac{1}{2}\|a\|^2 + \|b\|^2$ 成立, 第二个等式由于 $\nabla_v R(x_t, y^*(x_t), v^*(x_t)) = 0$, 最后一个不等式由 $\nabla_v R$ 的定义及假设 3.1、3.2、3.3 导出。

结合 (27), 可得:

$$\begin{aligned}
&\|v_{t+1} - \mathcal{P}_{y^*(x_t)}^{y_t} v^*(x_t)\|_{y_t}^2 \\
&\leq \left(1 - \frac{\mu L_g}{(\mu + L_g)d_{t+1}} \right) \|v_t - \mathcal{P}_{y^*(x_t)}^{y_t} v^*(x_t)\|_{y_t}^2 - \frac{1}{2(\mu + L_g)d_{t+1}} \|\nabla_v R(x_t, y_t, v_t)\|_{y_t}^2 \\
&\quad + \left(\frac{2}{\mu + L_g} + \frac{\mu + L_g}{\mu L_g} \right) \left(\frac{\rho l_f}{\mu} + L_f \right)^2 \frac{1}{d_{t+1}} d^2(y_t, y^*(x_t)), \tag{29}
\end{aligned}$$

其中第二个不等式由 $d_{t+1} \geq c_{t+1} \geq C_c \geq 2(\mu + L_g)$ 导出。

结合 (26), 有:

$$\begin{aligned}
&\|v_{t+1} - \mathcal{P}_{y^*(x_{t+1})}^{y_t} v^*(x_{t+1})\|_{y_t}^2 \\
&\leq (1 + \hat{\lambda}_{t+1}) \left(1 - \frac{\mu L_g}{(\mu + L_g)d_{t+1}} \right) \|v_t - \mathcal{P}_{y^*(x_t)}^{y_t} v^*(x_t)\|_{y_t}^2 - (1 + \hat{\lambda}_{t+1}) \frac{1}{2(\mu + L_g)d_{t+1}} \|\nabla_v R(x_t, y_t, v_t)\|_{y_t}^2 \\
&\quad + (1 + \hat{\lambda}_{t+1}) \left(\frac{2}{\mu + L_g} + \frac{\mu + L_g}{\mu L_g} \right) \left(\frac{\rho l_f}{\mu} + L_f \right)^2 \frac{1}{d_{t+1}} d^2(y_t, y^*(x_t)) + \left(1 + \frac{1}{\hat{\lambda}_{t+1}} \right) \|v^*(x_t) - \mathcal{P}_{y^*(x_{t+1})}^{y^*(x_t)} v^*(x_{t+1})\|_{y^*(x_t)}^2. \tag{30}
\end{aligned}$$

由此可得:

$$\begin{aligned}
&(1 + \hat{\lambda}_{t+1}) \frac{1}{2(\mu + L_g)d_{t+1}} \|\nabla_v R(x_t, y_t, v_t)\|_{y_t}^2 \\
&\leq (1 + \hat{\lambda}_{t+1}) \left(1 - \frac{\mu L_g}{(\mu + L_g)d_{t+1}} \right) \|v_t - \mathcal{P}_{y^*(x_t)}^{y_t} v^*(x_t)\|_{y_t}^2 - \|v_{t+1} - \mathcal{P}_{y^*(x_{t+1})}^{y_t} v^*(x_{t+1})\|_{y_t}^2 \\
&\quad + (1 + \hat{\lambda}_{t+1}) \left(\frac{2}{\mu + L_g} + \frac{\mu + L_g}{\mu L_g} \right) \left(\frac{\rho l_f}{\mu} + L_f \right)^2 \frac{1}{d_{t+1}} d^2(y_t, y^*(x_t)) + \left(1 + \frac{1}{\hat{\lambda}_{t+1}} \right) \|v^*(x_t) - \mathcal{P}_{y^*(x_{t+1})}^{y^*(x_t)} v^*(x_{t+1})\|_{y^*(x_t)}^2. \tag{31}
\end{aligned}$$

若设 $\hat{\lambda}_{t+1} := \frac{\mu L_g}{(\mu + L_g)d_{t+1}}$, 根据 (15) 有 $d_{t+1} \geq c_{t+1} \geq C_c \geq \frac{\mu L_g}{\mu + L_g}$, 则 $\hat{\lambda}_{t+1} \leq 1$ 。于是有:

$$\begin{aligned}
&\frac{\|\nabla_v R(x_t, y_t, v_t)\|_{y_t}^2}{d_{t+1}} \\
&\leq 2(\mu + L_g) (\|v_t - \mathcal{P}_{y^*(x_t)}^{y_t} v^*(x_t)\|_{y_t}^2 - \|v_{t+1} - \mathcal{P}_{y^*(x_{t+1})}^{y_t} v^*(x_{t+1})\|_{y_t}^2)
\end{aligned}$$

$$+ \left(\frac{4(\mu + L_g)^2}{\mu L_g} + 8 \right) \left(\frac{\rho l_f}{\mu} + L_f \right)^2 \frac{d^2(y_t, y^*(x_t))}{d_{t+1}} + \frac{4(\mu + L_g)^2 L_v^2 d_{t+1}}{\mu L_g} d^2(x_t, x_{t+1}), \quad (32)$$

其中第二个不等式由 $(1 + \hat{\lambda}_{t+1}) \leq 2$ 和引理 E.3.3 导出, 第三个不等式由 $d_{t+1} \geq C_c \geq \frac{\mu L_g}{\mu + L_g}$ 以及 $\frac{2(\mu + L_g)\mu L_g}{\mu L_g} \leq \frac{2(\mu + L_g)^2 d_{t+1}}{\mu L_g}$ 导出。

将 (32) 从 n_1 到 t 求和:

$$\begin{aligned} & \sum_{i=n_1}^t \frac{\|\nabla_v R(x_i, y_i, v_i)\|_{y_i}^2}{d_{i+1}} \\ & \leq 2(\mu + L_g) \|v_{n_1-1} - \mathcal{P}_{y^*(x_{n_1-1})}^{y_{n_1-1}} v^*(x_{n_1-1})\|_{y_{n_1-1}}^2 + \frac{4(\mu + L_g)^2 L_v^2}{\mu L_g} \sum_{i=n_1-1}^t \frac{\|\widehat{\mathcal{G}}F(x_i, y_i, v_i)\|_{y_i}^2}{a_{i+1}^2 d_{i+1}} \\ & \quad + \left(\frac{4(\mu + L_g)^2}{\mu L_g} + 8 \right) \left(\frac{\rho l_f}{\mu} + L_f \right)^2 \frac{1}{\mu^2} \sum_{i=n_1-1}^t \frac{\|\mathcal{G}_y g(x_i, y_i)\|_{y_i}^2}{b_{i+1}} \\ & \leq \frac{4(\mu + L_g)}{\mu^2} \|\nabla_v R(x_{n_1-1}, y_{n_1-1}, v_{n_1-1})\|_{y_{n_1-1}}^2 + \frac{4(\mu + L_g)}{\mu^2} \left(\frac{\rho l_f}{\mu} + L_f \right)^2 d^2(y_{n_1-1}, y^*(x_{n_1-1})) \\ & \quad + \frac{4(\mu + L_g)^2 L_v^2}{\mu L_g} \sum_{i=n_1-1}^t \frac{\|\widehat{\mathcal{G}}F(x_i, y_i, v_i)\|_{y_i}^2}{a_{i+1}^2 d_{i+1}} + \left(\frac{4(\mu + L_g)^2}{\mu L_g} + 8 \right) \left(\frac{\rho l_f}{\mu} + L_f \right)^2 \frac{1}{\mu^2} \sum_{i=n_1-1}^t \frac{\|\mathcal{G}_y g(x_i, y_i)\|_{y_i}^2}{b_{i+1}}, \end{aligned} \quad (33)$$

其中第三个不等式由 $d_{i+1} \geq b_{i+1}$ 导出, 第四个不等式由 g 的测地线强凸性导出, 第五个不等式由 R 的强凸性导出, 最后一个不等式由 $\nabla_v R(x_{n_1-1}, y^*(x_{n_1-1}), v^*(x_{n_1-1})) = 0$ 导出。

对于 (33) 中的 $d^2(y_{n_1-1}, y^*(x_{n_1-1}))$ 项。如果 $b_{n_1} \leq C_b$, 根据 g 的测地线强凸性和 b_{n_1} 的定义:

$$d^2(y_{n_1-1}, y^*(x_{n_1-1})) \leq \frac{1}{\mu^2} \|\mathcal{G}_y g(x_{n_1-1}, y_{n_1-1})\|_{y_{n_1-1}}^2 \leq \frac{C_b^2}{\mu^2}. \quad (34)$$

如果 $b_{n_1} > C_b$, 根据命题 F.1 可知 k_1 存在且 $n_1 > k_1$ 。令 (23) 中的 $\bar{\lambda}_{n_1-1} := \frac{2\mu L_g}{b_{n_1-1}(\mu + L_g)}$, 有:

$$\begin{aligned} & d^2(y_{n_1-1}, y^*(x_{n_1-1})) \\ & \leq d^2(y_{k_1-1}, y^*(x_{k_1-1})) + \frac{(\mu + L_g)L_y^2}{\mu L_g d_0} \sum_{i=k_1-1}^{n_1-2} \frac{\|\widehat{\mathcal{G}}F(x_i, y_i, v_i)\|_{x_i}^2}{a_{i+1}^2} \\ & \leq \frac{C_b^2}{\mu^2} + \frac{(\mu + L_g)L_y^2}{\mu L_g d_0} \sum_{i=k_1-1}^{n_1-2} \frac{\|\widehat{\mathcal{G}}F(x_i, y_i, v_i)\|_{x_i}^2}{a_{i+1}^2}, \end{aligned} \quad (35)$$

其中最后一步由 $b_{k_1} \leq C_b$ 和 (34) 导出。由此综合可得:

$$d^2(y_{n_1-1}, y^*(x_{n_1-1})) \leq \frac{C_b^2}{\mu^2} + \frac{(\mu + L_g)L_y^2}{\mu L_g d_0} \sum_{i=k_1-1}^{n_1-2} \frac{\|\widehat{\mathcal{G}}F(x_i, y_i, v_i)\|_{x_i}^2}{a_{i+1}^2}. \quad (36)$$

结合 (33), 并由于 $\|\nabla_v R(x_{n_1-1}, y_{n_1-1}, v_{n_1-1})\|_{y_{n_1-1}}^2 \leq c_{n_1}^2 \leq C_c^2$, 证毕。 $\square$

引理 G.4. 假设假设 3.1、3.2 和 3.3 成立。则在算法 1 中, 对于所有 $t \geq 0$ 有:

$$\|v_t\|_{y_t} \leq \frac{\sqrt{2}}{\mu} d_{t+1} + \frac{\sqrt{2}l_f}{\mu} \sqrt{t}.$$

证明. 根据 R 的 μ -强凸性:

$$\sum_{i=1}^t \mu^2 \|v_i\|_{y_i}^2 \leq \sum_{i=1}^t 2 \|\nabla_v R(x_i, y_i, v_i)\|_{y_i}^2 + \sum_{i=1}^t 2 \|\mathcal{G}_y f(x_i, y_i)\|_{y_i}^2 \leq 2c_{t+1}^2 + 2tl_f^2, \quad (37)$$

其中最后一个不等式由 c_t 的定义和 f 的 Lipschitz 连续性导出。由于 $\|v_t\|_{y_t}^2 \leq \sum_{i=1}^t \|v_i\|_{y_i}^2$ 且 $c_{t+1} \leq d_{t+1}$, 证毕。 $\square$

G.3 步长的上界

引理 G.5. 假设假设 3.1、3.2 和 3.3 成立。如果命题 F.1 中的 k_1 不存在, 则对于所有 $t < T$, 均有 $b_{t+1} \leq C_b$ 。如果命题 F.1 中的 k_1 存在, 则有:

$$\begin{cases} b_{t+1} \leq C_b, & t < k_1; \\ b_{t+1} \leq \left(C_b + \frac{(\mu + L_g)C_b^2}{\zeta\mu^2} + \frac{(\mu + L_g)^2 L_y^2}{\zeta\mu L_g d_0} \right) + \frac{(\mu + L_g)^2 L_y^2}{\zeta\mu L_g C_b} \sum_{i=k_1}^t \frac{\|\widehat{\mathcal{G}}F(x_i, y_i, v_i)\|_{y_i}^2}{a_{i+1}^2}, & t \geq k_1. \end{cases}$$

证明. 若命题 F.1 中的 k_1 不存在, 则显然对于所有 $t < T$, $b_{t+1} \leq C_b$ 成立。

若命题 F.1 中的 k_1 存在, 根据 b_{t+1} 的定义, 有 $\|\mathcal{G}_y g(x_t, y_t)\|^2 = b_{t+1}^2 - b_t^2$ 。于是:

$$\begin{aligned} b_{t+1} &= b_t + \frac{\|\mathcal{G}_y g(x_t, y_t)\|_{y_t}^2}{b_{t+1} + b_t} \leq b_t + \frac{\|\mathcal{G}_y g(x_t, y_t)\|_{y_t}^2}{b_{t+1}} \\ &\leq b_{k_1} + \sum_{i=k_1}^t \frac{\|\mathcal{G}_y g(x_i, y_i)\|_{y_i}^2}{b_{i+1}} \\ &\leq \left(C_b + \frac{(\mu + L_g)C_b^2}{\zeta\mu^2} + \frac{(\mu + L_g)^2 L_y^2}{\zeta\mu L_g d_0} \right) + \frac{(\mu + L_g)^2 L_y^2}{\zeta\mu L_g C_b} \sum_{i=k_1}^t \frac{\|\widehat{\mathcal{G}}F(x_i, y_i, v_i)\|_{y_i}^2}{a_{i+1}^2}, \end{aligned} \quad (38)$$

其中最后一个不等式由引理 G.2 得出。证毕。 $\square$

引理 G.6. 假设假设 3.1、3.2 和 3.3 成立。记 $\bar{k} := \min\{k_1, n_1\}$ 。如果命题 F.1 中的 k_1 和 n_1 均不存在, 则对于所有 $t \leq T$, 有 $d_t \leq C_d$ 。

如果命题 F.1 中的 k_1 和 n_1 中至少有一个存在, 则 d_t 的上界为:

$$\begin{cases} d_t \leq C_d, & t \leq \bar{k}; \\ d_t \leq \alpha_1 \log(t) + \beta_1, & t > \bar{k}, \end{cases}$$

其中 α_1 和 β_1 定义如下:

$$\alpha_1 := 6\alpha_0, \quad \beta_1 := 4\alpha_0 \log \left(1 + \frac{L_g \bar{\beta} + l_f}{L_g \bar{\alpha}} \right) + 4\alpha_0 \log(L_g \bar{\alpha}) + 4\alpha_0 + 2\beta_0, \quad (39)$$

且相关常数定义为:

$$\begin{aligned} \bar{\alpha} &:= \frac{\sqrt{2}}{\mu}, \quad \bar{\beta} := \frac{\sqrt{2}l_f}{\mu}, \\ \alpha_0 &:= \left(\left(\frac{4(\mu + L_g)^2}{\mu L_g} + 8 \right) \left(\frac{\rho l_f}{\mu} + L_f \right)^2 \frac{1}{\mu^2} + 1 \right) \frac{(\mu + L_g)^2 L_y^2}{\zeta\mu L_g C_b} \\ &\quad + \frac{4(\mu + L_g)(\mu + L_g) L_y^2}{\mu^3 L_g d_0} \left(\frac{\rho l_f}{\mu} + L_f \right)^2 + \frac{4(\mu + L_g)^2 L_v^2}{\mu L_g c_0}, \end{aligned}$$

$$\begin{aligned}\beta_0 := & C_b + C_c + \frac{4(\mu + L_g)C_b^2}{\mu^4} \left(\frac{\rho l_f}{\mu} + L_f \right)^2 + \frac{4(\mu + L_g)C_c^2}{\mu^2} + \left(\frac{4(\mu + L_g)^2}{\mu L_g} + 8 \right) \left(\frac{\rho l_f}{\mu} + L_f \right)^2 \frac{1}{\mu^2} \left(\frac{C_b^2}{b_0} - b_0 \right) \\ & + \left[\left(\frac{4(\mu + L_g)^2}{\mu L_g} + 8 \right) \left(\frac{\rho l_f}{\mu} + L_f \right)^2 \frac{1}{\mu^2} + 1 \right] \left(\frac{(\mu + L_g)C_b^2}{\zeta \mu^2} + \frac{(\mu + L_g)^2 L_y^2}{\zeta \mu L_g d_0} \right).\end{aligned}\quad (40)$$

证明. 根据 b_t 和 c_t 的定义, 有:

$$\begin{aligned}0 & \leq \min\{b_{t+1}^2, c_{t+1}^2\} - \min\{b_t^2, c_t^2\} \\ & = (b_{t+1}^2 + c_{t+1}^2) - (b_t^2 + c_t^2) - (d_{t+1}^2 - d_t^2),\end{aligned}$$

其中最后一个等式由 d_t 的定义得出. 进一步有:

$$d_{t+1}^2 - d_t^2 \leq (b_{t+1}^2 - b_t^2) + (c_{t+1}^2 - c_t^2) = \|\mathcal{G}_y g(x_t, y_t)\|_{y_t}^2 + \|\nabla_v R(x_t, y_t, v_t)\|_{y_t}^2.$$

类似于 (38) 的推导, 可得:

$$d_{t+1} \leq d_t + \frac{\|\mathcal{G}_y g(x_t, y_t)\|_{y_t}^2}{b_{t+1}} + \frac{\|\nabla_v R(x_t, y_t, v_t)\|_{y_t}^2}{d_{t+1}}. \quad (41)$$

根据命题 F.1 中 k_1 和 n_1 的定义, 若两者均不存在, 则:

$$d_t = \max\{b_t, c_t\} \leq \max\{C_b, C_c\} \leq C_d. \quad (42)$$

如果 k_1 存在但 n_1 不存在, 由于 $c_t \leq C_c$, 由 (38) 可知:

$$d_{t+1} \leq b_{t+1} + c_{t+1} \leq C_b + \sum_{i=k_1}^t \frac{\|\mathcal{G}_y g(x_i, y_i)\|_{y_i}^2}{b_{i+1}} + C_c. \quad (43)$$

如果 n_1 存在但 k_1 不存在, 由 (41) 及 b_t 的定义可得:

$$d_{t+1} \leq b_{t+1} + C_c + \sum_{i=n_1}^t \frac{\|\nabla_v R(x_i, y_i, v_i)\|_{y_i}^2}{d_{i+1}} \leq C_b + C_c + \sum_{i=n_1}^t \frac{\|\nabla_v R(x_i, y_i, v_i)\|_{y_i}^2}{d_{i+1}}. \quad (44)$$

如果 k_1 和 n_1 均存在, 结合上述推导有:

$$d_{t+1} \leq C_b + C_c + \sum_{i=k_1}^t \frac{\|\mathcal{G}_y g(x_i, y_i)\|_{y_i}^2}{b_{i+1}} + \sum_{i=n_1}^t \frac{\|\nabla_v R(x_i, y_i, v_i)\|_{y_i}^2}{d_{i+1}}. \quad (45)$$

在所有情况中, (45) 给出的上界最大. 我们只需给出该式中 d_t 的上界即可.

利用引理 G.4 以及 $\log$ 求和性质 (引理 E.1), 通过一系列放缩, 可以得到:

$$\sum_{i=t_0}^t \frac{\|\widehat{\mathcal{G}}F(x_i, y_i, v_i)\|_{x_i}^2}{a_{i+1}^2} \leq 3 \log(t+1) + 2 \log(L_g \bar{\alpha} d_{t+1} + L_g \bar{\beta} + l_f) + 1.$$

最后, 结合 d_{t+1} 的放缩性 (如 $\log d_{t+1} \leq d_{t+1}$), 整理各项常数可得:

$$d_{t+1} \leq \alpha_1 \log(t+1) + \beta_1. \quad (46)$$

证毕. $\square$

引理 G.7. 假设假设 3.1、3.2 和 3.3 成立。则对于所有 $0 \leq t_0 < t$ ，我们有

$$\begin{aligned} \sum_{i=t_0}^t \frac{\|\widehat{\mathcal{G}}F(x_i, y_i, v_i)\|_{x_i}^2}{a_{i+1}^2} &\leq 5 \log(t+1) + \gamma_2, \\ \sum_{i=t_0}^t \frac{\|\mathcal{G}_y g(x_i, y_i)\|_{y_i}^2}{b_{i+1}} &\leq \alpha_2 \log(t+1) + \beta_2, \\ \sum_{i=t_0}^t \frac{\|\nabla_v R(x_i, y_i, v_i)\|_{y_i}^2}{d_{i+1}} &\leq \alpha_3 \log(t+1) + \beta_3, \end{aligned}$$

其中 $\gamma_2, \alpha_2, \beta_2, \alpha_3, \beta_3$ 为

$$\begin{aligned} \gamma_2 &:= 2 \log(L_g \bar{\alpha} \alpha_1 + L_g \bar{\alpha} \beta_1 + L_g \bar{\beta} + l_f) + 1, \\ \alpha_2 &:= \frac{5(\mu + L_g)^2 L_y^2}{\mu L_g C_b}, \\ \beta_2 &:= \frac{(\mu + L_g)^2 L_y^2}{\zeta \mu L_g C_b} \gamma_2 + \left(\frac{C_b^2}{b_0} - b_0 + \frac{(\mu + L_g) C_b^2}{\zeta \mu^2} + \frac{(\mu + L_g)^2 L_y^2}{\zeta \mu L_g d_0} \right), \\ \alpha_3 &:= \frac{20(\mu + L_g)(\mu + L_g) L_y^2}{\mu^3 L_g d_0} \left(\frac{\rho l_f}{\mu} + L_f \right)^2 + \frac{20(\mu + L_g)^2 L_v^2}{\mu L_g C_c} + \left(\frac{4(\mu + L_g)^2}{\mu L_g} + 8 \right) \left(\frac{\rho l_f}{\mu} + L_f \right)^2 \frac{\alpha_2}{\mu^2}, \\ \beta_3 &:= \frac{C_c^2}{c_0} - c_0 + \frac{4(\mu + L_g) C_b^2}{\mu^4} \left(\frac{\rho l_f}{\mu} + L_f \right)^2 + \frac{4(\mu + L_g) C_c^2}{\mu^2} + \left(\frac{4(\mu + L_g)^2}{\mu L_g} + 8 \right) \left(\frac{\rho l_f}{\mu} + L_f \right)^2 \frac{\beta_2}{\mu^2} \\ &\quad + \left(\frac{4(\mu + L_g)(\mu + L_g) L_y^2}{\mu^3 L_g d_0} \left(\frac{\rho l_f}{\mu} + L_f \right)^2 + \frac{4(\mu + L_g)^2 L_v^2}{\mu L_g C_c} \right) \gamma_2. \end{aligned} \quad (47)$$

证明. 根据文献 [51]，我们有

$$\begin{aligned} &\sum_{i=t_0}^t \frac{\|\widehat{\mathcal{G}}F(x_i, y_i, v_i)\|_{x_i}^2}{a_{i+1}^2} \\ &\leq 3 \log(t+1) + 2 \log(L_g \bar{\alpha} d_{t+1} + L_g \bar{\beta} + l_f) + 1 \\ &\leq 3 \log(t+1) + 2 \log(L_g \bar{\alpha} \alpha_1 \log(t+1) + L_g \bar{\alpha} \beta_1 + L_g \bar{\beta} + l_f) + 1 \\ &\leq 3 \log(t+1) + 2 \log(L_g \bar{\alpha} \alpha_1(t+1) + L_g \bar{\alpha} \beta_1 + L_g \bar{\beta} + l_f) + 1 \\ &\leq 3 \log(t+1) + 2 \log((L_g \bar{\alpha} \alpha_1 + L_g \bar{\alpha} \beta_1 + L_g \bar{\beta} + l_f)(t+1)) + 1 \\ &\leq 5 \log(t+1) + 2 \log(L_g \bar{\alpha} \alpha_1 + L_g \bar{\alpha} \beta_1 + L_g \bar{\beta} + l_f) + 1 \\ &= 5 \log(t+1) + \gamma_2, \end{aligned} \quad (48)$$

其中第二个不等式由 (46) 得出，第三个不等式由 $\log(x) \leq x$ 得出，最后一个不等式由 (47) 中 γ_2 的定义得出。

随后，我们提供 $\sum_{i=t_0}^t \frac{\|\mathcal{G}_y g(x_i, y_i)\|_{y_i}^2}{b_{i+1}}$ 的上界。若 $b_{t+1} \leq C_b$ ，我们有

$$\sum_{i=t_0}^t \frac{\|\mathcal{G}_y g(x_i, y_i)\|_{y_i}^2}{b_{i+1}} \leq \frac{\sum_{i=t_0}^t \|\mathcal{G}_y g(x_i, y_i)\|_{y_i}^2}{b_0} \leq \frac{b_{t+1}^2 - b_{t_0}^2}{b_0} \leq \frac{C_b^2 - b_0^2}{b_0} = \frac{C_b^2}{b_0} - b_0 \leq \beta_2,$$

其中最后一个不等式由 (47) 中 β_2 的定义得出。

若 $b_{t+1} > C_b$ ，则命题 F.1 中的 k_1 存在且 $k_1 \leq t$ 。那么，根据 (??)，我们有

$$\sum_{i=t_0}^t \frac{\|\mathcal{G}_y g(x_i, y_i)\|_{y_i}^2}{b_{i+1}}$$

$$\begin{aligned}
&\leq \left(\frac{C_b^2}{b_0} - b_0 + \frac{(\mu + L_g)C_b^2}{\zeta\mu^2} + \frac{(\mu + L_g)^2L_y^2}{\zeta\mu L_g d_0} \right) + \frac{(\mu + L_g)^2L_y^2}{\mu L_g C_b} \sum_{i=k_1}^t \frac{\|\widehat{\mathcal{G}}F(x_i, y_i, v_i)\|_{x_i}^2}{a_{i+1}^2} \\
&\leq \frac{5(\mu + L_g)^2L_y^2}{\mu L_g C_b} \log(t+1) + \frac{(\mu + L_g)^2L_y^2}{\mu L_g C_b} \gamma_2 + \left(\frac{C_b^2}{b_0} - b_0 + \frac{(\mu + L_g)C_b^2}{\mu^2} + \frac{(\mu + L_g)^2L_y^2}{\mu L_g d_0} \right) \\
&= \alpha_2 \log(t+1) + \beta_2,
\end{aligned} \tag{49}$$

其中第二个不等式由 (48) 得出, 最后一个等式由 (47) 中 β_2 的定义得出。

最后, 我们提供 $\sum \frac{\|\nabla_v R(x_i, y_i, v_i)\|_{y_i}^2}{d_{i+1}}$ 的上界。若 $c_{t+1} \leq C_c$, 我们有

$$\sum_{i=t_0}^t \frac{\|\nabla_v R(x_i, y_i, v_i)\|_{y_i}^2}{d_{i+1}} \leq \frac{\sum_{i=t_0}^t \|\nabla_v R(x_i, y_i, v_i)\|_{y_i}^2}{d_0} \leq \frac{C_c^2 - c_0^2}{c_0} \leq \frac{C_c^2}{c_0} - c_0 \leq \beta_3,$$

其中最后一个不等式由 (47) 中 β_3 的定义得出。

若 $c_{t+1} > C_c$, 则命题 F.1 中的 n_1 存在且 $n_1 \leq t$ 。那么, 我们有

$$\begin{aligned}
&\sum_{i=t_0}^t \frac{\|\nabla_v R(x_i, y_i, v_i)\|_{y_i}^2}{d_{i+1}} \\
&\leq \sum_{i=t_0}^{n_1-1} \frac{\|\nabla_v R(x_i, y_i, v_i)\|_{y_i}^2}{d_{i+1}} + \sum_{i=n_1}^t \frac{\|\nabla_v R(x_i, y_i, v_i)\|_{y_i}^2}{d_{i+1}} \\
&\leq \frac{C_c^2 - c_0^2}{c_0} + \frac{4(\mu + L_g)C_c^2}{\mu^2} + \frac{4(\mu + L_g)C_b^2}{\mu^4} \left(\frac{\rho l_f}{\mu} + L_f \right)^2 \\
&\quad + \frac{4(\mu + L_g)(\mu + L_g)L_y^2}{\mu^3 L_g d_0} \left(\frac{\rho l_f}{\mu} + L_f \right)^2 \sum_{i=k_1-1}^{n_1-2} \frac{\|\widehat{\mathcal{G}}F(x_i, y_i, v_i)\|_{x_i}^2}{a_{i+1}^2} \\
&\quad + \frac{4(\mu + L_g)^2L_v^2}{\mu L_g C_c} \sum_{i=n_1-1}^t \frac{\|\widehat{\mathcal{G}}F(x_i, y_i, v_i)\|_{x_i}^2}{a_{i+1}^2} \\
&\quad + \left(\frac{4(\mu + L_g)^2}{\mu L_g} + 8 \right) \left(\frac{\rho l_f}{\mu} + L_f \right)^2 \frac{1}{\mu^2} \sum_{i=n_1-1}^t \frac{\|\mathcal{G}_y g(x_i, y_i)\|_{y_i}^2}{b_{i+1}} \\
&\leq \frac{C_c^2}{c_0} - c_0 + \frac{4(\mu + L_g)C_c^2}{\mu^2} + \frac{4(\mu + L_g)C_b^2}{\mu^4} \left(\frac{\rho l_f}{\mu} + L_f \right)^2 \\
&\quad + \left(\frac{4(\mu + L_g)(\mu + L_g)L_y^2}{\mu^3 L_g d_0} \left(\frac{\rho l_f}{\mu} + L_f \right)^2 + \frac{4(\mu + L_g)^2L_v^2}{\mu L_g C_c} \right) (5 \log(t+1) + \gamma_2) \\
&\quad + \left(\frac{4(\mu + L_g)^2}{\mu L_g} + 8 \right) \left(\frac{\rho l_f}{\mu} + L_f \right)^2 \frac{1}{\mu^2} (\alpha_2 \log(t+1) + \beta_2) \\
&= \alpha_3 \log(t+1) + \beta_3,
\end{aligned} \tag{50}$$

其中第二个不等式由 c_t 的定义、 $C_c \geq c_0$ 以及引理 G.3 得出, 第三个不等式由 (48) 和 (49) 得出, 最后一个等式由 (47) 中 α_3 和 β_3 的定义得出。证毕。 $\square$

引理 G.8. 假设假设 3.1、3.2、3.3 和 3.4 成立。若命题 F.1 中的 t_1 不存在, 则对于任何 $t \leq T$, 我们有 $a_t \leq C_a$ 。

若 t_1 存在, 我们有

$$\begin{cases} a_t \leq C_a, & t \leq t_1; \\ a_t \leq C_a + \left(\alpha_4 \log(t) + \beta_4 + 4(F(x_0) - F^*) \right) d_t, & t \geq t_1, \end{cases}$$

其中 α_4, β_4 为

$$\begin{aligned}\alpha_4 &:= \frac{2\bar{L}^2\alpha_2}{\mu^2 C_a} \left[1 + \frac{2}{\mu^2} \left(\frac{\rho l_f}{\mu} + L_f\right)^2\right] + \frac{4\bar{L}^2\alpha_3}{\mu^2 C_a} \\ \beta_4 &:= \frac{2\bar{L}^2\beta_2}{\mu^2 C_a} \left[1 + \frac{2}{\mu^2} \left(\frac{\rho l_f}{\mu} + L_f\right)^2\right] + \frac{4\bar{L}^2\beta_3}{\mu^2 C_a} + \frac{2L_F}{d_0^2} \frac{C_a^2}{a_0^2}.\end{aligned}\quad (51)$$

证明. 若命题 F.1 中的 t_1 不存在, 则对于任何 $t < T$, 恒有 $a_{t+1} \leq C_a$.

若命题 F.1 中的 t_1 存在, 根据引理 G.1, 对于所有 $i \geq t_1$, 有

$$\begin{aligned}F(x_{i+1}) &\leq F(x_i) - \frac{1}{2a_{i+1}d_{i+1}} \|\mathcal{G}F(x_i)\|_{x_i}^2 - \frac{1}{4a_{i+1}d_{i+1}} \|\widehat{\mathcal{G}}F(x_i, y_i, v_i)\|_{x_i}^2 \\ &\quad + \frac{\bar{L}^2}{2\mu^2} \left[1 + \frac{2}{\mu^2} \left(\frac{\rho l_f}{\mu} + L_f\right)^2\right] \frac{\|\mathcal{G}_y g(x_i, y_i)\|_{y_i}^2}{a_{i+1}d_{i+1}} + \frac{\bar{L}^2}{\mu^2} \frac{\|\nabla_v R(x_i, y_i, v_i)\|_{y_i}^2}{a_{i+1}d_{i+1}}.\end{aligned}$$

那么, 我们有

$$\begin{aligned}\frac{\|\widehat{\mathcal{G}}F(x_i, y_i, v_i)\|_{x_i}^2}{a_{i+1}d_{i+1}} &\leq 4(F(x_i) - F(x_{i+1})) \\ &\quad + \frac{2\bar{L}^2}{\mu^2} \left[1 + \frac{2}{\mu^2} \left(\frac{\rho l_f}{\mu} + L_f\right)^2\right] \frac{\|\mathcal{G}_y g(x_i, y_i)\|_{y_i}^2}{a_{i+1}d_{i+1}} + \frac{4\bar{L}^2}{\mu^2} \frac{\|\nabla_v R(x_i, y_i, v_i)\|_{y_i}^2}{a_{i+1}d_{i+1}}.\end{aligned}$$

从 t_1 到 t 求和, 可得

$$\begin{aligned}&\sum_{i=t_1}^t \frac{\|\widehat{\mathcal{G}}F(x_i, y_i, v_i)\|_{x_i}^2}{a_{i+1}d_{i+1}} \\ &\leq 4(F(x_{t_1}) - F^*) + \frac{2\bar{L}^2}{\mu^2 C_a} \left[1 + \frac{2}{\mu^2} \left(\frac{\rho l_f}{\mu} + L_f\right)^2\right] \sum_{i=t_1}^t \frac{\|\mathcal{G}_y g(x_i, y_i)\|_{y_i}^2}{d_{i+1}} + \frac{4\bar{L}^2}{\mu^2 C_a} \sum_{i=t_1}^t \frac{\|\nabla_v R(x_i, y_i, v_i)\|_{y_i}^2}{d_{i+1}},\end{aligned}\quad (52)$$

其中最后一个不等式由 $a_{t_1+1} \geq C_a$ 得出.

根据 (17), 有

$$\begin{aligned}F(x_{t_1}) &\leq F(x_0) + \frac{L_F}{2} \sum_{i=0}^{t_1-1} \frac{\|\widehat{\mathcal{G}}F(x_i, y_i, v_i)\|_{x_i}^2}{a_{i+1}^2 d_{i+1}^2} \\ &\quad + \frac{\bar{L}^2}{2\mu^2} \left[1 + \frac{2}{\mu^2} \left(\frac{\rho l_f}{\mu} + L_f\right)^2\right] \sum_{i=0}^{t_1-1} \frac{\|\mathcal{G}_y g(x_i, y_i)\|_{y_i}^2}{a_{i+1}d_{i+1}} + \frac{\bar{L}^2}{\mu^2} \sum_{i=0}^{t_1-1} \frac{\|\nabla_v R(x_i, y_i, v_i)\|_{y_i}^2}{a_{i+1}d_{i+1}}.\end{aligned}\quad (53)$$

结合 (52), 我们有

$$\begin{aligned}&\sum_{i=t_1}^t \frac{\|\widehat{\mathcal{G}}F(x_i, y_i, v_i)\|_{x_i}^2}{a_{i+1}d_{i+1}} \\ &\leq 4(F(x_0) - F^*) + \frac{2\bar{L}^2}{\mu^2 C_a} \left[1 + \frac{2}{\mu^2} \left(\frac{\rho l_f}{\mu} + L_f\right)^2\right] \sum_{i=0}^t \frac{\|\mathcal{G}_y g(x_i, y_i)\|_{y_i}^2}{d_{i+1}} \\ &\quad + \frac{4\bar{L}^2}{\mu^2 C_a} \sum_{i=0}^t \frac{\|\nabla_v R(x_i, y_i, v_i)\|_{y_i}^2}{d_{i+1}} + \frac{2L_F}{d_0^2} \frac{C_a^2}{a_0^2} \\ &\leq 4(F(x_0) - F^*) + \frac{2\bar{L}^2}{\mu^2 C_a} \left[1 + \frac{2}{\mu^2} \left(\frac{\rho l_f}{\mu} + L_f\right)^2\right] \sum_{i=0}^t \frac{\|\mathcal{G}_y g(x_i, y_i)\|_{y_i}^2}{b_{i+1}}\end{aligned}$$

$$\begin{aligned}
& + \frac{4\bar{L}^2}{\mu^2 C_a} \sum_{i=0}^t \frac{\|\nabla_v R(x_i, y_i, v_i)\|_{y_i}^2}{d_{i+1}} + \frac{2L_F}{d_0^2} \frac{C_a^2}{a_0^2} \\
& \leq 4(F(x_0) - F^*) + \frac{2\bar{L}^2}{\mu^2 C_a} \left[1 + \frac{2}{\mu^2} \left(\frac{\rho l_f}{\mu} + L_f \right)^2 \right] (\alpha_2 \log(t+1) + \beta_2) \\
& \quad + \frac{4\bar{L}^2}{\mu^2 C_a} (\alpha_3 \log(t+1) + \beta_3) + \frac{2L_F}{d_0^2} \frac{C_a^2}{a_0^2} \\
& = \alpha_4 \log(t+1) + \beta_4 + 4(F(x_0) - F^*), \tag{54}
\end{aligned}$$

其中第一个不等式由 d_t 和 α_t 的定义以及 $\sum_{i=0}^{t_1-1} \|\widehat{\mathcal{G}}F(x_i, y_i, v_i)\|_{x_i}^2 \leq C_a^2$ 得出, 第二个不等式由 $d_{i+1} \geq b_{i+1}$ 得出, 第三个不等式由 (49) 和 (50) 得出, 最后一个等式由 (51) 中 α_4 和 β_4 的定义得出。

根据 d_i 的单调性, 我们有

$$\sum_{i=t_1}^t \frac{\|\widehat{\mathcal{G}}F(x_i, y_i, v_i)\|_{x_i}^2}{a_{i+1}} \leq (\alpha_4 \log(t+1) + \beta_4 + 4(F(x_0) - F^*)) d_{t+1}.$$

那么, 类似于 (38), 有

$$\begin{aligned}
a_{t+1} & \leq a_{t_1} + \sum_{i=t_1}^t \frac{\|\widehat{\mathcal{G}}F(x_i, y_i, v_i)\|_{x_i}^2}{a_{i+1}} \\
& \leq C_a + (\alpha_4 \log(t+1) + \beta_4 + 4(F(x_0) - F^*)) d_{t+1}. \tag{55}
\end{aligned}$$

证毕。 $\square$

G.4 定理 3.1 的证明

若命题 F.1 中的 t_1 不存在, 则对于所有 $t < T$, 有 $a_{t+1} \leq C_a$ 成立。那么, 根据引理 G.1, 我们有

$$\begin{aligned}
\frac{\|\mathcal{G}F(x_t)\|_{x_t}^2}{a_{t+1}d_{t+1}} & \leq 2(F(x_t) - F(x_{t+1})) + \frac{L_F}{a_{t+1}^2 d_{t+1}^2} \|\widehat{\mathcal{G}}F(x_t, y_t, v_t)\|_{x_t}^2 \\
& \quad + \frac{\bar{L}^2}{\mu^2} \left[1 + \frac{2}{\mu^2} \left(\frac{\rho l_f}{\mu} + L_f \right)^2 \right] \frac{\|\mathcal{G}_y g(x_t, y_t)\|_{y_t}^2}{a_{t+1}d_{t+1}} + \frac{2\bar{L}^2}{\mu^2} \frac{\|\nabla_v R(x_t, y_t, v_t)\|_{y_t}^2}{a_{t+1}d_{t+1}},
\end{aligned}$$

进而, 我们有

$$\begin{aligned}
\frac{1}{T} \sum_{t=0}^{T-1} \frac{\|\mathcal{G}F(x_t)\|_{x_t}^2}{a_{t+1}d_{t+1}} & \leq \frac{2}{T} (F(x_0) - F(x_T)) + \frac{1}{T} \frac{L_F}{a_0^2 d_0^2} \sum_{t=0}^{T-1} \|\widehat{\mathcal{G}}F(x_t, y_t, v_t)\|_{x_t}^2 \\
& \quad + \frac{1}{T} \frac{\bar{L}^2}{\mu^2} \left[1 + \frac{2}{\mu^2} \left(\frac{\rho l_f}{\mu} + L_f \right)^2 \right] \sum_{t=0}^{T-1} \frac{\|\mathcal{G}_y g(x_t, y_t)\|_{y_t}^2}{a_{t+1}d_{t+1}} \\
& \quad + \frac{1}{T} \frac{2\bar{L}^2}{\mu^2} \sum_{t=0}^{T-1} \frac{\|\nabla_v R(x_t, y_t, v_t)\|_{y_t}^2}{a_{t+1}d_{t+1}} \\
& \leq \frac{2}{T} (F(x_0) - F(x_T)) + \frac{L_F C_a^2}{T a_0^2 d_0^2} \\
& \quad + \frac{\bar{L}^2}{T \mu^2 a_0} \left[1 + \frac{2}{\mu^2} \left(\frac{\rho l_f}{\mu} + L_f \right)^2 \right] \sum_{t=0}^{T-1} \frac{\|\mathcal{G}_y g(x_t, y_t)\|_{y_t}^2}{b_{t+1}} \\
& \quad + \frac{2\bar{L}^2}{T \mu^2 a_0} \sum_{t=0}^{T-1} \frac{\|\nabla_v R(x_t, y_t, v_t)\|_{y_t}^2}{d_{t+1}}
\end{aligned}$$

$$\begin{aligned}
&\leq \frac{2}{T}(F(x_0) - F^*) + \frac{L_F C_a^2}{T a_0^2 d_0^2} \\
&\quad + \frac{\bar{L}^2}{\mu^2 a_0 T} \left[1 + \frac{2}{\mu^2} \left(\frac{\rho l_f}{\mu} + L_f \right)^2 \right] (\alpha_2 \log(T) + \beta_2) \\
&\quad + \frac{2\bar{L}^2}{\mu^2 a_0 T} (\alpha_3 \log(T) + \beta_3) \\
&= \frac{1}{2T} (\alpha_4 \log(T) + \beta_4 + 4(F(x_0) - F^*)), \tag{56}
\end{aligned}$$

其中第二个不等式由于 $\sum_{t=0}^{T-1} \|\widehat{\mathcal{G}}F(x_t, y_t, v_t)\|_{x_t}^2 \leq a_T^2 \leq C_a^2$ 成立，第三个不等式根据引理 G.7 得出，最后一个等式根据 (51) 中 α_4 和 β_4 的定义得出。

若 t_1 存在，根据引理 G.1，对于所有 $t < t_1$ ，我们有

$$\begin{aligned}
\frac{\|\mathcal{G}F(x_t)\|_{x_t}^2}{a_{t+1}d_{t+1}} &\leq 2(F(x_t) - F(x_{t+1})) + \frac{L_F}{a_{t+1}^2 d_{t+1}^2} \|\widehat{\mathcal{G}}F(x_t, y_t, v_t)\|_{x_t}^2 \\
&\quad + \frac{\bar{L}^2}{\mu^2} \left[1 + \frac{2}{\mu^2} \left(\frac{\rho l_f}{\mu} + L_f \right)^2 \right] \frac{\|\mathcal{G}_y g(x_t, y_t)\|_{y_t}^2}{a_{t+1}d_{t+1}} + \frac{2\bar{L}^2}{\mu^2} \frac{\|\nabla_v R(x_t, y_t, v_t)\|_{y_t}^2}{a_{t+1}d_{t+1}}.
\end{aligned}$$

此外，对于所有 $t \geq t_1$ ，根据引理 G.1，我们有

$$\begin{aligned}
\frac{\|\mathcal{G}F(x_t)\|_{x_t}^2}{a_{t+1}d_{t+1}} &\leq 2(F(x_t) - F(x_{t+1})) \\
&\quad + \frac{\bar{L}^2}{\mu^2} \left[1 + \frac{2}{\mu^2} \left(\frac{\rho l_f}{\mu} + L_f \right)^2 \right] \frac{\|\mathcal{G}_y g(x_t, y_t)\|_{y_t}^2}{a_{t+1}d_{t+1}} + \frac{2\bar{L}^2}{\mu^2} \frac{\|\nabla_v R(x_t, y_t, v_t)\|_{y_t}^2}{a_{t+1}d_{t+1}}.
\end{aligned}$$

那么，我们有

$$\begin{aligned}
\frac{1}{T} \sum_{t=0}^{T-1} \frac{\|\mathcal{G}F(x_t)\|_{x_t}^2}{a_{t+1}d_{t+1}} &= \frac{1}{T} \sum_{t=0}^{t_1-1} \frac{\|\mathcal{G}F(x_t)\|_{x_t}^2}{a_{t+1}d_{t+1}} + \frac{1}{T} \sum_{t=t_1}^{T-1} \frac{\|\mathcal{G}F(x_t)\|_{x_t}^2}{a_{t+1}d_{t+1}} \\
&\leq \frac{2}{T}(F(x_0) - F(x_{t_1})) + \frac{1}{T} \frac{L_F}{a_0^2 d_0^2} \sum_{t=0}^{t_1-1} \|\widehat{\mathcal{G}}F(x_t, y_t, v_t)\|_{x_t}^2 \\
&\quad + \frac{1}{T} \frac{\bar{L}^2}{\mu^2} \left[1 + \frac{2}{\mu^2} \left(\frac{\rho l_f}{\mu} + L_f \right)^2 \right] \sum_{t=0}^{t_1-1} \frac{\|\mathcal{G}_y g(x_t, y_t)\|_{y_t}^2}{a_{t+1}d_{t+1}} \\
&\quad + \frac{1}{T} \frac{2\bar{L}^2}{\mu^2} \sum_{t=0}^{t_1-1} \frac{\|\nabla_v R(x_t, y_t, v_t)\|_{y_t}^2}{a_{t+1}d_{t+1}} \\
&\quad + \frac{2}{T}(F(x_{t_1}) - F(x_T)) \\
&\quad + \frac{1}{T} \frac{\bar{L}^2}{\mu^2} \left[1 + \frac{2}{\mu^2} \left(\frac{\rho l_f}{\mu} + L_f \right)^2 \right] \sum_{t=t_1}^{T-1} \frac{\|\mathcal{G}_y g(x_t, y_t)\|_{y_t}^2}{a_{t+1}d_{t+1}} \\
&\quad + \frac{1}{T} \frac{2\bar{L}^2}{\mu^2} \sum_{t=t_1}^{T-1} \frac{\|\nabla_v R(x_t, y_t, v_t)\|_{y_t}^2}{a_{t+1}d_{t+1}} \\
&\leq \frac{2}{T}(F(x_0) - F^*) + \frac{1}{T} \frac{L_F}{a_0^2 d_0^2} \sum_{t=0}^{t_1-1} \|\widehat{\mathcal{G}}F(x_t, y_t, v_t)\|_{x_t}^2 \\
&\quad + \frac{1}{T} \frac{\bar{L}^2}{\mu^2} \left[1 + \frac{2}{\mu^2} \left(\frac{\rho l_f}{\mu} + L_f \right)^2 \right] \sum_{t=0}^{T-1} \frac{\|\mathcal{G}_y g(x_t, y_t)\|_{y_t}^2}{a_{t+1}d_{t+1}}
\end{aligned}$$

$$\begin{aligned}
& + \frac{1}{T} \frac{2\bar{L}^2}{\mu^2} \sum_{t=0}^{T-1} \frac{\|\nabla_v R(x_t, y_t, v_t)\|_{y_t}^2}{a_{t+1}d_{t+1}} \\
& \leq \frac{2}{T} (F(x_0) - F^*) + \frac{L_F}{Ta_0^2d_0^2} \sum_{t=0}^{t_1-1} \|\hat{\mathcal{G}}F(x_t, y_t, v_t)\|_{x_t}^2 \\
& \quad + \frac{\bar{L}^2}{T\mu^2a_0} \left[1 + \frac{2}{\mu^2} \left(\frac{\rho l_f}{\mu} + L_f \right)^2 \right] \sum_{t=0}^{T-1} \frac{\|\mathcal{G}_y g(x_t, y_t)\|_{y_t}^2}{d_{t+1}} \\
& \quad + \frac{2\bar{L}^2}{T\mu^2a_0} \sum_{t=0}^{T-1} \frac{\|\nabla_v R(x_t, y_t, v_t)\|_{y_t}^2}{d_{t+1}} \\
& \leq \frac{2}{T} (F(x_0) - F^*) + \frac{L_F C_a^2}{Ta_0^2d_0^2} \\
& \quad + \frac{\bar{L}^2}{T\mu^2a_0} \left[1 + \frac{2}{\mu^2} \left(\frac{\rho l_f}{\mu} + L_f \right)^2 \right] (\alpha_2 \log(T) + \beta_2) \\
& \quad + \frac{2\bar{L}^2}{T\mu^2a_0} (\alpha_3 \log(T) + \beta_3) \\
& = \frac{1}{2T} (\alpha_4 \log(T) + \beta_4 + 4(F(x_0) - F^*)), \tag{57}
\end{aligned}$$

其中第三个不等式由于 $a_{t+1} \geq a_0$ 成立，最后一个不等式根据 (51) 中 α_4 和 β_4 的定义得出。

因此，我们有

$$\begin{aligned}
& \frac{1}{T} \sum_{t=0}^{T-1} \|\mathcal{G}F(x_t)\|_{x_t}^2 \\
& \leq \frac{1}{2T} (\alpha_4 \log(T) + \beta_4 + 4(F(x_0) - F^*)) a_T d_T \\
& \stackrel{(a)}{\leq} \frac{1}{2T} \left[(\alpha_4 \log(T) + \beta_4 + 4(F(x_0) - F^*))^2 d_T^2 + C_a (\alpha_4 \log(T) + \beta_4 + 4(F(x_0) - F^*)) d_T \right] \\
& \stackrel{(b)}{\leq} \frac{1}{2T} \left[(\alpha_4 \log(T) + \beta_4 + 4(F(x_0) - F^*))^2 (\alpha_1 \log(T) + \beta_1)^2 \right. \\
& \quad \left. + C_a (\alpha_4 \log(T) + \beta_4 + 4(F(x_0) - F^*)) (\alpha_1 \log(T) + \beta_1) \right] \\
& = \mathcal{O}\left(\frac{\log^4(T)}{T}\right),
\end{aligned}$$

其中第一个不等式根据引理 G.8 中 α_T 的上界得出，第三个不等式根据引理 G.6 得出。证明完成。

G.5 推论 3.1 的证明

回顾定理 3.1，我们有

$$\frac{1}{T} \sum_{t=0}^{T-1} \|\mathcal{G}F(x_t)\|_{x_t}^2 \leq \mathcal{O}\left(\frac{\log^4(T)}{T}\right). \tag{58}$$

这立即表明，为了达到 ϵ -准确的驻点，我们有以下复杂度结果：

$$G_f = G_g = \tilde{\mathcal{O}}\left(\frac{1}{\epsilon}\right), \quad JV_g = HV_g = \tilde{\mathcal{O}}\left(\frac{1}{\epsilon}\right).$$

H 第 3.5 节的证明

本节提供了第 3.5 节中结果的证明。为了保持一致性，我们保留了第 3.3 节中引入的符号，例如 C_a , C_b , C_c 等。

首先，与命题 F.1 类似，我们先给出一个关于步长 a_1 , b_t 和 c_t 的引理。

命题 H.1. 假设假设 3.1, 3.2, 3.3, 3.5 和 3.6 成立。记 $\{T, K, N\}$ 为 $\{x, y, v\}$ 的迭代次数。给定任意常数 $C_a \geq a_0$, $C_b \geq b_0$, $C_c \geq c_0$, 则我们有：

AdaRHD-S:

- (1) 要么对于任何 $t \leq T$ 都有 $a_t \leq C_a$, 要么存在 $t_1 \leq T$ 使得 $a_{t_1} \leq C_a$ 且 $a_{t_1+1} > C_a$;
- (2) 要么对于任何 $t \leq K$ 都有 $b_t \leq C_b$, 要么存在 $k_1 \leq K$ 使得 $b_{k_1} \leq C_b$ 且 $b_{k_1+1} > C_b$;
- (3) 要么对于任何 $t \leq N$ 都有 $c_t \leq C_c$, 要么存在 $n_1 \leq N$ 使得 $c_{n_1} \leq C_c$ 且 $c_{n_1+1} > C_c$ 。

H.1 命题 D.1 的证明

H.1.1 单步更新目标函数的改进

与参考文献 [51] 中的引理类似，我们有以下引理。

引理 H.1. 假设假设 3.1, 3.2, 3.3, 3.5 和 3.6 成立。则我们有

$$F(x_{t+1}) \leq F(x_t) - \frac{1}{2a_{t+1}} \|\mathcal{G}F(x_t)\|_{x_t}^2 - \frac{1}{2a_{t+1}} \left(1 - \frac{\bar{L}_F}{a_{t+1}}\right) \|\hat{\mathcal{G}}F(x_t, y_t^{K_t}, v_t^{N_t})\|_{x_t}^2 + \frac{\epsilon_{y,v}}{2a_{t+1}}$$

此外，如果命题 H.1 中的 t_1 存在，则对于 $t \geq t_1$, 我们有

$$F(x_{t+1}) \leq F(x_t) - \frac{1}{2a_{t+1}} \|\mathcal{G}F(x_t)\|_{x_t}^2 - \frac{1}{4a_{t+1}} \|\hat{\mathcal{G}}F(x_t, y_t^{K_t}, v_t^{N_t})\|_{x_t}^2 + \frac{\epsilon_{y,v}}{2a_{t+1}} \quad (59)$$

其中 $\bar{L}_F = (L_F c_u + 2c_R(l_f + l_f L_g/\mu))$, $\epsilon_{y,v} = \frac{\bar{L}^2}{\mu^2}(\epsilon_y + \epsilon_v)$, $\bar{L} := \max\{\sqrt{2}(L_g(1 + \frac{L_f}{\mu} + \frac{l_f \rho}{\mu^2}) + \frac{l_f \rho}{\mu}), \sqrt{2}L_g\}$, 且 c_u, c_R 在假设 3.6 中定义。

证明. 根据引理 E.2, 我们有

$$\begin{aligned} F(x_{t+1}) &\leq F(x_t) + \langle \mathcal{G}F(x_t), \text{Exp}_{x_t}^{-1}(x_{t+1}) \rangle_{x_t} + \frac{L_F}{2} d(x_{t+1}, x_t)^2 \\ &= F(x_t) + \langle \mathcal{G}F(x_t), \text{Exp}_{x_t}^{-1}(x_{t+1}) - \text{Retr}_{x_t}^{-1}(x_{t+1}) \rangle_{x_t} + \langle \mathcal{G}F(x_t), \text{Retr}_{x_t}^{-1}(x_{t+1}) \rangle_{x_t} + \frac{L_F}{2} d(x_{t+1}, x_t)^2 \\ &\leq F(x_t) + c_R \left(l_f + l_f \frac{L_g}{\mu} \right) \|\text{Retr}_{x_t}^{-1}(x_{t+1})\|_{x_t}^2 - \frac{1}{a_{t+1}} \left\langle \mathcal{G}F(x_t), \hat{\mathcal{G}}F(x_t, y_t^{K_t}, v_t^{N_t}) \right\rangle_{x_t} \\ &\quad + \frac{L_F c_u}{2a_{t+1}^2} \|\hat{\mathcal{G}}F(x_t, y_t^{K_t}, v_t^{N_t})\|_{x_t}^2 \\ &\leq F(x_t) + \frac{c_R(l_f + l_f L_g/\mu)}{a_{t+1}^2} \|\hat{\mathcal{G}}F(x_t, y_t^{K_t}, v_t^{N_t})\|_{x_t}^2 + \frac{L_F c_u}{2a_{t+1}^2} \|\hat{\mathcal{G}}F(x_t, y_t^{K_t}, v_t^{N_t})\|_{x_t}^2 \\ &\quad - \frac{1}{a_{t+1}} \|\mathcal{G}F(x_t)\|_{x_t}^2 - \frac{1}{a_{t+1}} \|\hat{\mathcal{G}}F(x_t, y_t^{K_t}, v_t^{N_t})\|_{x_t}^2 + \frac{1}{a_{t+1}} \|\mathcal{G}F(x_t) - \hat{\mathcal{G}}F(x_t, y_t^{K_t}, v_t^{N_t})\|_{x_t}^2 \\ &= F(x_t) - \frac{1}{2a_{t+1}} \|\mathcal{G}F(x_t)\|_{x_t}^2 - \frac{1}{2a_{t+1}} \left(1 - \frac{L_F c_u + 2c_R(l_f + l_f L_g/\mu)}{a_{t+1}}\right) \|\hat{\mathcal{G}}F(x_t, y_t^{K_t}, v_t^{N_t})\|_{x_t}^2 \\ &\quad + \frac{1}{2a_{t+1}} \|\mathcal{G}F(x_t) - \hat{\mathcal{G}}F(x_t, y_t^{K_t}, v_t^{N_t})\|_{x_t}^2 \\ &\leq F(x_t) - \frac{1}{2a_{t+1}} \|\mathcal{G}F(x_t)\|_{x_t}^2 - \frac{1}{2a_{t+1}} \left(1 - \frac{L_F c_u + 2c_R(l_f + l_f L_g/\mu)}{a_{t+1}}\right) \|\hat{\mathcal{G}}F(x_t, y_t^{K_t}, v_t^{N_t})\|_{x_t}^2 + \frac{\epsilon_{y,v}}{2a_{t+1}}, \quad (60) \end{aligned}$$

其中第二个不等式使用了引理 E.2 (2) 和假设 3.6。

如果命题 H.1 中的 t_1 存在，那么对于 $t \geq t_1$, 我们有 $a_{t+1} > C_a \geq 2(L_F c_u + 2c_R(l_f + l_f L_g/\mu))$ 。(59) 的预期结果可由 (60) 得出。证明完毕。 $\square$

我们在给出步长 a_t 的上界时, 为参数 a_t 定义一个阈值。

$$C_a := \max\{2\bar{L}_F, a_0\}$$

其中 $\bar{L}_F = (L_F c_u + 2c_R(l_f + l_f L_g/\mu))$ 定义在引理 H.1 中。

我们有以下步长 a_t 的上界。

引理 H.2. 假设假设 3.1, 3.2, 3.3, 3.4, 3.5 和 3.6 成立。如果命题 H.1 中的 t_1 不存在, 则对于任何 $t \leq T$ 都有 $a_t \leq C_a$ 。

如果存在命题 H.1 中描述的 $t_1 \leq T$, 则我们有

$$\begin{cases} a_t \leq C_a, & t \leq t_1; \\ a_t \leq C_a + 2F_0 + \frac{2t\epsilon_{y,v}}{a_0}, & t \geq t_1, \end{cases}$$

其中我们定义

$$F_0 := 2(F(x_0) - F^*) + \frac{\bar{L}_F C_a^2}{a_0^2} \quad (61)$$

与参考文献 [51] 中的引理类似, 只需要将 L_F 替换为 $\bar{L}_F$ 。此处省略。

在证明命题 D.1 之前, 与引理 F.1 类似, 我们给出了用收缩映射 (retraction mapping) 替换指数映射时的如下技术引理。

引理 H.3. 假设假设 3.1, 3.2, 3.3, 3.5 和 3.6 成立。则我们有

$$d^2(y_t^{k+1}, y^*(x_t)) \leq (1 + \frac{1}{b_{k+1}^2} \bar{\zeta} L_g^2 - \frac{\mu}{b_{k+1}}) d^2(y_t^k, y^*(x_t)),$$

其中 $\bar{\zeta} := \zeta c_u + 2\bar{D}c_R$ 。

证明. 根据引理 B.1, 由 $\text{Retr}_{y_t^k}^{-1} y_t^{k+1} = -\frac{1}{b_{k+1}} \mathcal{G}g(x_t, y_t^k)$ 的定义, 我们有

$$\begin{aligned} d^2(y_t^{k+1}, y^*(x_t)) &\leq d^2(y_t^k, y^*(x_t)) + \zeta d^2(y_t^k, y_t^{k+1}) - 2 \left\langle \text{Exp}_{y_t^k}^{-1} y_t^{k+1}, \text{Exp}_{y_t^k}^{-1} y^*(x_t) \right\rangle_{y_t^k} \\ &\leq d^2(y_t^k, y^*(x_t)) + \frac{1}{b_{k+1}^2} \zeta c_u \|\mathcal{G}_y g(x_t, y_t^k)\|_{y_t^k}^2 - 2 \left\langle \text{Exp}_{y_t^k}^{-1} y_t^{k+1} - \text{Retr}_{y_t^k}^{-1} y_t^{k+1}, \text{Exp}_{y_t^k}^{-1} y^*(x_t) \right\rangle_{y_t^k} \\ &\quad + 2 \frac{1}{b_{k+1}} \left\langle \mathcal{G}_y g(x_t, y_t^k), \text{Exp}_{y_t^k}^{-1} y^*(x_t) \right\rangle_{y_t^k} \\ &\leq d^2(y_t^k, y^*(x_t)) + \frac{1}{b_{k+1}^2} \zeta c_u \|\mathcal{G}_y g(x_t, y_t^k)\|_{y_t^k}^2 + 2 \frac{1}{b_{k+1}} \left\langle \mathcal{G}_y g(x_t, y_t^k), \text{Exp}_{y_t^k}^{-1} y^*(x_t) \right\rangle_{y_t^k} \\ &\quad + 2\bar{D} \|\text{Exp}_{y_t^k}^{-1} y_t^{k+1} - \text{Retr}_{y_t^k}^{-1} y_t^{k+1}\|_{y_t^k} \\ &\leq d^2(y_t^k, y^*(x_t)) + \frac{1}{b_{k+1}^2} (\zeta c_u + 2\bar{D}c_R) \|\mathcal{G}_y g(x_t, y_t^k)\|_{y_t^k}^2 + 2 \frac{1}{b_{k+1}} \left\langle \mathcal{G}_y g(x_t, y_t^k), \text{Exp}_{y_t^k}^{-1} y^*(x_t) \right\rangle_{y_t^k} \\ &\leq \left(1 + \frac{1}{b_{k+1}^2} (\zeta c_u + 2\bar{D}c_R) L_g^2 - \frac{\mu}{b_{k+1}} \right) d^2(y_t^k, y^*(x_t)), \end{aligned} \quad (62)$$

其中第二个不等式由假设 3.6 和

$$\left\langle \text{Retr}_{y_t^k}^{-1} y_t^{k+1}, \text{Exp}_{y_t^k}^{-1} y^*(x_t) \right\rangle_{y_t^k} = -\frac{1}{b_{k+1}} \left\langle \mathcal{G}_y g(x_t, y_t^k), \text{Exp}_{y_t^k}^{-1} y^*(x_t) \right\rangle_{y_t^k}$$

得出, 第三个不等式通过采用 [5, Proposition 10.22] 由假设 3.5 得出, 即:

$$\|\text{Exp}_{y_t^k}^{-1} y^*(x_t)\| = d(y_t^k, y^*(x_t)) \leq \bar{D},$$

第四个不等式由假设 3.6 得出。 □

我们定义步长 b_k 和 c_n 的如下阈值。

$$C_b := \max\{2\bar{\zeta}L_g\frac{L_g}{\mu}, b_0\}, \quad C_c := \max\{L_g, c_0\},$$

其中 $\bar{\zeta} = \zeta c_u + 2\bar{D}c_R$ 在引理 H.3 中定义。

命题 D.1 的证明

证明. 对于 AdaRHD-GD, 记

$$\bar{K} := \frac{\log(C_b^2/b_0^2)}{\log(1 + \epsilon_y/C_b^2)} + \frac{1}{(\mu/\bar{b} - \bar{\zeta}L_g^2/\bar{b}^2)} \log\left(\frac{\tilde{b}}{\epsilon_y}\right), \quad (63)$$

以及

$$\bar{N}_{gd} := \frac{\log(C_c^2/c_0^2)}{\log(1 + \epsilon_v/C_c^2)} + \frac{\bar{c}}{\mu} \log\left(\frac{\tilde{c}}{\epsilon_v}\right),$$

其中 $\tilde{b} := \max\{\frac{L_g(\bar{b}-C_b)}{2}, 1\}$, $\tilde{c} := \max\{L_g(\bar{c}-C_c), 1\}$, $\bar{b} := C_b + 2L_g\left(\frac{2\epsilon_y}{\mu^2} + \frac{2L_g^2C_f^2}{\mu^2a_0^2} + 2\bar{\zeta}\log\left(\frac{C_b}{b_0}\right) + \bar{\zeta}\right)$, 其中 $C_f = \left(\frac{2L_g^2\epsilon_v}{\mu^2} + \frac{4L_g^2l_f^2}{\mu^2} + 4l_f^2\right)^{\frac{1}{2}}$ 定义在引理 E.5 中, 且 $\bar{c} := C_c + L_g\left(\frac{2\epsilon_y}{\mu^2} + \frac{8l_f^2}{\mu^2} + 2\log\left(\frac{C_c}{c_0}\right) + 1\right)$ 。

对于 AdaRHD-CG, 记

$$\bar{N}_{cg} := \frac{1}{2}\log\left(\frac{4L_g^3l_f^2}{\mu^3\epsilon_v}\right)/\log\left(\frac{\sqrt{L_g/\mu}+1}{\sqrt{L_g/\mu}-1}\right)$$

首先, 我们证明对于所有 $0 \leq t \leq T$ 都有 $K_t \leq \bar{K}$ 。

如果命题 H.1 中的 k_1 不存在, 我们有 $b_{K_t} \leq C_b$ 。根据 [66, Lemma 2], 有 $K_t \leq \frac{\log(C_b^2/b_0^2)}{\log(1+\epsilon_y/C_b^2)}$ 成立。如果 $K_t > \frac{\log(C_b^2/b_0^2)}{\log(1+\epsilon_y/C_b^2)}$, 由于对于所有 $k < K_t$ 都有 $\|\mathcal{G}_y g(x_t, y_t^k)\|_{x_t}^2 \geq \epsilon_y$ 和 $b_k \leq C_b$ 成立, 我们有

$$\begin{aligned} b_{K_t}^2 &= b_{K_t-1}^2 + \|\mathcal{G}_y g(x_t, y_t^{K_t-1})\|_{y_t^{K_t-1}}^2 = b_{K_t-1}^2 \left(1 + \frac{\|\mathcal{G}_y g(x_t, y_t^{K_t-1})\|_{y_t^{K_t-1}}^2}{b_{K_t-1}^2}\right) \\ &\geq b_0^2 \prod_{k=0}^{K_t-1} \left(1 + \frac{\|\mathcal{G}_y g(x_t, y_t^k)\|_{y_t^k}^2}{b_k^2}\right) \geq b_0^2 \left(1 + \frac{\epsilon_y}{C_b^2}\right)^{K_t} > b_0^2 \left((1 + \frac{\epsilon_y}{C_b^2})^{1/\log(1+\epsilon_y/C_b^2)}\right)^{\log(C_b^2/b_0^2)} = C_b^2 \end{aligned} \quad (64)$$

这与 $b_{K_t} \leq C_b$ 矛盾。

如果命题 H.1 中的 k_1 存在, 我们有 $b_{k_1} \leq C_b$ 且 $b_{k_1+1} > C_b$ 。我们首先证明 $k_1 \leq \frac{\log(C_b^2/b_0^2)}{\log(1+\epsilon_y/C_b^2)}$ 。如果 $k_1 > \frac{\log(C_b^2/b_0^2)}{\log(1+\epsilon_y/C_b^2)}$, 与 (64) 类似, 我们有

$$b_{k_1}^2 \geq b_0^2 \left(1 + \frac{\epsilon_y}{C_b^2}\right)^{k_1} > C_b^2,$$

这与 $b_{k_1} \leq C_b$ 的设定矛盾。

根据引理 H.3, 我们有

$$\begin{aligned} d^2(y_t^{k_1}, y^*(x_t)) &\leq d^2(y_t^{k_1-1}, y^*(x_t)) + \zeta d^2(y_t^{k_1-1}, y_t^{k_1}) - 2 \left\langle \text{Exp}_{y_t^{k_1-1}}^{-1} y_t^{k_1}, \text{Exp}_{y_t^{k_1-1}}^{-1} y^*(x_t) \right\rangle_{y_t^{k_1-1}} \\ &\stackrel{(a)}{\leq} d^2(y_t^{k_1-1}, y^*(x_t)) + \zeta c_u \left\| \frac{\mathcal{G}_y g(x_t, y_t^{k_1-1})}{b_{k_1}} \right\|_{y_t^{k_1-1}}^2 - 2 \left\langle \text{Exp}_{y_t^{k_1-1}}^{-1} y_t^{k_1} - \text{Retr}_{y_t^{k_1-1}}^{-1} y_t^{k_1}, \text{Exp}_{y_t^{k_1-1}}^{-1} y^*(x_t) \right\rangle_{y_t^{k_1-1}} \end{aligned}$$

$$\begin{aligned}
& + 2 \frac{1}{b_{k_1}} \left\langle \mathcal{G}_y g(x_t, y_t^{k_1-1}), \text{Exp}_{y_t^{k_1-1}}^{-1} y^*(x_t) \right\rangle_{y_t^{k_1-1}} \\
& \stackrel{(b)}{\leq} d^2(y_t^{k_1-1}, y^*(x_t)) + \zeta c_u \left\| \frac{\mathcal{G}_y g(x_t, y_t^{k_1-1})}{b_{k_1}} \right\|_{y_t^{k_1-1}}^2 + 2 \frac{1}{b_{k_1}} \left\langle \mathcal{G}_y g(x_t, y_t^{k_1-1}), \text{Exp}_{y_t^{k_1-1}}^{-1} y^*(x_t) \right\rangle_{y_t^{k_1-1}} \\
& \quad + 2\bar{D} \|\text{Exp}_{y_t^{k_1-1}}^{-1} y_t^{k_1} - \text{Retr}_{y_t^{k_1-1}}^{-1} y_t^{k_1}\|_{y_t^{k_1-1}} \\
& \stackrel{(c)}{\leq} d^2(y_t^{k_1-1}, y^*(x_t)) + (\zeta c_u + 2\bar{D} c_R) \left\| \frac{\mathcal{G}_y g(x_t, y_t^{k_1-1})}{b_{k_1}} \right\|_{y_t^{k_1-1}}^2 + 2 \frac{1}{b_{k_1}} \left\langle \mathcal{G}_y g(x_t, y_t^{k_1-1}), \text{Exp}_{y_t^{k_1-1}}^{-1} y^*(x_t) \right\rangle_{y_t^{k_1-1}} \\
& \stackrel{(d)}{\leq} d^2(y_t^{k_1-1}, y^*(x_t)) + \bar{\zeta} \frac{\|\mathcal{G}_y g(x_t, y_t^{k_1-1})\|_{y_t^{k_1-1}}^2}{b_{k_1}^2} \leq d^2(y_t^0, y^*(x_t)) + \bar{\zeta} \sum_{p=0}^{k_1-1} \frac{\|\mathcal{G}_y g(x_t, y_t^p)\|_{y_t^p}^2}{b_{k+1}^2} \\
& \stackrel{(e)}{\leq} d^2(y_{t-1}^{K-1}, y^*(x_t)) + \bar{\zeta} \sum_{p=0}^{k_1-1} \frac{\|\mathcal{G}_y g(x_t, y_t^p)\|_{y_t^p}^2 / b_0^2}{\sum_{k=0}^p \|\mathcal{G}_y g(x_t, y_t^k)\|_{y_t^k}^2 / b_0^2} \\
& \stackrel{(f)}{\leq} 2d^2(y_{t-1}^{K-1}, y^*(x_{t-1})) + 2d^2(y^*(x_{t-1}), y^*(x_t)) + \bar{\zeta} \log \left(\sum_{p=0}^{k_1-1} \frac{\|\mathcal{G}_y g(x_t, y_t^p)\|_{y_t^p}^2}{b_0^2} \right) + \bar{\zeta} \\
& \stackrel{(g)}{\leq} \frac{2\epsilon_y}{\mu^2} + \frac{2L_g^2 \|\widehat{G}F(x_{t-1}, y_{t-1}^{K-1}, v_{t-1}^{N-1})\|_{y_{t-1}^{K-1}}^2}{\mu^2 a_t^2} + \bar{\zeta} \log \left(\sum_{p=0}^{k_1-1} \frac{\|\mathcal{G}_y g(x_t, y_t^p)\|_{y_t^p}^2}{b_0^2} \right) + \bar{\zeta} \\
& \stackrel{(h)}{\leq} \frac{2\epsilon_y}{\mu^2} + \frac{2L_g^2 C_f^2}{\mu^2 a_0^2} + 2\bar{\zeta} \log \left(\frac{C_b}{b_0} \right) + \bar{\zeta}, \tag{65}
\end{aligned}$$

其中 (a) 由 (62) 的第二个不等式得出, (b) 由假设 3.5 得出, (c) 由假设 3.6 得出, (d) 由 g 的凸性得出, (e) 由 y_t^0 的热启动得出, (f) 由引理 E.1 得出, (g) 由引理 E.2 (1) 和 E.4 得出, (h) 由引理 E.5 和 $b_{k_1} \leq C_b$ 得出。

对于所有 $K > k_1$, 根据引理 H.3, 我们有

$$\begin{aligned}
d^2(y_t^K, y^*(x_t)) & \leq \left(1 - \left(\frac{\mu}{b_k} - \bar{\zeta} \frac{L_g^2}{b_k^2} \right) \right) d^2(y_t^{K-1}, y^*(x_t)) \leq e^{-\left(\frac{\mu}{b_k} - \bar{\zeta} \frac{L_g^2}{b_k^2} \right)(K-k_1)} d^2(y_t^{k_1}, y^*(x_t)) \\
& \leq e^{-\left(\frac{\mu}{b_k} - \bar{\zeta} \frac{L_g^2}{b_k^2} \right)(K-k_1)} \left(\frac{2\epsilon_y}{\mu^2} + \frac{2L_g^2 C_f^2}{\mu^2 a_0^2} + 2\bar{\zeta} \log \left(\frac{C_b}{b_0} \right) + \bar{\zeta} \right), \tag{66}
\end{aligned}$$

其中第一个不等式由 $b_k \geq C_b \geq 2\bar{\zeta} L_g \frac{L_g}{\mu}$ 以及对于 $0 < m < 1$ 有 $1 - m \leq e^{-m}$ 得出, 特别地, 我们有 $C_b \geq 2\bar{\zeta} L_g \frac{L_g}{\mu}$ 且 $0 < \frac{\mu}{b_k} - \bar{\zeta} \frac{L_g^2}{b_k^2} < 1$ 成立, 第二个不等式由 (65) 得出。

与文献 [51] 类似, 我们有

$$b_K = b_{K-1} + \frac{\|\mathcal{G}_y g(x_t, y_t^{K-1})\|_{y_t^{K-1}}^2}{b_K + b_{K-1}} \leq b_{k_1} + \sum_{k=k_1}^{K-1} \frac{\|\mathcal{G}_y g(x_t, y_t^k)\|_{y_t^k}^2}{b_{k+1}} \tag{67}$$

同时, 我们有

$$\begin{aligned}
d^2(y_t^K, y^*(x_t)) & \leq d^2(y_t^{K-1}, y^*(x_t)) + \bar{\zeta} \frac{\|\mathcal{G}_y g(x_t, y_t^{K-1})\|_{y_t^{K-1}}^2}{b_K^2} + \frac{2 \left\langle \mathcal{G}_y g(x_t, y_t^{K-1}), \text{Exp}_{y_t^{K-1}}^{-1} y^*(x_t) \right\rangle_{y_t^{K-1}}}{b_K} \\
& \leq d^2(y_t^{K-1}, y^*(x_t)) + \bar{\zeta} \frac{\|\mathcal{G}_y g(x_t, y_t^{K-1})\|_{y_t^{K-1}}^2}{2b_K \bar{\zeta} L_g \frac{L_g}{\mu}} - \frac{\|\mathcal{G}_y g(x_t, y_t^{K-1})\|_{y_t^{K-1}}}{b_K L_g}
\end{aligned}$$

$$\leq d^2(y_t^{K-1}, y^*(x_t)) - \frac{(1 - \mu/2L_g)}{L_g} \frac{\|\mathcal{G}_y g(x_t, y_t^{K-1})\|^2}{b_K} \leq d^2(y_t^{k_1-1}, y^*(x_t)) - \frac{(1 - \mu/2L_g)}{L_g} \sum_{k=k_1}^{K-1} \frac{\|\mathcal{G}_y g(x_t, y_t^k)\|^2}{b_{k+1}},$$

其中第二个不等式由引理 F.3 和 $b_K \geq C_b \geq 2\bar{\zeta}L_g \frac{L_g}{\mu}$ 得出。

根据 (65)，我们有

$$\begin{aligned} \left(1 - \frac{\mu}{2L_g}\right) \sum_{k=k_1}^{K-1} \frac{\|\mathcal{G}_y g(x_t, y_t^k)\|_{y_t^k}^2}{b_{k+1}} &\leq L_g \left(d^2(y_t^{k_1}, y^*(x_t)) - d^2(y_t^K, y^*(x_t))\right) \leq L_g d^2(y_t^{k_1}, y^*(x_t)) \\ &\leq L_g \left(\frac{2\epsilon_y}{\mu^2} + \frac{2L_g^2 C_f^2}{\mu^2 a_0^2} + 2\bar{\zeta} \log\left(\frac{C_b}{b_0}\right) + \bar{\zeta}\right) \end{aligned}$$

那么，根据 (67) 以及 $\frac{1}{1-\mu/2L_g} \leq 2$ ，我们有

$$b_K \leq C_b + 2L_g \left(\frac{2\epsilon_y}{\mu^2} + \frac{2L_g^2 C_f^2}{\mu^2 a_0^2} + 2\bar{\zeta} \log\left(\frac{C_b}{b_0}\right) + \bar{\zeta}\right)$$

记 $\bar{b} := C_b + 2L_g \left(\frac{2\epsilon_y}{\mu^2} + \frac{2L_g^2 C_f^2}{\mu^2 a_0^2} + 2\bar{\zeta} \log\left(\frac{C_b}{b_0}\right) + \bar{\zeta}\right)$ 。那么在 (66) 下，考虑到当 $b \geq 2\bar{\zeta}L_g \frac{L_g}{\mu}$ 时 $\frac{\mu}{b} - \bar{\zeta} \frac{L_g^2}{b^2}$ 关于 b 的单调性，由于 $\bar{b} \geq b_K \geq 2\bar{\zeta}L_g \frac{L_g}{\mu}$ ，有 $\frac{\mu}{\bar{b}} - \bar{\zeta} \frac{L_g^2}{\bar{b}^2} \leq \frac{\mu}{b_K} - \bar{\zeta} \frac{L_g^2}{b_K^2}$ 成立，我们得到

$$d^2(y_t^K, y^*(x_t)) \leq e^{-(\frac{\mu}{\bar{b}} - \bar{\zeta} \frac{L_g^2}{\bar{b}^2})(K-k_1)} \left(\frac{2\epsilon_y}{\mu^2} + \frac{2L_g^2 C_f^2}{\mu^2 a_0^2} + 2\bar{\zeta} \log\left(\frac{C_b}{b_0}\right) + \bar{\zeta}\right) = e^{-(\frac{\mu}{\bar{b}} - \bar{\zeta} \frac{L_g^2}{\bar{b}^2})(K-k_1)} \frac{\bar{b} - C_b}{2L_g} \quad (68)$$

由于 $k_1 \leq \frac{\log(C_b/b_0)}{\log(1+\epsilon_y/C_b^2)}$ ，根据 (63) 中 $\bar{K}$ 的定义，显然有 $\bar{K} \geq k_1$ 。因此，根据 (68)，我们有

$$\|\mathcal{G}_y g(x_t, y_t^{\bar{K}})\|_{y_t^{\bar{K}}}^2 \leq L_g^2 d^2(y_t^{\bar{K}}, y^*(x_t)) \leq e^{-(\frac{\mu}{\bar{b}} - \bar{\zeta} \frac{L_g^2}{\bar{b}^2})(\bar{K}-k_1)} \frac{L_g(\bar{b} - C_b)}{2} \leq \epsilon_y,$$

这表明在最多 $\bar{K}$ 次迭代后，条件 $\|\mathcal{G}_y g(x_t, y_t^{\bar{K}})\|_{y_t^{\bar{K}}}^2 \leq \epsilon_y$ 得到满足，即对于所有 $t \geq 0$ 都有 $K_t \leq \bar{K}$ 成立。

关于解决线性系统所需的总迭代次数 N_t ，由于解决该系统不涉及收缩映射，其总迭代次数与双循环算法一致。证明完毕。

H.2 定理 3.2 的证明

在本小节中，我们结合前述引理来推导收敛速度界限。

证明. 根据引理 H.1，在 $t \geq t_1$ 以后，由于步长参数 $a_{t+1} > C_a \geq 2\bar{L}_F$ ，目标函数的单步下降满足：

$$\frac{1}{2a_{t+1}} \|\mathcal{G}F(x_t)\|_{x_t}^2 \leq F(x_t) - F(x_{t+1}) - \frac{1}{4a_{t+1}} \|\hat{\mathcal{G}}F(x_t, y_t^{K_t}, v_t^{N_t})\|_{x_t}^2 + \frac{\epsilon_{y,v}}{2a_{t+1}} \quad (69)$$

为了得到整体收敛性，我们对 $t = 0$ 到 $T-1$ 进行求和。为了处理可变步长带来的影响，我们利用自适应更新律 $a_{t+1}^2 = a_t^2 + \|\hat{\mathcal{G}}F_t\|^2$ ，通过对 (69) 两端同时乘以 $2a_{t+1}$ 并重新求和，可以得到：

$$\begin{aligned} \sum_{t=0}^{T-1} \|\mathcal{G}F(x_t)\|_{x_t}^2 &\leq \sum_{t=0}^{T-1} 2a_{t+1}(F(x_t) - F(x_{t+1})) - \sum_{t=0}^{T-1} \frac{1}{2} \|\hat{\mathcal{G}}F_t\|^2 + \sum_{t=0}^{T-1} \epsilon_{y,v} \\ &\leq 2a_T(F(x_0) - F^*) + \sum_{t=1}^{T-1} 2(a_{t+1} - a_t)(F(x_t) - F^*) - \frac{1}{2} \sum_{t=0}^{T-1} \|\hat{\mathcal{G}}F_t\|^2 + T\epsilon_{y,v} \quad (70) \end{aligned}$$

其中第二项使用了阿贝尔求和法 (Summation by parts)。利用 $F(x_t) - F^* \leq D_F$ (由假设 3.4 保证) 以及 $a_{t+1} - a_t \leq \frac{\|\hat{\mathcal{G}}F_t\|^2}{a_{t+1} + a_t}$, 我们可以进一步放缩误差项。

关键在于利用附录 H 中证明的步长参数有界性。根据命题 D.1 的证明, 内层步长参数 b_k 始终满足 $b_k \leq \bar{b}$ (即定理中的 $\tilde{C}$)。这保证了外层估计梯度 $\hat{\mathcal{G}}F$ 的范数是有界的, 即 $\|\hat{\mathcal{G}}F\| \leq C_f$ 。带入引理 H.2 对 a_T 的估计:

$$a_T \leq C_a + 2F_0 + \frac{2T\epsilon_{y,v}}{a_0} \quad (71)$$

将此上界代入 (70) 并两边除以 T , 得到:

$$\begin{aligned} \frac{1}{T} \sum_{t=0}^{T-1} \|\mathcal{G}F(x_t)\|_{x_t}^2 &\leq \frac{2a_T(F(x_0) - F^*)}{T} + \frac{2D_F}{T} \sum_{t=0}^{T-1} \frac{\|\hat{\mathcal{G}}F_t\|^2}{2a_t} + \epsilon_{y,v} \\ &\leq \frac{2(C_a + 2F_0)D_F}{T} + \frac{4\epsilon_{y,v}D_F}{a_0} + \frac{2D_F}{T} \log(a_T) + \epsilon_{y,v} \end{aligned} \quad (72)$$

其中 $\log(a_T)$ 项源于自适应步长的对数累积性质。由于我们设定内层迭代次数 $\bar{K}$ (公式 63) 使得 $\epsilon_{y,v}$ 满足 $O(1/T)$ 或通过自适应调节使误差项受控, 且 a_T 的增长中包含由 $\bar{b}$ 决定的对数项 $\log^k(T)$ 。

最终, 结合 a_T 的显式定义以及附录 H 中 $\bar{b}$ 对精度的贡献, 我们可以得出存在常数 $\tilde{C}_S$ 使得:

$$\frac{1}{T} \sum_{t=0}^{T-1} \|\mathcal{G}F(x_t)\|_{x_t}^2 \leq \tilde{C}_S \frac{\log^4(T)}{T} = \tilde{O}\left(\frac{1}{T}\right), \quad (73)$$

由此, 定理 3.2 得证。 □

□